Budapesti Műszaki és Gazdaságtudományi Egyetem

Villamosmérnöki és Informatikai Kar

Távközlési és Mesterséges Intelligencia Tanszék

Tudásgráf-építés műszaki rajzokból és adatlapokból skálázható Q&A rendszerhez

Knowledge Graph Construction from Engineering Drawings and Datasheets for a Scalable Q&A System

Tudományos Diákköri Konferencia dolgozat

Szerzők: Szabó Zsombor István, Kiszely Benedek

Témavezető: [TÉMAVEZETŐ]

Budapest, 2026

Kivonat

Egy ipari üzemet sokféle dokumentum ír le: a csővezeték- és műszerezési rajzok (P&ID) a kapcsolatokat, a gyártói adatlapok az egyes eszközök jellemzőit. Egy mérnöki kérdés gyakran mindkettőt igényli. Két korábbi munkánk ugyanennek a dokumentációnak két oldalát dolgozta fel: az egyik többlapos rajzokból épít üzemi tudásgráfot és egy szabályozott Cypher–ágens kaszkáddal válaszol rajta, a másik egy-egy eszköz adatlapjából épít ISO 15926 / QUDT szerinti gráfot, amelyben a feltételek és a kereszthivatkozások megmaradnak.

Ebben a dolgozatban a két munkát összekötjük. Egy seedelt, négylapos példaüzemhez, amelynek mind a 24 tagelt fizikai eleméhez gyártói adatlap tartozik, egyetlen Neo4j-adatbázisba töltjük az üzemi réteget és hét eszköz adatlapgráfját, és egy tagalapú kapcsolattal kötjük össze őket. Három módszert hasonlítunk össze: a kaszkád kiegészítését az adatlapréteggel és egy új adatlap-primitívvel (M1), egy routert a két meglévő rendszer fölött (M2) és egy gráf nélküli baseline-t (M3). A méréshez 60 kérdést állítottunk össze négy családban (csak rajz, csak adatlap, összetett, megválaszolhatatlan), részben programmal, részben modellel előállított referenciaválaszokkal; a 40 kérdéses teszthalmazt befagyasztottuk.

A teszten a legjobb a router volt GLM-5.3 Flash modellel (31 helyes válasz a 40-ből), a gráf nélküli baseline 30, az összevont gráfon dolgozó M1 25 helyes választ adott; GPT-6 Lunával a három módszer különbsége nem volt szignifikáns. Egyik módszer sem hallucinált a teszten; a 10 megválaszolhatatlan kérdésből GLM-mel mindegyik módszer mind a 10-et, Lunával 9-et ismerte fel. A különbség az adatlapi és az összetett kérdéseken jelent meg, ahol az M1 egylekérdezéses válaszai gyakran hiányosak. Egy kiegészítő mérésen, 12 több adatlapot összevető kérdésen teljesen helyes választ csak a router adott (GLM-mel 3-at). Kérdésenként az M1 volt a legdrágább, az M3 a legolcsóbb. Az eredmények egy kis, szintetikus üzemre érvényesek, modellkészítésű referenciákkal.

Kulcsszavak: tudásgráf, GraphRAG, nagy nyelvi modellek, P&ID, műszaki adatlapok, kérdés-válaszolás, ipari dokumentáció.

Abstract

An industrial plant is described by many kinds of documents: piping and instrumentation diagrams (P&IDs) show how the items are connected, vendor datasheets give each device's specification. Engineering questions often need both. Our two earlier projects covered the two sides of the same documentation: one builds a plant knowledge graph from multi-sheet drawings and answers over it with a governed Cypher-then-agent cascade, the other turns a single device's datasheet into an ISO 15926 / QUDT graph that keeps conditions and cross-references.

This work joins the two. For a seeded four-sheet example plant in which every one of the 24 tagged physical items has a vendor datasheet, we load the plant layer and the datasheet graphs of seven devices into one Neo4j database and link them by tag. We compare three methods: the cascade extended with the datasheet layer and a new datasheet primitive (M1), a router over the two existing systems (M2), and a graph-free baseline (M3). We built 60 questions in four families (drawing only, datasheet only, combined, unanswerable) with reference answers partly assembled by program and partly written by a model, and froze a 40-question test set.

On the test set the router with GLM-5.3 Flash was best (31 of 40 correct), the graph-free baseline answered 30 and the merged-graph method M1 25 correctly; with GPT-6 Luna the differences were not significant. No method hallucinated on the test set; with GLM every method recognised all 10 unanswerable questions, with GPT-6 Luna 9 of 10. The differences appear on datasheet and combined questions, where M1's single-query answers are often incomplete. On a supplementary set of 12 questions that compare several datasheets, only the router gave fully correct answers (3 with GLM). M1 was the most expensive per question and M3 the cheapest. The results hold for one small synthetic plant with model-written references.

Keywords: knowledge graph, GraphRAG, large language models, P&ID, technical datasheets, question answering, industrial documentation.

Tartalomjegyzék

Kivonat ... 2
Abstract ... 3
Tartalomjegyzék ... 4
1. Bevezetés ... 7
1.1 Kutatási kérdések ... 7
1.2 Hozzájárulások ... 8
1.3 Munkamegosztás ... 8
1.4 A dolgozat felépítése ... 8
2. Háttér és kapcsolódó munkák ... 9
2.1 P&ID-k és gyártói adatlapok ... 9
A P&ID mint dokumentum ... 9
A DEXPI és a pyDEXPI ... 9
A gyártói adatlap ... 10
Szabványok az adatlapi tények ábrázolására ... 10
Tulajdonsággráf és RDF ... 11
Feltételes, n-áris tények ... 11
2.2 Kérdés-válaszolás P&ID-ken ... 11
Visszakeresés a rajz gráfján ... 11
A rajzok gráffá alakítása ... 12
Üzemi méret ... 12
2.3 Kérdés-válaszolás műszaki dokumentumokon ... 13
2.4 GraphRAG és visszakeresési stratégiák ... 13
Mikor segít a gráf? ... 13
Gráfeszközöket hívó ágensek ... 14
Kaszkád és önjelzés ... 14
2.5 Összevetés ... 14
2.6 A hiányzó lépés ... 15
3. Adatok és feladat ... 16
3.1 A kis példaüzem ... 16
3.2 A nagy példaüzem ... 17
3.3 Adatlapok ... 17
3.4 A kérdéssor ... 18
3.5 Pontozás ... 18
4. Az összevont tudásgráf ... 20
4.1 A rajzoldali réteg ... 20
Az üzemi réteg és a vonalnézet ... 20
4.2 Az adatlapoldali réteg ... 21

Az adatlapréteg a Neo4j-ben ... 21
4.3 Az összekötés ... 22
4.4 Betöltés ... 23
5. Kérdés-megválaszolási módszerek ... 24
5.1 Közös építőelemek ... 24
A rajzoldali kaszkád ... 24
Az ágens primitívjei ... 25
Az adatlapoldali A2 ... 26
5.2 M1 — egy gráf, egy lekérdezés ... 26
5.3 M2 — router ... 27
5.4 M3 — gráf nélküli baseline ... 27
5.5 A módszerek várható erősségei és gyengeségei ... 28
M1 ... 28
M2 ... 28
M3 ... 29
5.6 Költség és mérés ... 29
6. Kiértékelés ... 30
6.1 Beállítás ... 30
6.2 A fejlesztés a kis üzemen ... 30
6.3 Eredmény a nagy üzemen ... 30
6.4 A gráf szerepe a nagy rajzon ... 31
6.5 Költség és késleltetés ... 31
6.6 Útvonalak ... 32
6.7 Több adatlapos kérdések ... 32
6.8 Hibaelemzés ... 33
7. Demó és esettanulmány ... 34
7.1 A demó felépítése ... 34
7.2 Két kérdés végigkövetve ... 34
Összetett kérdés a routerrel ... 35
Megválaszolhatatlan kérdés és a részletes „nincs benne” ... 35
7.3 Tanulságok ... 36
8. Összefoglalás ... 37
8.1 Válaszok a kutatási kérdésekre ... 37
8.2 Korlátok ... 37
8.3 Továbblépés ... 37
Irodalomjegyzék ... 39
Függelék ... 42
A. Példakérdések családonként (dev halmaz) ... 42
B. Az M2 router rendszerüzenete ... 42

C. Az M1 Cypher-szintjének sémakiegészítése (eleje) és az új primitív leírása 43
D. A két forrásfolyamat részletei 43
A plantgraph üzemgenerátora 43
A plantgraph lapokra bontója és a lapközi csatlakozók 44
A plantgraph feloldója 44
A plantdocs folyamatának lépései 45
A plantdocs célformátuma 46
A plantdocs RDF-modellje 47
E. A módszerek részletei 48
Az ágens primitívjei 48
Az adatlapoldali A2 lépései 49
Az M1 sémakiegészítésének felépítése 50
Az M2 router protokollja 50
F. További demó-képernyőképek 50
Rajzi útvonal egyetlen lekérdezéssel (M1) 50
Több adatlapos kérdés (M2) 51
Két további kérdés képernyőkép nélkül 52
G. A kis üzem mérései 52
Fejlesztési iterációk 52
Végső mérés a teszthalmazon 53
Költség és késleltetés 54
Útvonalak 55
Összetett, több adatlapos kérdések 55
Hibaelemzés 56

1. Bevezetés

Egy ipari üzemet sokféle dokumentum ír le. A csővezeték- és műszerezési rajzok (angol rövidítéssel P&ID) megmutatják, hogyan kapcsolódnak egymáshoz a berendezések, szelepek és műszerek; a gyártói adatlapok megadják, mire képes az egyes eszköz. A rajzon minden elemnek egyedi azonosítója, tagje van (például P-101 egy szivattyú), és ez köti össze a rajzot az eszköz adatlapjával. Egy üzemeltető vagy tervező mérnök kérdései gyakran mindkét dokumentumfajtát érintik: „Mekkora a megengedett legnagyobb nyomás azon a szelepen, amely a P-101 szivattyú nyomóoldalát elzárja?" A válaszhoz előbb a rajzon kell megtalálni a szelepet (a vezeték akár egy másik rajzlapon is folytatódhat), majd a tagje alapján az adatlapját, és abban a megfelelő feltételhez tartozó értéket. Ma ezt kézzel végzik.

A nagy nyelvi modellek (LLM) kézenfekvő eszköznek tűnnek, de az üzemi dokumentáció nehéz terep számukra. A lényeges információ gyakran nem egyetlen elemben van, hanem a kontextusban: egy táblázat fejlécében, egy értéket korlátozó lábjegyzetben, vagy egy lapközi csatlakozóban, amely egy csővezetéket egy másik lapon folytat. Ezt a szerkezetet egy tudásgráf teheti explicitté: olyan adatbázis, amelyben a dolgok csúcsok, a köztük lévő kapcsolatok élek, és amelyből a modell a kérdéshez tartozó részt visszakeresve válaszol (az angol szakirodalomban: GraphRAG). Ez azonban csak akkor működik, ha a gráf megőrzi a kontextust.

A munka két részből épül fel, mindkettő az egyik szerző egyéni munkája.

- **A rajzoldali rész** (Kiszely Benedek) az egész üzemet leíró tudásgráfot épít a rajzlapokból: a berendezések és műszerek csúcsok, a csövek és jelvezetékek élek, és a lapok határán megszakadó vezetékek újra összekapcsolódnak. Erre a gráfra építve egy kétlépcsős rendszer válaszol a kérdésekre: először egyetlen adatbázis-lekérdezéssel próbálkozik, és ha ez nem elég, egy gráfbejáró eszközöket hívó LLM-ágens veszi át a kérdést. A rész fő kérdése, hogy ez a megközelítés több száz, akár ezer lapos üzemen is működik-e.
- **Az adatlapoldali rész** (Szabó Zsombor) egy-egy eszköz PDF-adatlapjából épít tudásgráfot, amelyben minden érték mellett megmarad a mértékegysége, az érvényességi feltétele (például „csak 100 °F alatt") és a forrásoldala, mert egy feltétel nélküli érték nem hiányos, hanem hibás. A gráf nemzetközi ipari szabványok szókészletére épül, ezeket a 2. fejezet mutatja be.

Ebben a dolgozatban a két részt összekapcsoljuk: a rajzi gráf elemeit a tagjük alapján az adatlapgráfokhoz kötjük, és megmérjük, mennyire jól válaszolnak a rendszerek a két dokumentumfajtát együtt igénylő kérdésekre. A módszereket egy kis, négylapos üzemen fejlesztettük, majd változtatás nélkül egy hétszer nagyobb, 27 lapos üzemen mértük meg.

1.1 Kutatási kérdések

- **RQ1.** Megválaszolhatók-e a rajzot és az adatlapot összekötő kérdések egyetlen összevont tudásgráfon (M1), és hogyan viszonyul ennek pontossága egy olyan irányítóéhoz (router, M2), amely a két rész meglévő rendszerét külön hívja, illetve egy gráf nélküli alapmódszeréhez (baseline, M3)?
- **RQ2.** Hogyan változik a módszerek pontossága és költsége, ha a négylapos üzemről a 27 laposra lépünk, a módszerek változtatása nélkül?

- **RQ3.** Mely kérdéscsaládokon segít a gráf, és milyen hibák jellemzők az egyes módszerekre?

1.2 Hozzájárulások

1. Két közös példaüzem: egy négylapos, 26 tagelt elemes és egy 27 lapos, 190 tagelt elemes P&ID ugyanazzal a generátorral, amelyek elemeihez program rendeli hozzá hét eszköz gyártói adatlapját.
2. Az összevont tudásgráf: a rajzi üzemi réteg és hét eszköz adatlapgráfja egy Neo4j-adatbázisban, egy tagalapú kapcsolattal összekötve, egy paranccsal újratölthetően.
3. Három kérdés-válaszoló módszer a két rész meglévő kódjára építve: a rajzoldali rendszer kiegészítése az adatlapréteggel és egy új adatlap-eszközzel (M1), egy irányító a két rendszer fölött (M2) és egy gráf nélküli alapmódszer (M3).
4. Üzemenként egy 60 kérdéses, négy családra bontott kérdéssor és 12 több adatlapot összevető kérdés, részben programmal, részben modellel előállított referenciaválaszokkal; a három módszer mért összehasonlítása két modellel mindkét üzemen.
5. Egy webes demó, amely bármely módszerrel válaszol, és megmutatja az útvonalat, a lekérdezéseket és az adatlapi forrásoldalakat.

1.3 Munkamegosztás

A rajzoldali rendszer (generátor, lapokra bontás, üzemi gráf, kaszkád) Kiszely Benedek, az adatlapoldali rendszer (feldolgozó folyamat, ISO 15926 gráf, A2-lekérdezés) Szabó Zsombor egyéni munkájának eredménye; ezeket változtatás nélkül használjuk. Az összevonást, a kérdéssort, a három módszert, a mérést és a demót közösen készítettük. A döntéseket és a mért számokat a projekt naplói rögzítik (`docs/dontesek.md`, `docs/eredmenyek.md`).

1.4 A dolgozat felépítése

A 2. fejezet a hátteret és a kapcsolódó munkákat foglalja össze. A 3. fejezet bemutatja a két példaüzemet, az adatlapokat és a kérdéssort, a 4. fejezet az összevont tudásgráfot, az 5. fejezet a három módszert. A 6. fejezet a nagy üzemen mért eredményeket, a 7. fejezet a demót és egy esettanulmányt, a 8. fejezet a következtetéseket és a korlátokat tárgyalja. A Függelék a példakérdéseket (A), a két módszer promptjainak részleteit (B, C), a két forrásfolyamat részletes leírását (D), a módszerek lépéseinek részleteit (E), további demó-képernyőképeket (F) és a kis üzemen végzett mérések teljes leírását (G) tartalmazza.

2. Háttér és kapcsolódó munkák

Ebben a fejezetben összefoglaljuk a dokumentumokat, a szabványokat és a nyelvimodell-alapú kérdezési módszereket, amelyekre a dolgozat épül, majd egy táblázatban vetjük össze a kapcsolódó munkákat. Az irodalmat a két forrásrepó irodalmi jegyzeteiből válogattuk; csak olyan forrást idézünk, amelyet a jegyzet szerint ténylegesen elolvastak.

2.1 P&ID-k és gyártói adatlapok

A P&ID mint dokumentum

A csővezeték- és műszerezési rajz (P&ID) az üzem központi tervdokumentuma: megmutatja, mely berendezések, szelepek és műszerek vannak az üzemben, és hogyan kapcsolódnak egymáshoz [Toghraei2019], [Christensen2020].

A rajzi elemeket a tag azonosítja (pl. P-101, FT-202). A tag betűi az elem fajtáját és szerepét jelölik, a műszereknél az első betű a mért változót (F áramlás, P nyomás, L szint, T hőmérséklet), a további betűk a funkciót (például T távadó, IC szabályozó); a betűk a hurokszámmal együtt adnak egyedi azonosítót [AIChE2010a]. A csővezetékek azonosítója, a vezetékszám szokás szerint névleges átmérőből, közegkódból, sorszámból, csőosztályból és szigetelésből áll [AIChE2010b]. A példaüzem tagjei egyszerűsített mintát követnek: a `P-1-3` az 1. egység harmadik szivattyúja, az `FT-2-2` a 2. egység második szabályozókörének áramlástávadója.

Egy valódi üzem rajza sok lapra tagolódik. A laphatáron átmenő vezetéket lapközi csatlakozó (off-page connector) folytatja egy másik lapon: a lap szélén álló, feliratozott jel, amely megnevezi a másik lapot, és amelyhez a másik lapon egy párja tartozik. A rajzi szabályok szerint a többlapos rajzok vezetékvégei kölcsönösen hivatkoznak egymásra [ISO10628-1], és a rajzok közötti hivatkozó jelek jól strukturált rajzszámot hordoznak, amely akár reguláris kifejezésekkel is összeköthető [Mani2020]. A laphatár két különböző kapcsolatot vághat el. Az egyik egy cső: ekkor két csatlakozó jelzi, hogy a vezeték a másik lapon folytatódik. A másik egy elem: ugyanaz a berendezés több lapon is megjelenik, egyszer teljes adatokkal, máshol csak a tagjével. Az első esetben a hiba látható (a gráf szétesik), a másodikban nem: a gráf épnek látszik, de a válaszok hiányosak.

A DEXPI és a pyDEXPI

A rajz digitális cseréjének szabványa a DEXPI, amely UML információs modell saját XML-szerializációval [DEXPI2025]. A rajzi szabvány (például az ISO 10628) azt mondja meg, hogyan néz ki egy szimbólum; az információs modell azt, milyen osztályok és attribútumok vannak; az ontológia ugyanezt formális logikával, globális azonosítókkal írja le. A DEXPI információs modell: OWL- vagy RDF-formája nincs, de az osztálydefiníciói az ISO 15926 4. részének referenciakönyvtárából származnak, így szemantikailag le van horgonyozva [DEXPI2025]. Egy DEXPI-modell egyetlen rajzot ír le; rajzkészletet, és azt, hogy két lapon lévő elem ugyanaz, nem modellez.

A DEXPI szemantikus változata épül: a DEXPI egyesület hírei szerint a TotalEnergies a BFO-hoz és az IDO-hoz igazított DEXPI-n dolgozik [DEXPI2026news], a POSC Caesar Arrowhead-

kézikönyve pedig a DEXPI életciklus-zónáit és tulajdonságmodelljét igazítja az IDO-hoz, egyelőre egyetlen, kézzel írt szivattyús példán [ArrowheadHandbook]. Az OPC UA felé is van leképezés [OPC30250]. Ezért ebben a dolgozatban nem építünk P&ID-ontológiát; a rajzoldalon a DEXPI osztályneveit használjuk címkeként, ahogy a kapcsolódó munkák is.

A DEXPI Python-megvalósítása a pyDEXPI: a DEXPI adatmodell Pydantic-osztályai, Proteus XML betöltő és NetworkX-gráffá alakító export [pyDEXPI]. A ChatP&ID és elődje a pyDEXPI osztálynevét teszi a gráfcsúcsok címkéjébe [Alimin2026], [Alimin2025]; Benedek generátora is pyDEXPI-modellt épít, ezért a példaüzem elemei is ezeket az osztályneveket viselik (`CentrifugalPump`, `CheckValve`).

A gyártói adatlap

A rajz csak a kapcsolatokat mutatja; az egyes eszközök műszaki jellemzőit (nyomás- és hőmérséklethatár, anyag, méret, opciók) a gyártói adatlapok tartalmazzák. Egy adatlap néhány oldalastól több mint száz oldalasig terjedő PDF táblázatokkal, lábjegyzetekkel, feltételekhez kötött értékekkel és diagramokkal; a példaüzem adatlapjai 2 és 114 oldal közöttiek (EXP-007).

Az adatlapi tény ritkán egyetlen szám. Egy szabályozószelep adatlapján egy hőmérsékleti határ csak egy adott testanyagra és csatlakozóméret-tartományra érvényes, egy lábjegyzet tovább szűkíti, és ugyanaz az érték két mértékegységben is ki van nyomtatva. Ha egy rendszer ebből csak a számot és az egységet őrzi meg, a válasza nem hiányos, hanem hibás lehet. A plantdocs végső mérésén éppen a feltételes kérdéseken volt nagy a két lekérdezési módszer különbsége: a 31 feltételes kérdésből az A1 21-re, az A2 28-ra, a 17 több feltételt kombináló kérdésből 7-re, illetve 15-re adott helyes választ (a plantdocs `_results.md` szerint, EXP-0041).

Szabványok az adatlapi tények ábrázolására

Az adatlapi tények szemantikus ábrázolására több, egymásra épülő szabvány áll rendelkezésre.

- Az **Industrial Data Ontology (IDO)** W3C OWL 2 felső ontológia ipari eszköz- és folyamatadatokhoz; korábban ISO/TR 15926-14 volt, ma ISO 23726-3 néven szabványosítják [IDO]. Ez adja a nyelvtant: fizikai tárgy, rész–egész viszony, információs tárgy, érték és mértékegység.
- A **POSC Caesar referenciakönyvtára (PCA RDL)** a konkrét berendezés-, cső- és műszerosztályok és tulajdonságok gyűjteménye; a régi azonosítói ma is feloldhatók, az új, gépileg olvasható forma hitelesítéshez kötött [PCARDL].
- A **CFIHOS** az üzemátadáskor elvárt adatokat írja le (tag- és berendezésosztály-attribútumok, dokumentum-metaadatok); referenciaadatai Excelben és CSV-ben érhetők el [CFIHOS].
- A **QUDT** a mértékegységek, mennyiségfajták és dimenziók szemantikus leírása; berendezést és topológiát nem modellez [QUDT].

Mérlegelhető, de a célra nem alkalmas szókészlet az OntoCAPE, amely hosszú ideje nem frissül [OntoCAPE], a berendezést és topológiát nem modellező SOSA/SSN [SOSASSN2017], a folyamatüzemi modul nélküli IOF [IOF] és a szivattyú- vagy szeleposztályt nem ismerő schema.org [SchemaOrg]. A plantdocs ezért az ISO 15926 vonalat választotta (4. fejezet).

Ugyanerre a vonalra épít a szelepspecifikációs tervezési szabványok (például az ASME B16.34) IDO-alapú, moduláris OWL-ontológiává alakítása is [Gjerver2025]; mivel a DEXPI osztálydefiníciói is innen származnak, a rajzi és az adatlapi oldalnak közös a szemantikai gyökere.

Tulajdonsággráf és RDF

Az RDF-ben minden állítás egy alany–állítmány–tárgy hármas, az azonosítók globálisak (IRI), és az élnek nincs saját tulajdonsága. A tulajdonsággráfban (labeled property graph, LPG; legismertebb megvalósítása a Neo4j) a csúcsoknak és az éleknek is lehetnek tulajdonságaik, az azonosítók lokálisak. A ChatP&ID szerzői mérlegelték az RDF-et, de az attribútumokban gazdag mérnöki adat miatt a tulajdonsággráfot választották [Alimin2026], és Benedek rendszere is Neo4j-re épül. A plantdocs adatlapgráfja RDF-ben készül (mert az IDO OWL 2), de a neosemantics (n10s) bővítménnyel Neo4j-be is betölthető; ez a híd teszi lehetővé, hogy a két réteg egy adatbázisba kerüljön.

Feltételes, n-áris tények

Az adatlapi tények jelentős része n-áris: egy érték egy alanyról, egy tulajdonságról és több feltételről egyszerre szól. Az ilyen tények bináris hármasokra bontása elveszíti a feltételt, és szemantikai széttöredezéshez vezet [HyperRAG2026]. Erre a hiper-relációs tudásgráfok és a hipergráfos RAG ad ábrázolást. A minősítők (qualifiers) javítják a linkpredikciót [StarE2020], a HyperGraphRAG pedig az n-áris tényeket hiperélekként tárolja [HyperGraphRAG2025]. A plantdocs jegyzetei szerint az ábrázolás tehát elvben megoldott; ami nehéz, az a dokumentum szerkezetében (táblázatfejlécben, lábjegyzetben, diagramtartományban) kódolt feltételek kinyerése. A plantdocs a feltételeket a POSC Caesar adatlap-mintájának esetcsúcsaival ábrázolja; ezt a 4. fejezetben mutatjuk be.

2.2 Kérdés-válaszolás P&ID-ken

Visszakeresés a rajz gráfján

A legközelebbi előzmény a ChatP&ID [Alimin2026]: DEXPI-rajzokat pyDEXPI-vel Neo4j-gráffá alakít, és egy iteratív ágens négy visszakeresési eszköz közül választ. A négy eszköz négy különböző választ ad arra, hogyan jut el a gráf releváns része a modellhez. A ContextRAG az egész (sűrített) gráfot szövegként a promptba teszi, keresés nélkül. A VectorRAG a kérdéshez jelentés szerint leghasonlóbb csúcsok leírását adja, beágyazásvektorok koszinusz-hasonlósága alapján. A PathRAG egy így talált kiinduló csúcsból lépésenként bejárja a szomszédokat. A CypherRAG-ban a modell a kérdést Cypher-lekérdezéssé fordítja, az adatbázis lefuttatja, és az eredmény kerül a promptba. Egyetlen lapon, 19 kérdésen a ContextRAG adta a legjobb eredményt; a szerzők szerint viszont ez a módszer többlapos rajzoknál nem skálázódik. Egy korábbi munka ugyanettől a csoporttól a sűrített gráfot GraphML-ként, visszakeresés nélkül adja a modellnek, egy folyamatábrán, három kérdésen értékelve [Alimin2025]. A legnagyobb közölt P&ID-kérdéskészlet a PIDQA-é: 500 szintetikus rajzlapon 64 000 programmal előállított kérdés-válasz pár, négy kategóriában (egyszerű és térbeli számlálás, térbeli kapcsolat, értékalapú kérdés). A rajzból képfelismeréssel tulajdonsággráf készül Neo4j-ben, a kérdést pedig egy LLM fordítja

Cypher-lekérdezéssé; minden kérdés egyetlen lapra vonatkozik, lapokon vagy dokumentumokon átívelő kérdés nincs benne [Gupta2025].

Raszteres rajzokon a Gadekar és társai által javasolt módszer előbb visszanyeri a folyamatgráfot, majd a látás-nyelvi modell a topológiai kérdésekre csak hét, tényt visszaadó gráfoperátoron keresztül válaszolhat [Gadekar2026]; a TopoPID-VQA kérdésein ez a megkötés jelentősen javítja a pontos egyezést, de egylapos, szintetikus rajzokon. A szoftveres előzmények között egy nyílt LangGraph-ágens hét általános gráfeszközzel kérdez DEXPI-fájlokon, kérdésenként egy fájlon [PidGraphAgent2026], egy ipari esettanulmány pedig olyan Neo4j-tudásgráfot ír le, amely helyreállítja a lapok közötti kapcsolatokat, és fölötte egy ágens előre definiált gráflekérdező eszközökkel és szabad Cypherrel válaszol, kiértékelés közlése nélkül [Kochanski2026].

A rajzok gráffá alakítása

A rajzok digitalizálását mi nem végezzük el, de a kérdés-válaszolás bemenete ennek a kimenete. Egy transzformeres módszer a szimbólumokat és a kapcsolataikat együtt jósolja, és ehhez kiadta a PID2Graph adatkészletet, amelynek gráfjai tisztán geometriaiak, címkék és lapok közötti megoldókulcs nélkül [Sturmer2024], [PID2Graph2025]. Ipari rajzokból automatikus tudásgráf-építést [Lopomo2026], a pyDEXPI-gráfon szabályalapú javítást [SchulzeBalhorn2025], és mesterséges rajzgenerálást [Hirtreiter2022] is javasoltak. A képfelismerés töredezett vonalszakaszait folytonos kapcsolati gráffá egyesítő módszer [Prusty2025] és a digitalizálást tagkinyerésként és topológia-következtetésként, két lépésben, multimodális nyelvi modellel megoldó megközelítés [Zhu2026a] is a rajz gráfját állítja elő, amelyre a kérdés-válaszolás épül. Valódi, többlapos, nyilvános rajzsorozatból kevés van; az OPEN100 sorozat 12 lapja ezek közé tartozik [OPEN100].

Üzemi méret

A fenti munkák közös vonása, hogy egy-egy rajzlapot vizsgálnak, és a rajzon kívüli dokumentumokat (adatlapokat) nem kapcsolják be. Kiszely Benedek egyéni munkája a P&ID-QA-t üzemi méretben vizsgálja: seedelt, többlapos szintetikus üzemeken, ahol a lapokra bontás a megoldókulcs, mert nyilvános, lapközi megoldókulccsal ellátott többlapos rajzkészlet nincs. Az ott mért kaszkád a README szerint a lezárt teszten (460 kérdés, a fejlesztés során nem látott üzemeken) 100 lapos üzemen 0,937, 1000 lapos üzemen 0,917 pontosságot ért el. A ContextRAG pontossága 1-ről 30 lapra 0,824-ről 0,658-ra csökkent, miközben a kaszkádé 0,941-ről 0,947-re változott, a ContextRAG relatív költsége a kaszkádéhoz képest 1,8-szorosról 41,5-szeresre nőtt, és a szerializált rajz körülbelül 143 lap fölött már nem fér el a promptban (Kiszely, plantgraph README).

A valósághűbb v2 generátor üzemein a befagyasztott v1 rendszer gyengébb, ezért Benedek egy külön megjelölt, hangolt rendszert (V2T) épített és fagyasztott be. Két, a hangolás során nem látott v2 üzemen (kb. 100 és kb. 1000 lap, egyenként 163 kérdés) a V2T kaszkádja 154, illetve 156 helyes választ adott, a v1 rendszer 145, illetve 144-et (plantgraph EXP-0007-V2T-VAL). A létramérésen (R4, regisztrált tesztseedek) a kaszkád pontossága 1, 3, 11 és 30 lapon 0,957 / 0,885 / 0,909 / 0,924 volt, a ContextRAG-é 1, 3 és 11 lapon 0,686 / 0,654 / 0,614. A ContextRAG kérdésenkénti költsége 1 lapon a kaszkád 3,79-szerese, 11 lapon

21,57-szerese, és a szerializált rajz kb. 62 lap fölött már nem fér el a promptban (plantgraph EXP-0007-R4). A lezárt v2-teszten (R5, regisztrált tesztseedek, 440 kérdés üzemenként) a V2T kaszkádja kb. 100 lapon 401 (0,911), kb. 1000 lapon 392 (0,891) helyes választ adott; a változás (−0,020, 95% CI −0,059 és +0,018 között) nem szignifikáns, a kérdésenkénti költség 0,00137, illetve 0,00148 USD, a medián késleltetés 7,1, illetve 7,5 s. A hangolás során nem látott kérdéscsaládokon (100 kérdés) a pontosság 0,770, illetve 0,740, a különbség szinte teljesen a lefelé izolációs (DOWNSTREAM_ISOLATION) kérdésekből jön, ahol a 20-ból mindkét méretnél 2 volt helyes (plantgraph EXP-0007-R5). Ezek a számok háttérként szerepelnek; jelen munka nem méri őket újra, de a 6. fejezetben ezekre támaszkodunk, amikor a gráf nélküli módszer skálázódásáról beszélünk.

2.3 Kérdés-válaszolás műszaki dokumentumokon

Gyártási dokumentumokon a Document GraphRAG a dokumentum saját szerkezetéből és egy könnyű, automatikusan épített példánygráfból épít tudásgráfot [Knollmeyer2025]; a szerzők elismerik, hogy szakterületen az automatikus tudásgráf-építés pontatlan, ezért ma is főleg kézi munka. Ipari tudásbázison a Golden-Retriever a visszakeresés előtt egy reflexiós lépésben azonosítja és tisztázza a szakzsargont és a rövidítéseket [GoldenRetriever2024]. A műszaki dokumentumokba ágyazott táblázatokat és szerkezetet a visszakeresésben külön kezelő, strukturált adatokat figyelembe vevő RAG-irány [StructRAG2025] azt jelzi, hogy az adatlapi táblázatok a sima szövegdarabolástól eltérő kezelést igényelnek. Mérnöki rajzokat és kézikönyveket feldolgozó látás-nyelvi modellek egy friss benchmarkon megtalálják a tételeket, de gyakran pontatlanul írják le őket, és a szövegátfedésen alapuló metrikák alulmérik a képességüket; a szerzők ezért keresztbírálós LLM-értékelést használnak [Kumar2026]. Ezért a szabad szöveges válaszokat mi is bírálóval pontozzuk (3. fejezet).

Szabó Zsombor egyéni munkája (plantdocs) egyetlen eszköz adatlapjából épít ISO 15926 / QUDT szerinti tudásgráfot, amelyben a feltételek és a kereszthivatkozások külön elemek maradnak. Két lekérdezési módszert hasonlít össze: A1 (RDF + SPARQL) és A2 (Neo4j + Cypher, vektoros kereséssel). A plantdocs végső mérésén (EXP-0041, a Rosemount 3051 adatlap 200 befagyasztott kérdésén, GLM-mel, vak bírálóval) az A1 141, az A2 172 kérdésre adott helyes választ (a plantdocs `_results.md` szerint). Ebben a munkában az A2 az adatlapoldal alapja.

2.4 GraphRAG és visszakeresési stratégiák

Mikor segít a gráf?

A gráfalapú RAG nem mindig jobb a szövegalapúnál. Egy benchmark szöveges korpuszon méretfüggő keresztezést mutatott ki a sima RAG és egy gráfalapú módszer között: kis korpuszon a sima RAG nyer, és a gráf előnye a korpusz méretével jelenik meg [Xiang2025]. A ChatP&ID egylapos eredménye és Benedek üzemi méretű mérései ugyanezt a mintát mutatják a rajzokon; a mi négylapos példaüzemünkön ezért a gráf nélküli módszer erős ellenfél.

Ha több visszakeresési stratégia áll rendelkezésre, kérdésenként lehet közöttük választani. A GraphRAG-Router megerősítéses tanulással tanított útválasztója kérdésenként választ GraphRAG-módszer és nyelvi modell között, és ezzel csökkenti a nagy modell hívásainak számát [Fan2026]. A mi M2 routerünk ennek egyszerű, tanítás nélküli változata: egy nyelvi modell dönti el lépésenként, melyik meglévő rendszert hívja.

Gráfeszközöket hívó ágensek

A tudásgráf-kérdés-válaszolás bevett mintája az ágens, amely lépésenként eszközöket hív a gráfon, és az eredményekből állítja össze a választ. A KBQA-Agent hét tudásbázis-eszközt ad (relációk, szomszédok, attribútumok, legnagyobb és legkisebb érték, metszet, darabszám), amelyek a korábbi lépések eredményeit megnevező változókon dolgoznak [KBQAAgent2024]. Hasonló mintát követ a KG-Agent [KGAgent2024] és a Graph-CoT [GraphCoT2024]. A skála másik végén a szabad Cypher áll: a Neo4j MCP-szervere mindössze sémalekérdező, olvasó és író Cypher-eszközt ad, a lekérdezést a modell írja [MCPNeo4j].

Benedek ágense a KBQA-Agent családjába tartozik: hat általános, egymással komponálható üzemi primitívet hív, az eredményeket hivatkozással adja tovább (plantgraph README, ADR-0034); a mi `datasheet_fact` primitívünk ezt a készletet bővíti (5. fejezet).

Kaszkád és önjelzés

A kaszkád (lépcsős módszer) a kérdést előbb a legolcsóbb módszernek adja, és csak akkor viszi tovább, ha az olcsó válasz gyanús. A gyanú forrása önjelzés: olyan jel, amelyet a lépcső maga ad a válaszáról, a helyes válasz ismerete nélkül, például a hibát dobó vagy üres lekérdezés. Az ilyen szabály nem illeszt paramétert a mért adatra, ezért kevésbé hajlamos a túlillesztésre, mint a kérdéstípus szerinti útválasztás (Benedek tanulási jegyzete a kaszkádról). Benedek kaszkádja is ilyen szabállyal dönt; az 5. fejezetben részletezzük.

2.5 Összevetés

Az alábbi táblázat azt foglalja össze, hogy a kapcsolódó munkák a probléma mely részeit fedik le; a kiértékelés méretét a forrás jegyzete vagy README-je szerint adjuk meg.

1. táblázat: A kapcsolódó munkák összevetése (a két forrásrepó irodalmi jegyzetei, a két forrásrepó README-je és `_results.md`-je, valamint EXP-004 és EXP-009 alapján)

Munka	Rajz	Adatlap	Több lap	Gráf	Kiértékelés mérete
ChatP&ID [Alimin2026]	igen (DEXPI)	nem	nem, egy lap	Neo4j, tulajdonsággráf	19 kérdés
Talking like P&IDs [Alimin2025]	igen (DEXPI)	nem	nem	sűrített gráf a promptban	3 kérdés, egy folyamatábra
PIDQA [Gupta2025]	igen (szintetikus, raszteres)	nem	nem, kérdésenként egy lap	Neo4j, tulajdonsággráf, Text2Cypher	64 000 kérdés, 500 lap
Gadekar és társai [Gadekar2026]	igen (raszteres)	nem	nem	visszanyert folyamatgráf, 7 operátor	3000 kérdés, szintetikus lapok

Munka	Rajz	Adatlap	Több lap	Gráf	Kiértékelés mérete
pid-graph-agent [PidGraphAgent2026]	igen (DEXPI)	nem	nem, kérdésenként egy fájl	gráfeszközös ágens	15 + 37 saját kérdés
Everllence-esettanulmány [Kochanski2026]	igen	nem	igen	Neo4j, ágens	nem közöl
Lopomo és társai [Lopomo2026]	igen (126 rajz)	nem	a jegyzet nem rögzíti	automatikusan épített tudásgráf	gráfépítés, nem kérdés-válaszolás
Document GraphRAG [Knollmeyer2025]	nem	gyártási dokumentumok	–	dokumentumszerkezet és példánygráf	a jegyzet nem rögzíti
Enginuity [Kumar2026]	mérnöki rajzok	kézikönyvek, alkatrésztáblák	–	nincs	6940 oldal
plantgraph (Kiszely)	igen (szintetikus)	nem	igen, kb. 100 és 1000 lap	Neo4j, üzemi réteg	460 kérdés a lezárt teszten
plantdocs (Szabó)	nem	igen, egy eszköz	–	ISO 15926 / QUDT, RDF és Neo4j	200 kérdés
Jelen munka	igen (4 lap)	igen, 7 adatlap	igen	összevont Neo4j-gráf	20 dev + 40 teszt kérdés, 12 (e) kérdés

A rajzoldali munkák szinte mind egylaposak, és egyikük sem kapcsolja be az eszközök adatlapjait; az egyetlen többlapos ipari példa kiértékelést nem közöl. A dokumentumoldali munkák pedig nem használják a rajz topológiáját.

2.6 A hiányzó lépés

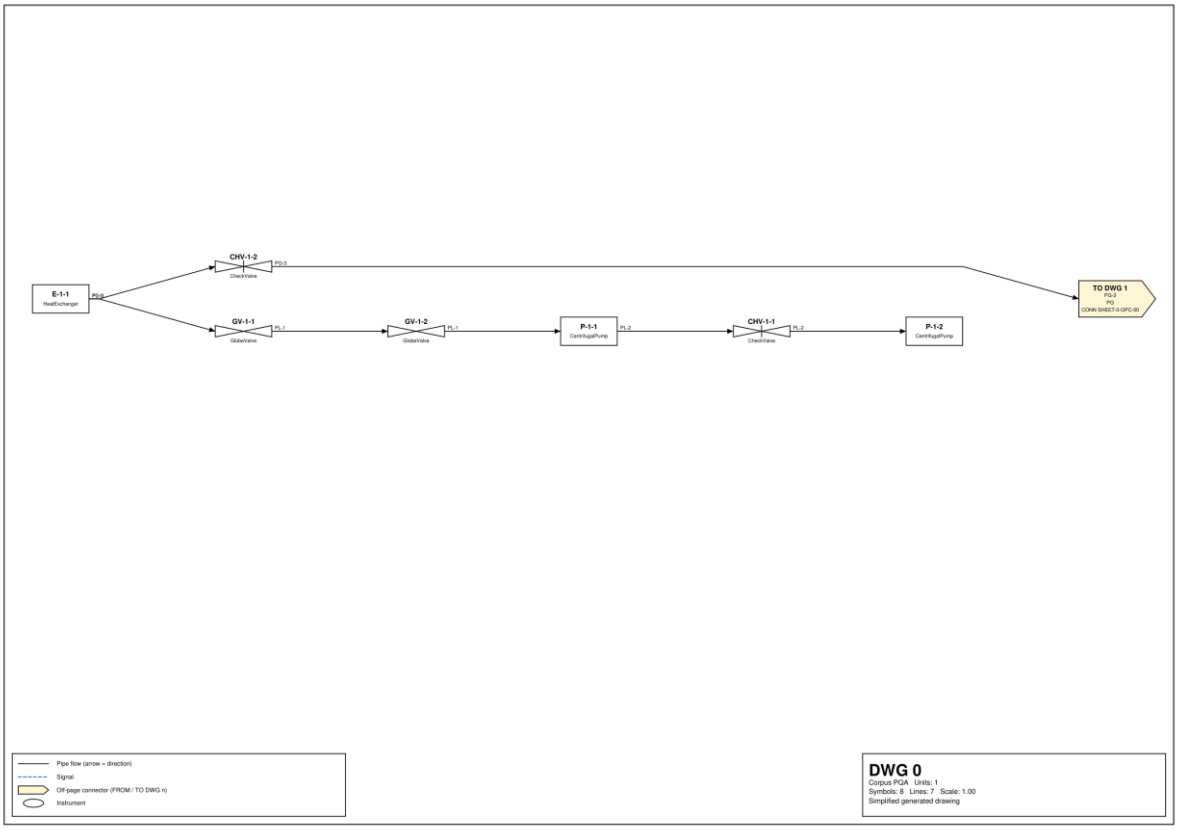
A két egyéni munka ugyanannak az üzemi dokumentációnak két oldalát dolgozza fel. A rajzon látszik, hogy mi mivel áll kapcsolatban, az adatlapon, hogy egy eszköz mire képes. Egy mérnöki kérdés gyakran mindkettőt igényli („mekkora a maximális nyomás azon a szelepen, amely a P-101 nyomóoldalát elzárja?”). Nem találtunk olyan munkát a két repó irodalmi jegyzeteiben, amely a rajzi gráfot és az eszközönkénti adatlapgráfokat egy lekérdezhető modellben kötné össze, és ezt mérné. Ez a dolgozat tárgya.

3. Adatok és feladat

Ebben a fejezetben bemutatjuk a mérés tárgyát: a két példaüzem rajzát, a tagelt elemeikhez tartozó gyártói adatlapokat és az üzemenként 60 kérdésből álló kérdéssort. A kis üzemen fejlesztettük a módszereket, a nagy üzemen változtatás nélkül mértük meg őket. Minden számot a mellette megadott mérés (EXP-azonosító) rögzít; a mérések listája a `docs/eredmenyek.md` fájlban található.

3.1 A kis példaüzem

Egy közepesen bonyolult, többlapos P&ID-t generáltunk Kiszely Benedek seedelt generátorával (plantgraph, v1). A generátor pyDEXPI-modellt épít, a lapokra bontó a vágott vezetékekből lapok közötti csatlakozópárokat (off-page connector) képez, és maga a bontás a megoldókulcs. A generátort nem módosítottuk. Két eszközzel szűkítettünk: a berendezéssúlyok csak olyan osztályokat engednek, amelyekhez van adatlap (centrifugálszivattyú, hőcserélő), a szabályozókörök változóját (áramlás, szint, nyomás, hőmérséklet) pedig seedkereséssel szűrtük. Az 1-es seedtől indulva az első olyan seedet fogadtuk el, amelynek üzemében csak áramlás- és nyomásszabályozó kör van (a nyomástávadó adatlapja mindkettőt lefedi), a tagelt elemek száma 20 és 40 közé, a lapoké 2 és 4 közé esik, és minden adatlaptípus szerepel. Ez a 6-os seed lett: 26 tagelt elem, 4 lap, 4 lapközi csatlakozópár, 36 csúcs és 116 kapcsolat a Neo4j-ben tárolt üzemi rétegben (EXP-002). A visszaépítési ellenőrzés (a lapokból feloldott üzem azonos-e a generálttal) hibátlan volt.



1. ábra: A kis példaüzem egyik lapja (Benedek rajzexportja, EXP-003). A jobb szélen a lapközi csatlakozó.

3.2 A nagy példaüzem

A kis üzem négy lapja egy valódi üzemnél nagyságrendekkel kisebb, ezért a közös mérést egy nagyobb üzemen is elvégeztük. Ugyanazzal a generátorral, ugyanazokkal a berendezéssúlyokkal és ugyanazzal a hét adatlappal 15 egységes üzemet generáltunk; az elfogadási határ 120–400 tagelt elem és 24–40 lap volt. A szabályozókörök változóját itt nem szűrtük, mert ennyi körnél szinte minden seedben van szint- és hőmérséklet-szabályozás is. Ezek távadójához nem rendeltünk adatlapot, mert a gyűjtemény nyomástávadója (Rosemount 3051) ezeket nem méri; egy valódi üzemben sem tartozik minden elemhez adatlap a rendelkezésre álló dokumentumok között. Az első elfogadott seed (1) üzeme 27 lapos, 190 tagelt elemmel, amelyek közül 164-hez tartozik adatlap; adatlap nélkül marad 18 szabályozófunkció és 8 szint- vagy hőmérséklet-távadó (EXP-051). Egy adatlap így több tagot is leír: például 58 szivattyú ugyanazt a Gorman-Rupp adatlapot kapja, ahogy egy valódi üzemben is ugyanaz a típus több helyen beépül.

3.3 Adatlapok

A tagelt elemek osztálya és szerepe határozza meg az adatlapot (lásd az alábbi táblázatot). A hozzárendelést program állítja elő a generátor kimenetéből (`data/plant/tag_to_datasheet.json`), nem kézzel. A szabályozókör által működtetett globe szelep a Fisher ET szabályozószelep, a kör nélküli globe szelep a GF 165 mágnesszelep (kétutas, globe kialakítású nyitó-záró szelep). A két szabályozófunkcióhoz (FIC, PIC) nem rendeltünk adatlapot, mert ezek a folyamatirányító rendszer funkciói, gyártói adatlapjuk nincs.

2. táblázat: Elemosztályok és adatlapok a példaüzemben (EXP-002, EXP-006, EXP-007)

DEXPI-osztály (szerep)	Tagek	Adatlap	Oldal
CentrifugalPump	P-1-1 … P-2-3 (8 db)	Gorman-Rupp VGH (0700286)	6
HeatExchanger	E-1-1, E-2-1, E-2-2, E-2-3	Alfa Laval M3	2
GlobeValve (szabályozókörben)	FV-2-2, PV-2-1	Fisher ET (D100022X012)	36
GlobeValve (kör nélkül)	GV-1-1, GV-1-2, GV-2-2	GF Type 165 mágnesszelep	6
BallValve	BV-2-1	Flowserve Worcester F51/F52	12
CheckValve	CHV-1-1 … CHV-2-2 (4 db)	Swagelok MS-01-176	16
ProcessSignalGeneratingFunction	FT-2-2, PT-2-1	Rosemount 3051 (00813-0100-4001)	114

Az adatlapokból a plantdocs tíz lépéses folyamata épít ISO 15926 / QUDT szerinti tudásgráfot (Azure Document Intelligence, rekordok, ábrák, diagramok, célformátum, forrásleírások, szókészlet, RDF). A korábban feldolgozott négy eszköz közül a Fisher, a GF 165 és a Gorman-Rupp gráfja a plantdocs Opusszal épített változata (a plantdocs EXP-0030-ja szerint). A Rosemount 3051-et és a három új adatlapot most dolgoztuk fel: a folyamat programlépései változatlanok, az LLM-lépéseket a claude-opus-5-5 modell végezte (EXP-

006). A Rosemount 3051 Opus-gráfja 91 202 tripletből és 3538, az eszközről szóló tényből áll, szemben ugyanennek a dokumentumnak a plantdocs EXP-0038-ban GLM-mel épített gráfjával (20 973 triplet, 626 tény, a plantdocs saját jelentése szerint). A három új adatlap gráfja 1102, 16 281 és 66 747 tripletes (Alfa Laval M3, Worcester F51/F52, Swagelok MS-01-176; EXP-006).

3.4 A kérdéssor

A kis üzem kérdéssora 60 kérdésből áll, négy családban (lásd a második táblázatot ebben a fejezetben). Családonként 5 kérdés a fejlesztési (dev) halmazba, 10 a teszthalmazba került; a teszthalmazt a módszerek fejlesztése előtt befagyasztottuk (sha256-tal rögzítve, EXP-004), és csak a végső mérésnél futtattuk. A nagy üzem kérdéssorát ugyanaz a program, ugyanazzal a seeddel állította elő (EXP-052); mivel a módszereket a nagy üzemen nem fejlesztettük, ott mind a 60 kérdés tesztkérdés. Mindkét üzemhez tartozik 12 további, több adatlapot összevető kérdés is (az (e) család, EXP-009, EXP-052).

3. táblázat: A kérdéscsaládok (EXP-004)

Család	Mit kérdez	Referenciaválasz forrása	Dev / teszt
(a) csak rajz	kapcsolat, áramlási út, felső források, műszerek, típus, egység, lapok	Benedek kérdésgenerátora a gold gráfból	5 / 10
(b) csak adatlap, tagen át	„Regarding P-1-3 on the P&ID: …”	a plantdocs EXP-0026 / EXP-0039 gold párjai	5 / 10
(c) összetett	egy topológiai lépés és egy adatlapi tény	programmal összerakva (a) és (b) goldjából	5 / 10
(d) megválaszolhatatlan	nem létező tag, a dokumentumban nem szereplő tény	Benedek generátora, plantdocs „not in document” párok	5 / 10

Az összetett kérdések topológiai lépését a gold üzemgráfból program számolja: csak egyértelmű lépés marad (pl. „a P-1-1 előtt közvetlenül álló elem”, „az E-2-1-et mérő távadó”, „a PIC-2-1 kör által működtetett szelep”), és csak olyan, amelynek cél-eleméhez van gold kérdés. A kérdés szövege a lépés és az eredeti adatlapi kérdés összefűzése. A (b)–(d) családok referenciaválaszai modellkészítésűek: a plantdocs EXP-0026 és EXP-0039 válaszait egy Opus-modell írta a PDF-ből, és azokat ember nem ellenőrizte. Ezt a korlátot a kiértékelésnél figyelembe vesszük.

3.5 Pontozás

Ahol a válasz programmal ellenőrizhető, programmal pontozunk. Az (a) család és a rajzos megválaszolhatatlan kérdések Benedek pontozóját használják (tagek halmaza, rendezett út, szám, igen/nem, tartózkodás). A szabad szöveges kérdéseknél programmal helyes a válasz, ha a gold minden kötelező eleme számot tartalmaz, és minden szám a mértékegységével együtt megjelenik a válaszban; programmal rossz a megválaszolható kérdésre adott „nincs benne”, programmal helyes a megválaszolhatatlanra adott „nincs benne”. Minden más tételt vak bíráló pontoz: a claude-opus-5-5 modell (vak bírálóként), a plantdocs EXP-0029 bírálati promptjával szó szerint (helyes, részben helyes, rossz, hallucinált). A bíráló csak a kérdést,

a gold választ és a jelölt választ látja; a tételek sorrendje kevert, az azonosítójuk nem árulja el, melyik módszer és melyik modell válaszolt. Pontosságnak a helyes válaszok arányát tekintjük.

4. Az összevont tudásgráf

A két egyéni munka két külön gráfot épít: a rajzból egy üzemi réteget (Benedek), az adatlapokból eszközönként egy-egy adatlapgráfot (plantdocs). Az összevonás célja, hogy egyetlen adatbázisban egyetlen lekérdezés mindkettőt elérje. Ebben a fejezetben előbb röviden összefoglaljuk a két forrásfolyamatot és az általuk épített réteget, utána a két réteg közötti kapcsolatot és a betöltés mérését. A két folyamat kódját nem módosítottuk; részletes leírásuk, amely a két forrásrepó tervezési jegyzeteiből és kódjából származik, a Függelék D-ben található.

4.1 A rajzoldali réteg

Benedek rendszerében a generátor egy teljes üzemet épít, a lapokra bontó (splitter) lapokra vágja, a feloldó (resolver) a lapokból megoldókulcs nélkül visszaépíti az üzemet, végül a betöltő Neo4j-be tölti (részletesen: Függelék D). A generátor minden véletlen döntést egyetlen seedelt véletlenszám-generátoron át hoz meg, ezért ugyanaz a seed ugyanazt az üzemet adja; a kimenet valódi pyDEXPI-modell elágazó topológiával, a berendezésekhez tartozó szabályozókörökkel és a szokásos tagbetűkkel. A példaüzem a v1 generátorral készült, mert a valósághűbb v2 generátor berendezésosztályai nem szűkíthetők az adatlappal rendelkező osztályokra (`docs/felmeres.md`). A bontó minden elvágott élre lapközi csatlakozópárt illeszt, a megoldókulcsot pedig külön fájlba írja, amely a vizsgált adatbázisba nem kerül be. A feloldó csak a lapokat látja: a csatlakozókat a feliratuk kölcsönös hivatkozása alapján párosítja, a több lapon felrajzolt elemeket a (tag, osztály) kulcs szerint vonja össze, és nem találgat. Mivel a bontást a rendszer maga végzi, a feloldó eredménye a megoldókulcshoz mérhető. A példaüzem 4 lapja között 4 lapközi csatlakozópár van (EXP-002); a rajzexportban mind a 8 lapközi jel összekötött (EXP-003), a visszaépítési ellenőrzés pedig hibátlan volt (EXP-002).

Az üzemi réteg és a vonalnézet

Benedek döntése (ADR-0036) szerint az adatbázisban két réteg lehet: a rajz szerinti előfordulásréteg (rajzolt szimbólumok, lapközi csonkok, azonossági élek) a nyomon követésre, és az összevont üzemi réteg, a tulajdonképpeni tudásgráf, amely kizárólag a feloldó kimenetéből épül. Az üzemi rétegben egy laphatár átlépése egyetlen él, az előfordulásrétegben több lépéses minta.

A generált üzemet Benedek betöltője tölti Neo4j-be, a kaszkád által olvasott `plant_lines` profillal. Minden rajzi elem egyetlen `(:PlantItem)` csúcs, akárhány lapon szerepel is; osztálycímkéi a konkrét osztálytól a családig terjednek (például `:PlantItem:CentrifugalPump:Pump:Equipment`). Az anyagáramot a `send_to` kapcsolat írja le, csőrészenként; a lapot átlépő kapcsolat `crossed_sheets` tulajdonságot kap. A jelutakat a `send_signal_to`, a mérést a `measured_by`, a beavatkozást a `control` kapcsolat ábrázolja; az elemek lapjait és egységeit `is_drawn_on` és `is_located_in` kapcsolat köti a szerkezeti csúcsokhoz.

A `plant_lines` profil egy vonalnézettel bővíti ezt (ADR-0061). A `line_to` kapcsolat két berendezést vagy szelepet köt össze akkor is, ha köztük jelöletlen idomok vagy beépített

komponensek vannak; az átugrott elemeket a kapcsolat `via_tags` és `n_fittings` tulajdonsága őrzi. Minden elem `kind` tulajdonságot kap, a szelepek közös `Valve` címkét, és a be- vagy kimenő áram nélküli elemek vonalvégként jelöltek. A `send_to` megmarad, így a csőrészenkénti nézet sem vész el. A vonalnézetet Benedek a valósághűbb v2 üzemekhez vezette be, ahol sok jelöletlen idom áll az elemek között; a mi v1 példaüzemünkön ilyen idom nincs, de a kaszkád promptjai és lekérdezési szabályai erre a profilra készültek, ezért ezt használjuk. A példaüzem üzemi rétege 36 csúcsból és 116 kapcsolatból áll (EXP-005).

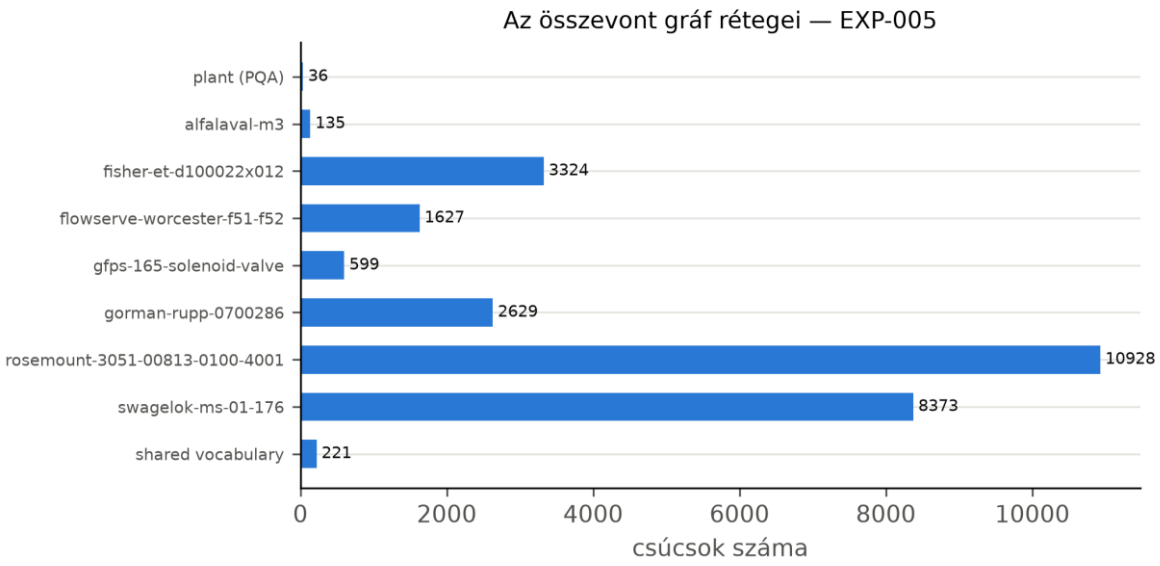
4.2 Az adatlapoldali réteg

A plantdocs egy gyártói adatlap PDF-jéből tíz számozott lépésben jut el az ontológia szerinti RDF-gráfig. Az Azure Document Intelligence elrendezés-elemzése után egy nyelvi modell a táblázatokból rekordokat ír (paraméter, érték, egység, táblázatbeli útvonal), további lépések feldolgozzák az ábrákat és leolvassák a diagramokat, a program minden rekord számát megkeresi a PDF szövegében, majd a rekordokból egy ontológiafüggetlen célformátum, a tulajdonságokhoz és feltétel-dimenziókhoz szabványos fogalmakat rendelő szókészlet-térkép, végül RDF-gráf készül. A lépések felváltva programok és nyelvi modellek; minden nyelvimodell-lépésnek verziózott promptja van, és a kimenete csak akkor mehet tovább, ha átmegy a lépés szerződésén (egy programmal ellenőrzött formai és tartalmi feltételrendszeren). Az általunk feldolgozott négy adatlapon mind a 24 nyelvimodell-kimenet elsőre átment a plantdocs szerződésein; a POSC Caesar régi SPARQL-végpontja HTTP 404-et adott, ezért csak az új végponttal és a CFIHOS-szal illesztettünk (EXP-006).

A célformátumban egy rekord egy tény, nem egy nyomtatott cella; a feltételek elsőrendű elemek, a nyomtatott forma megmarad, és minden visszakövethető a PDF-oldalig. Az RDF-modell a plantdocs ontológiai döntése (ADR-0005) szerint az ISO 15926 vonalat követi: az IDO a felső ontológia, a POSC Caesar könyvtára az eszköz- és referenciaszótár, a mértékegység QUDT, saját, kézzel írt szókészlet pedig nem lehet. Egy mennyiségi tény mennyiségi adatpont (Quantity Datum), a feltételek együttese egy esetcsúcs (Case), amelyre a tény és minden egyes feltétel mutat, a forrás szakaszcsúcs (Section Datum), a lábjegyzet külön adatpont (részletesen: Függelék D).

Az adatlapréteg a Neo4j-ben

Egy adatlapgráf a plantdocs RDF-kimenete, amelyet a neosemantics (n10s) bővítmény tölt be: minden csúcs `:Resource {uri}`, az RDF-típusok további címkék (például a mennyiségi adatpont címkéje `plm__PCA_100029511`), a szabványos azonosítók rövidített előtagos neveket kapnak. Az eszköz gyökércsúcsának URI-ja `urn:plantdocs:<doc>:device`. Az adatpontok az eszközre vagy egy alkatrészére mutatnak, a feltételeket esetcsúcs, a lábjegyzeteket külön adatpont, a forrást (táblázat, ábra, szakasz) forrásszakasz-csúcs hordozza oldalszámmal. Ez a szerkezet őrzi meg, hogy egy érték milyen feltétel mellett és melyik oldalon érvényes. A hét eszközgráf együtt 27 615 csúcsból és 103 366 kapcsolatból áll; a közös szókészlet-csúcsok (egységek, osztályok, szabványos attribútumok) száma 221 (EXP-005).



2. ábra: Az összevont gráf csúcsai rétegenként és adatlaponként (EXP-005).

4.3 Az összekötés

A két réteget egy kapcsolat köti össze: `(:PlantItem {tag})-[:DESCRIBED_BY]->(eszköz)`. A kapcsolatot a program által előállított tag → adatlap tábla alapján töltjük be; a 26 tagelt elemből 24-nek van adatlapja, ennyi `DESCRIBED_BY` él jön létre (EXP-002, EXP-005). Több tag mutathat ugyanarra az eszközgráfra: a nyolc szivattyú ugyanazt a Gorman-Rupp adatlapot kapja, mert ugyanaz a típus. A névütközést az URI-k dokumentumonkénti előtagja zárja ki; emellett minden adatlapcsúcs `document_id` tulajdonságot kap, amellyel a lekérdezés egy dokumentumra szűkíthető. A közös szókészlet-csúcsok (például egy mértékegység) az eszközök között közösek.

Egy összetett kérdés így egyetlen bejárásként fogalmazható meg: a rajzi rétegben megkeressük a kérdéses elemet (például a P-1-1 utáni első szelepet a `line_to` mentén), a `DESCRIBED_BY` kapcsolaton átlépünk az adatlapjára, és ott a megfelelő adatpontot olvassuk ki a feltételével és az oldalszámával. Az alábbi minta az összevont gráf egy részletét mutatja Cypher-jelöléssel: egy szivattyút, a rajzi szomszédját, az adatlapja gyökércsúcsát és egy adatpontot a környezetével.

```
// rajzi réteg (Benedek, plant_lines profil)
(p:PlantItem:CentrifugalPump {tag: 'P-1-3'})-[:line_to]->(v:PlantItem:Valve)
(p)-[:is_drawn_on]->(:Sheet)

// az összekötés
(p)-[:DESCRIBED_BY]->(dev:Resource:lis__PhysicalObject)

// adatlapi réteg (plantdocs, egy adatpont a környezetével)
(d:plm__PCA_100029511)-[:plm__PCA_100029516]->(dev)                // alany: az eszköz
vagy egy alkatrésze
(d)-[:plm__PCA_100029520]->(c:plm__PCA_100029524)                  // eset: a feltételek
együttese
(cond:plm__PCA_100029508)-[:plm__PCA_100029520]->(c)               // egy feltétel
ugyanabban az esetben
(d)-[:plm__PCA_100029525]->(s:plm__PCA_100029513)                  // forrásszakasz,
oldalszámmal
(d)-[:plm__PCA_100029514]->(f:plm__PCA_100029505)                  // lábjegyzet
```

```
(d)-[:lis__datumUOM]->(u:Resource)                                    // mértékegység, QUDT-megfeleltetéssel
```

Az összekötés módját több alternatívával szemben választottuk. A legegyszerűbb az lett volna, ha az adatlapi tényeket tulajdonságként a rajzi csúcsra másoljuk; ez azonban éppen a feltételeket, a lábjegyzeteket és az oldalszámot veszítené el, amelyekért a plantdocs gráfja készült. Két külön adatbázis között egy lekérdezés nem járhat át (és a helyi Neo4j Community kiadás csak egy felhasználói adatbázist enged); az egész gráf RDF-ben pedig Benedek Neo4j-re írt kaszkádjának módosítását igényelte volna. A tagalapú él a legkisebb beavatkozás: egyik réteg szerkezete sem változik, és a kapcsolat a gyakorlatot követi, ahol a tag köti össze a rajzot a többi dokumentummal. Ára, hogy a tag → adatlap táblát elő kell állítani; nálunk ezt program végzi a generátor kimenetéből (3. fejezet), valódi üzemben ez az eszközlista vagy az átadási adatbázis dolga volna.

4.4 Betöltés

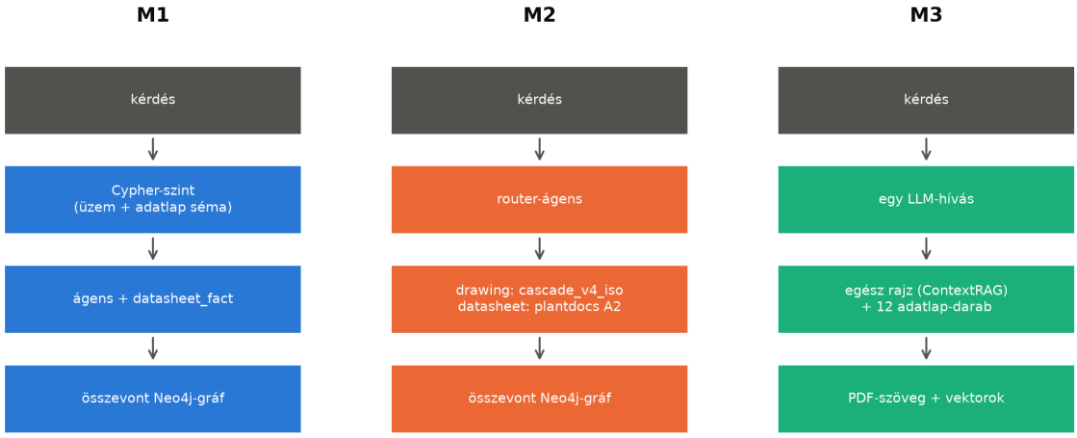
A betöltés egy paranccsal újrafuttatható (`python -m plantqa.graph.load`). Sorrendje: az adatbázis törlése és a neosemantics beállítása, az eszközgráfok betöltése és névtérbe sorolása, az üzemi réteg betöltése Benedek betöltőjével (amely csak a saját korpuszát törli), a `DESCRIBED_BY` élek, végül a plantdocs A2 vektoros kereséséhez szükséges beágyazások. A teljes betöltés 243,2 s; ennek nagy része (222,4 s) a 14 489 beágyazás előállítása, tárolása és indexelése, az üzemi réteg 3,6 s alatt töltődik be (EXP-005). A helyi Neo4j Community kiadás csak egy felhasználói adatbázist enged, ezért a betöltő minden futáskor az egész adatbázist újraépíti.

Két illesztési pontra külön figyelni kellett. Benedek tárellenőrzése összeveti az adatbázis kapcsolatszámait a betöltési tervvel, és eltérésnél nem indítja el a kaszkádot; ezért a kaszkád egy leszármazott nézeten át olvas, amely a `DESCRIBED_BY` kapcsolatot nem számolja a rajzi korpuszhoz. A másik pont a plantdocs: az alkalmazása dokumentumonként törli és újratölti az adatbázist, ami az összevont gráfot tönkretenné. Ezért az A2-t nem az alkalmazáson át hívjuk, hanem közvetlenül a lekérdező függvényét, egy dokumentumra szűkítő lekérdezés-futtatóval (5. fejezet).

5. Kérdés-megválaszolási módszerek

Három módszert hasonlítunk össze. Mindhárom a két meglévő rendszerre épül, azokat nem módosítja: a kódjukat importáljuk, és csak a hiányzó kapcsolatot írjuk meg. A három módszer ugyanazt a kérdést kapja (szöveg és elvárt válaszalak), és ugyanabban az alakban válaszol: egy JSON-objektum a válasszal és egy jelzővel arra, hogy a dokumentumok nem tartalmazzák a választ. Mindhárom módszert mindkét kérdés-válaszoló modellel mérjük: a `z-ai/glm-5.3-flash` és az `openai/gpt-6-luna` modellel, Benedek rögzített paramétereivel (pinjeivel).

A válaszalak Benedek kérdéstípusait követi: szabad szöveg (`FREE_TEXT`), egy tag vagy taghalmaz (`TAG`, `TAG_SET`), rendezett út (`TAG_PATH`), igen/nem (`BOOLEAN`), darabszám (`COUNT`), egység (`UNIT_ID`) és osztálynév (`CLASS_NAME`). A válaszalakot leíró mondatot mindhárom módszer Benedek kódjából veszi, így a válaszíró modell mindhárom esetben ugyanazt az utasítást látja. A fejezetben előbb a közös építőelemeket, majd a három módszert és a tervezési döntéseiket mutatjuk be, végül megfogalmazzuk, mit várunk az egyes módszerektől.



3. ábra: A három módszer felépítése. Bal: M1 (egy összevont gráf); közép: M2 (router a két rendszer fölött); jobb: M3 (gráf nélküli baseline).

5.1 Közös építőelemek

A rajzoldali kaszkád

Benedek legutóbb mért szabályozott kaszkádja, a `cascade_v4_iso` (a V2T-A rendszer) két szintből áll. A kaszkádot Benedek a valósághűbb v2 üzemeken hangolta egy külön megjelölt rendszerként (V2T, ADR-0061), a pontosságot helyezve előtérbe. A hangolás többek között a jelöletlen idomokat (ehhez készült a 4. fejezetben leírt vonalnézet, mindkét szintre ugyanazzal a szabállyal), a Cypher-lekérdezések szintaktikai hibáit és a korlátlan útkereséstől lejáró lekérdezéseket kezelte. A kaszkád két változata közül a `cascade_v4_iso`-t egy előre rögzített szabály választotta: akkor lép a `cascade_v4` helyébe, ha a hangolókészleten legalább olyan pontos (`docs/felmeres.md`).

Első szint: egy Cypher-lekérdezés. Egy LLM egyetlen Cypher-lekérdezést ír a Neo4j-ben tárolt üzemi rétegre (`cypher_rag_lines`). A prompt Benedek sémaszövegét (a csúcscímkéket, a kapcsolatokat és a tulajdonságokat), egy rövid, általános P&ID-olvasási bevezetőt (primer) és lekérdezési formaszabályokat tartalmaz: korlátlan hosszúságú változó utat nem szabad kötni, halmazhoz különböző végpontokat kell kérni, útvonalhoz a legrövidebb utat, elérhetőséghez létezésvizsgálatot a `line_to` mentén. A lekérdezés csak olvashat, 30 s időkorláttal és legfeljebb 1000 sorral fut. Ha a lekérdezés hibát ad, egy javítókörben a modell megkapja az adatbázis hibaüzenetét, és újraírhatja. Egy programozott ellenőrzés emellett azt is megnézi, hogy a kérdésben szereplő tagek léteznek-e. A sorokból a közös válaszlépés fogalmaz.

Az elfogadási szabály. A Cypher-szint válaszát a kaszkád akkor fogadja el, ha az önjelzések mind rendben vannak: a lépés válaszolt, nem tartózkodott („nincs benne" válasz helyett érdemben felelt), a lekérdezés adott sort, és az eredmény nem csonka (nem érte el a sorkorlátot). Egyik jel sem igényli a helyes válasz ismeretét, ezért a szabály a teszten is alkalmazható, és nincs illesztett paramétere. Ha bármelyik jel hiányzik, a kérdés a második szintre kerül.

Második szint: gráfeszköz-ágens. Az ágens (`graph_agent_lines`) üzemi primitíveket hív lépésenként, legfeljebb 40-szer. Minden lépésben egy JSON-akciót ír (egy primitív hívását az argumentumaival, vagy a befejezést), a primitív eredményét szövegesen kapja vissza, és a végén az összegyűjtött megfigyelésekből ugyanaz a közös válaszlépés fogalmaz, amely a Cypher-szint válaszát is írja. A közös válaszlépés szabályai a V2T-ben szigorodtak: egy berendezés- és szeleplistában csak ezek szerepelhetnek, a kiinduló elem nem kerül a listába, és ha egy kérdezett tag nem létezik, a válasz „nincs benne".

Címke szerinti indítás. A `cascade_v4_iso` egyetlen kivételt tesz: az „első szelep" típusú kérdések (a felfelé vagy lefelé eső első szelep, `UPSTREAM_TO_FIRST_VALVE`, `DOWNSTREAM_TO_FIRST_VALVE`) rögtön az ágensnél indulnak. Ennek oka Benedek elemzése szerint az, hogy az ilyen kérdésekre írt Cypher-lekérdezések jellemzően az összes felfelé eső szelepet kérik az első helyett; amíg ezek lejárnak, a kaszkád az ágenshez fordul, ha viszont gyorsan lefutnának, rossz választ adnának, amelyet a kaszkád elfogadna. Benedek élő kaszkádja a címke szerinti útválasztást elutasítja, ezért két kaszkádot futtatunk (a teljeset és egy csak-ágenseset), és a kérdéscsalád címkéje alapján választunk köztük. A Cypher-szint és a válaszlépés alacsony, az ágens magas gondolkodási szinttel fut (a GLM-hez Benedek alacsony pinjének magas szintű másolatát használjuk, mert magas GLM-pinje nincs).

A kaszkád elfogadási szabályait, paramétereit és promptjait változatlanul vettük át. A tiereket a plantqa mérő kliensével raktuk össze Benedek stratégiaépítőjével, mert az ő élő kaszkádja a tokenhasználatot nem méri; a stratégiák és a promptok ugyanazok.

Az ágens primitívjei

Benedek ágense hat általános, egymással komponálható primitívet hív (ADR-0034): a szűrőnek megfelelő elemek keresését (`find`), a szomszédokat (`neighbours`), a bejárást (`traverse`), az utat két elem között (`path`), egy korábbi eredmény szűkítését (`filter`) és összesítését (`aggregate`). A primitívek a feloldó kimenetéből a memóriában épített, a

betöltött üzemi réteggel egyező elemgráfon futnak, ezért az ágens nem látja a laphatárokat, csak az üzemet; az eredmények hivatkozást kapnak, így egy korábbi lépés eredménye a következő bemenete lehet. A tervezési döntés lényege, hogy az eszközök száma a gráfsémából következik, nem a kérdéstípusokból: egy új kérdéstípus egy új kompozíció, nem egy új eszköz (részletesen: Függelék E).

Az adatlapoldali A2

A plantdocs A2-módszere egy eszköz egy kérdésére a következőképpen válaszol. A rendszerüzenet a plantdocs gráfmodelljének leírását, az eszköz gráfjának leltárát és a forrásszakaszok katalógusát tartalmazza. Egy LLM egyetlen csak olvasó, széles keresésű Cypher-lekérdezést ír, és legfeljebb három forrásszakaszt választ, amelyek minden sora a lekérdezés sorai mellé kerül; hibás, üres vagy túl sok sort adó lekérdezésnél egy javítókör következik. Ezzel párhuzamosan a kérdés beágyazásvektorához legközelebbi 30 adatpont kerül elő a gráf vektorindexéből. A válaszíró csak a megtalált tényekből fogalmaz: a közvetlen válasz után az értékeket az egységükkel, a feltételeikkel és oldalhivatkozással adja meg, új tényt, értéket vagy eljárást nem tehet hozzá (részletesen: Függelék E).

Az összevont gráfban több eszköz gráfja van egyszerre, ezért néhány illesztésre volt szükség, a plantdocs kódjának módosítása nélkül. A leltár elé egy sor kerül, amely közli, hogy a kérdés melyik dokumentumról szól, és hogy minden csúcsot `document_id` szerint kell szűkíteni. A lekérdezés-futtató csak olyan lekérdezést enged, amely a dokumentum azonosítóját tartalmazza, és semmilyen írást nem enged. A vektoros keresés egy nagyobb jelöltkészletből csak a dokumentum csúcsait tartja meg. A másik lehetőség az lett volna, hogy kérdésenként újratöltjük az adatbázist a kérdezett eszköz gráfjával, ahogy a plantdocs alkalmazása teszi; ez az összevont gráfot tönkretenné, és az M1 számára értelmetlenné tenné az egész összevonást.

5.2 M1 — egy gráf, egy lekérdezés

Az M1 Benedek kaszkádja az összevont gráfon, két kiegészítéssel. A Cypher-szint sémaleírása az üzemi réteg mellett az adatlapréteget is tartalmazza: a `DESCRIBED_BY` kapcsolatot, a plantdocs A2-promptjának gráfmodelljét és lekérdezési szabályait, valamint a tagek dokumentumonkénti listáját. Így egyetlen lekérdezés követheti a rajzot és olvashatja az adatlapot, például:

```
MATCH (p:PlantItem {tag: 'P-1-3'})-[:DESCRIBED_BY]->(dev)
MATCH (d) WHERE d.document_id = dev.document_id AND d:plm__PCA_100029511
  AND toLower(d.plm__PCA_100029521) CONTAINS 'casing pressure'
RETURN d.plm__PCA_100029521 AS label, d.plm__PCA_100029522 AS value, d.schema__pageStart
AS page
```

A sémakiegészítés felépítését a Függelék E, elejét a Függelék C mutatja; a plantdocs lekérdezési szabályai a második fejlesztési iterációban kerültek be (EXP-011).

Az ágens egy új primitívet kap: a `datasheet_fact(tag, question)` a tagből feloldja az eszközt, és a plantdocs A2-logikájával kérdezi meg az adatlapját. A primitív Benedek eszközregiszterébe kerül, ezért az ágens promptjában ugyanúgy jelenik meg, mint a többi primitív. A regisztráció csak az ágens felépítésének és a kérdés megválaszolásának idejére

szól, így Benedek kódja és a többi futás eszközkészlete nem változik. Az eredmény Benedek eredményosztályainak felületét követi (szöveges megjelenítés hosszkorláttal), és tartalmazza a dokumentum azonosítóját, a tagot, az első forrásoldalakat és az A2 válaszát. Ismeretlen vagy adatlap nélküli tagre a primitív nem hibát dob, hanem szövegesen közli, hogy a taghez nem tartozik adatlap, így az ágens folytathatja a munkát. Az eszköz leírása arra kéri az ágenst, hogy a rajzon nem látható tulajdonságokhoz ezt használja, és előbb a rajzon keresse meg a tagot.

Az M1 útvonala a lefutott tierekből és az adatlapi hívásokból áll (például `cypher-v2t`, vagy `cypher-v2t`, `agent-v2t` és `datasheet_fact:FT-2-2`). A válaszlépés Benedek változatlan válaszpromptja; az M2-ben és az M3-ban bevezetett válaszszabályt (részválasz, a dokumentumon túli tanács tilalma) az M1 ezért nem kapta meg, mert az a kaszkád része, amelyet nem módosítunk.

5.3 M2 — router

Az M2 egy ágens két eszközzel: a `drawing(question)` Benedek kaszkádját hívja a rajzra (változtatás nélkül), a `datasheet(tag, question)` a tagből feloldott eszköz A2-jét. Az ágens minden lépésben egy JSON-objektumot ír (eszközhívást vagy végső választ), legfeljebb hat eszközhívással. Ha a kérdés egy elemet a helyével vagy szerepével nevez meg, előbb a rajzeszközt kérdezi meg a tagről, utána az adatlapot.

A protokoll. A router minden lépésben pontosan egy JSON-objektumot ír (rajzeszköz-hívás, adatlap-hívás vagy végső válasz a „nincs benne” jelzővel); a program végrehajtja a hívást, és az eredményt egy új üzenetben adja vissza. A router alacsony gondolkodási szinttel fut; a rendszerüzenetet a Függelék B, a hibakezelést a Függelék E írja le.

A válaszszabály. A második fejlesztési iterációtól (EXP-011) az M2 és az M3 egy közös válaszszabályt kap: ha a dokumentumok a kérdésnek csak egy részére adnak választ, a módszer ezt a részt adja meg, és megnevezi a hiányzó részt; a „nincs benne” jelzőt csak akkor állítja, ha semmi releváns nincs; tanácsot, eljárást, okot vagy értéket, amelyet a dokumentumok nem mondanak ki, nem tehet hozzá. A szabály után a dev halmazon az M2 és az M3 hallucinációi eltűntek (EXP-011, 6. fejezet).

Tervezési döntések. Az M2-ben mindkét rendszer abban a beállításban fut, amelyre a szerzője hangolta, és a két rendszer egymásról nem tud; az összekötést a router végzi a kérdés szövegének értelmezésével. Ennek két következménye van. A rajzeszköz szabad szöveges kérdést kap (`FREE_TEXT`), a kérdéscsalád címkéjét nem, ezért a kaszkád az „első szelep” kérdéseket is a Cypher-szinten kezdi, és a rajzeszköz válaszának alakja eltérhet attól, amit a kérdés eredetileg kért (taghalmaz, út); ezt a hibát a 6. fejezetben egy szabályozókörös kérdésen látjuk is. A másik következmény, hogy az összetett kérdés legalább két egymás utáni eszközhívást igényel, amelyek mindegyike maga is több LLM-hívás, ezért a késleltetés nagyobb.

5.4 M3 — gráf nélküli baseline

Az M3-ban nincs gráf. A kontextus a teljes rajz Benedek ContextRAG-szerializálásával (ez a ChatP&ID-módszer: az egész rajz a promptban) és a hét adatlap PDF-szövegéből vektoros

kereséssel kiválasztott 12 legközelebbi darab, ugyanazzal a beágyazómodellel, amelyet a plantdocs is használ (`qwen/qwen3-embedding-8b`, 512 dimenzió). A válasz egyetlen hívás magas gondolkodási szinttel, ahogy Benedek ContextRAG-karja is fut.

A szerializált rajz a rajzolt előfordulások gráfja: lapról lapra minden szimbólum egy csúcs a tagjével és az osztályával, az élek a csövek és a jelek, a lapokat a lapközi csatlakozók kötik össze. Az M3 modellje tehát maga követi a csatlakozókat a laphatáron át; az összevont üzemi réteget nem látja. Az adatlap-darabok a PDF-ek szövegrétegéből készülnek oldalanként, bekezdéshatáron vágva, korlátozott hosszúságú darabokra; minden darab a dokumentum azonosítóját és az oldalszámot hordozza. A prompt tartalmazza a tag → adatlap táblát is, hogy a modell tudja, melyik darab melyik elemhez tartozik. Az Azure-kimenet szövegét azért nem használtuk, mert a plantqa-ban nem minden dokumentumhoz volt meg.

A baseline-t szándékosan erősnek választottuk: a négylapos példaüzem rajza kicsi, így a teljes rajz elfér a promptban, és a ChatP&ID mérése szerint egyetlen lapon éppen ez a módszer nyert [Alimin2026]. Az adatlapoldalon a szövegdarabok vektoros keresése a legegyszerűbb, gráf nélküli visszakeresés; ha az M3 felveszi a versenyt a két gráfos módszerrel, az arra utal, hogy ezen a méreten a gráf előnye nem a visszakeresésben, hanem legfeljebb a feltételek megőrzésében jelentkezhet.

5.5 A módszerek várható erősségei és gyengeségei

Az alábbiakban a módszerek felépítéséből következő, minőségi várakozásokat foglaljuk össze; a 6. fejezet eredményeit ezek fényében érdemes olvasni.

M1

Az M1 erőssége, hogy egy összetett kérdés elvben egyetlen lekérdezéssel megválaszolható: a rajzi lépés és az adatlapi tény ugyanabban a mintában szerepel, így nincs szöveges átadás két rendszer között, és a válasz minden eleme visszakövethető egy csúcsig. Az ágensszint a `datasheet_fact` primitívvel ugyanazt az A2-logikát éri el, mint az M2, tehát ahol a Cypher-szint elakad, ott az M1-nek az M2-höz hasonló képességei vannak.

A gyengeségei ugyanebből fakadnak. A Cypher-író modellnek egyszerre két szókincset kell kezelnie: Benedek olvasható osztálycímkéit és a plantdocs előtagos, számkódos szabványos neveit. A sémaszöveg ettől hosszú, ami minden kérdés költségét növeli, akkor is, ha a kérdés csak a rajzról szól. A legnagyobb kockázat az elfogadási szabály: a rajzi kérdéseken a nem üres, nem csonka eredmény jó jelzés, egy adatlapi kérdésnél viszont egy szűk lekérdezés is adhat nem üres, de hiányos sort (például egy értéket a feltétele nélkül), amelyet a kaszkád elfogad, és az ágens nem kap esélyt. Végül a válaszlépés a rajzi kérdésekre készült, és nem tartalmazza az adatlapi válaszíró szabályait (feltételek kiírása, oldalhivatkozás).

M2

Az M2 erőssége a modularitás: mindkét rendszer abban a beállításban fut, amelyben a szerzője mérte, az adatlapi válasz a plantdocs teljes A2-láncán megy át (szakaszválasztás, vektoros keresés, a feltételeket kiíró válaszíró), és egy új dokumentumtípus egy új eszközzel bővíthető. Az útvonal átlátható: a naplóból látszik, melyik eszközt milyen kérdéssel hívta a router.

A gyengesége az illesztésben van. A két rendszer szöveggel kommunikál, így a rajzeszköz válaszának alakja elcsúszhat, és a router félreértheti; az összetett kérdés helyes felbontása is a routeren múlik. Mivel az eszközhívások egymás után futnak, és mindegyik maga is több LLM-hívás, a késleltetés a három módszer közül várhatóan itt a legnagyobb.

M3

Az M3 erőssége az egyszerűség: egyetlen hívás, nincs lekérdezés, amely elromolhat, és nincs elfogadási szabály, amely rossz választ engedhet át. Egy kis rajzon a teljes gráf elfér a promptban, és a modell mindent lát; az adatlapi kérdéseknél a kérdés szavaihoz közeli szövegrészek gyakran éppen a keresett táblázatot tartalmazzák.

A gyengesége a méret és a szerkezet. Benedek mérései szerint a teljes rajz promptba tétele a lapszámmal romlik és drágul, egy határ fölött pedig nem is fér el (2. fejezet), ezért az M3 előnye nagyobb üzemen nem várható. Az adatlap-darabok a táblázatokat szövegként, a fejlécektől elszakítva tartalmazhatják, a feltételek és a lábjegyzetek nem explicitek, és a vektoros keresés egy több eszközt érintő kérdésnél elhanyagolhatja valamelyik eszköz adatlapját. Az M3 a forrásoldalakat csak darabszinten tudja megadni.

5.6 Költség és mérés

Minden LLM-hívás egy közös, cache-elt és naplózott rétegen megy át. A cache miatt az ismételt futás nem fizet újra; minden élő hívás költsége a közös naplóba kerül, és a teljes keret 20 USD (18 USD felett új mérés nem indul). Kérdésenként mérjük a tokeneket, a szolgáltató által jelentett költséget (cache-ből érkező válasznál az eredeti hívás árát), a késleltetést és az útvonalat (melyik szint vagy eszköz kellett a válaszhoz).

6. Kiértékelés

Ebben a fejezetben a három módszert a 27 lapos nagy üzemen mérjük meg. A módszereket a négylapos kis üzemen fejlesztettük és fagyasztottuk be, a nagy üzemen semmit nem változtattunk rajtuk, így a nagy üzem mind a 60 kérdése tesztkérdés. Minden szám a megadott mérésből származik (`docs/eredmenyek.md`).

6.1 Beállítás

Mindhárom módszert mindkét kérdés-válaszoló modellel futtattuk: `z-ai/glm-5.3-flash` és `openai/gpt-6-luna`, OpenRouteren át, Benedek rögzített paramétereivel. A Luna-pinek Benedek pin-fájljai, a GLM-hez az ő `pin_low` beállítását és annak magas gondolkodású változatát használtuk. Minden hívás cache-elt és naplózott; a teljes projekt fizetős költése 3,4753 USD volt a 20 USD-s keretből, ebből a nagy üzem mérése 1,8411 USD (EXP-063). A pontosság a helyes válaszok aránya; a konfidenciaintervallum 10 000 ismétléses, seedelt percentilis-bootstrap, a módszerpárok különbségét ugyanazokon a kérdéseken, párosítva számoltuk.

6.2 A fejlesztés a kis üzemen

A kis üzem 20 kérdéses fejlesztési halmazán négy iterációt mértünk (EXP-010–EXP-013). Ezek hozták az M1 Cypher-szintjének lekérdezési szabályait, az M2 és az M3 válaszszabályát (részválasznál a meglévő és a hiányzó rész megnevezése, a dokumentumon túli tanács tilalma) és a Rosemount 3051 adatlapgráfját; utána a módszereket befagyasztottuk. A kis üzem befagyasztott, 40 kérdéses teszthalmazán a legjobb az M2 volt GLM-mel (31 helyes), a gráf nélküli M3 30, az M1 25 helyes választ adott (EXP-020). A kis üzem méréseit a Függelék G írja le részletesen; a továbbiakban csak a nagy üzemmel foglalkozunk.

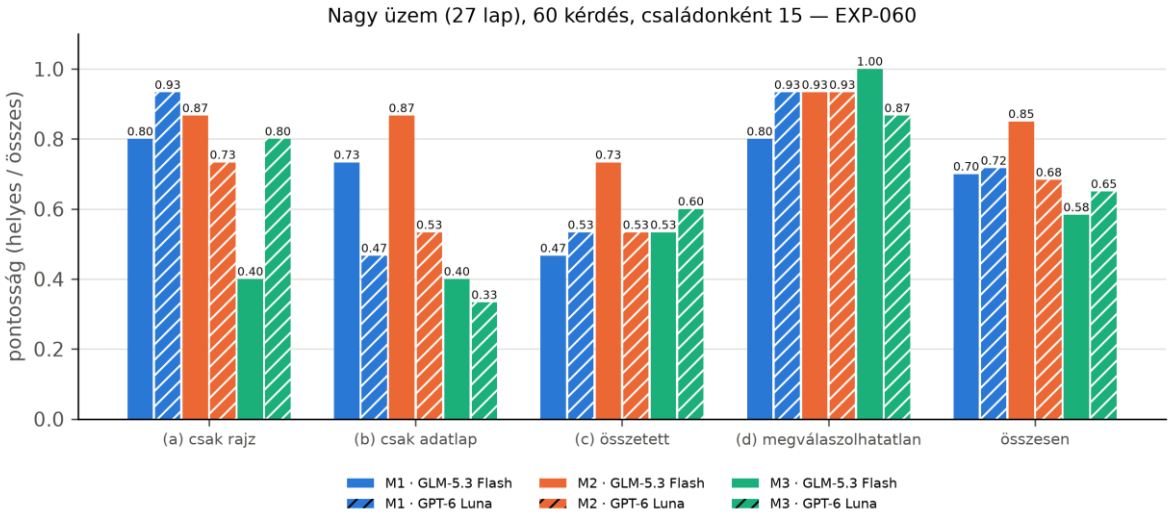
6.3 Eredmény a nagy üzemen

A nagy üzem 60 kérdése (családonként 15) mindegyik párosításon egyszer futott le (EXP-060). Az eredményt az alábbi táblázat és ábra mutatja.

4. táblázat: Eredmény a nagy üzemen párosításonként és családonként (60 kérdés, EXP-060)

Módszer	Modell	Helyes	Részben	Rossz	Hallucinált	Pontosság [95% CI]	(a)	(b)	(c)	(d)
M1	GLM-5.3 Flash	42	9	8	1	0,700 [0,583–0,817]	12/15	11/15	7/15	12/15
M2	GLM-5.3 Flash	51	4	5	0	0,850 [0,750–0,933]	13/15	13/15	11/15	14/15
M3	GLM-5.3 Flash	35	5	20	0	0,583 [0,450–0,700]	6/15	6/15	8/15	15/15
M1	GPT-6 Luna	43	12	5	0	0,717 [0,600–0,833]	14/15	7/15	8/15	14/15

Módszer	Modell	Helyes	Részben	Rossz	Hallucinált	Pontosság [95% CI]	(a)	(b)	(c)	(d)
M2	GPT-6 Luna	41	14	4	1	0,683 [0,567–0,800]	11/15	8/15	8/15	14/15
M3	GPT-6 Luna	39	7	14	0	0,650 [0,533–0,767]	12/15	5/15	9/15	13/15



4. ábra: A nagy üzem pontossága családonként, a hat párosításon (EXP-060).

A legjobb párosítás az M2 GLM-mel (51 helyes a 60-ból). GLM-mel az M2 szignifikánsan jobb a gráf nélküli M3-nál (párosított különbség +0,267, 95% CI +0,133 és +0,400 között) és az M1-nél (az M1 és az M2 különbsége −0,150; −0,267 és −0,033 között); az M1 és az M3 különbsége (+0,117; −0,033 és +0,267 között) nem szignifikáns. Lunával a három módszer különbsége nem szignifikáns. A 360 válaszból kettő hallucinált (az M1 GLM-mel és az M2 Lunával egy-egy). A rajzi (a) családon a két gráfos módszer 11–14 helyes választ adott a 15-ből; az adatlapi (b) és az összetett (c) családon az M2 GLM-mel 13, illetve 11 kérdést oldott meg, a gráf nélküli M3 legfeljebb 6, illetve 9-et.

6.4 A gráf szerepe a nagy rajzon

Az M3 a teljes szerializált rajzot és tizenkét adatlap-darabot kapja promptban. A kis üzemen ez versenyképes volt, a nagy üzemen GLM-mel a rajzi kérdések közül csak 6-ot oldott meg a 15-ből. A 9 nem helyes válaszból 8 téves „nincs benne” jelzés: a modell a 27 lapos rajz szövegében nem találta meg a választ, és úgy döntött, hogy a dokumentum nem tartalmazza; a kis üzemen egyetlen ilyen eset sem fordult elő (EXP-062). Ugyanez a hiba a több adatlapos kérdéseken is megjelenik (lásd alább). A gráfos módszereknél ez a hiba nem jelentkezik, mert ott a rajzot lekérdezés vagy gráfbejáró eszköz olvassa, és a modell csak a talált elemeket látja. Ez egybevág Benedek mérésével, amely szerint a teljes rajz promptba tétele a lapszámmal romlik és drágul (2. fejezet).

6.5 Költség és késleltetés

5. táblázat: Költség és medián késleltetés kérdésenként a nagy üzemen (EXP-060)

Módszer	Modell	Költség / kérdés (USD)	Medián késleltetés (s)
M1	GLM-5.3 Flash	0,00335	17,9
M2	GLM-5.3 Flash	0,00344	12,4
M3	GLM-5.3 Flash	0,00133	15,9
M1	GPT-6 Luna	0,01027	14,7
M2	GPT-6 Luna	0,00227	16,9
M3	GPT-6 Luna	0,00680	6,4

Kérdésenként egyik módszer sem drágább egy amerikai centnél a GPT-6 Luna M1-es párosításán kívül (0,01027 USD). Az M1 első szintje a teljes kétrétegű sémát és a 164 adatlappal rendelkező tag listáját kapja promptban, és ha a válaszát nem fogadják el, az ágens is lefut. Az M2 csak a szükséges eszközt hívja. Az M3 kérdésenként egyetlen hívás, de a 27 lapos rajzot is viszi magával; a kis üzemhez képest a kérdésenkénti költsége GLM-mel 0,00029-ről 0,00133 USD-re, Lunával 0,00182-ről 0,00680 USD-re nőtt (EXP-020, EXP-060), és a nagyobb rajzzal tovább nőne.

6.6 Útvonalak

Az M1 GLM-mel a 60 kérdésből 32-t a Cypher-szinten zárt le, 8-hoz az ágens is kellett adatlap-hívás nélkül, 20-hoz az ágens és legalább egy `datasheet_fact` hívás; Lunával ugyanez 35, 5 és 20. Az M2 GLM-mel 20 kérdésnél csak a rajzot, 20-nál csak az adatlapot, 20-nál mindkettőt kérdezte; Lunával 20, 21 és 19 (EXP-060). Az M2 tehát a kérdések kétharmadánál a két forrás közül csak az egyiket hívja, és ez a kérdéscsaládok megoszlásával egyezik.

6.7 Több adatlapos kérdések

A nagy üzemen is lefuttattuk a 12 kérdéses (e) családot, amelyben a rajzon egy utat, egy elemhalmazt vagy két topológiai lépést kell bejárni, és két-három különböző adatlapot kell összevetni (például „Along the process flow path from E-1-1 to CHV-2-1, which item has the lowest maximum allowable pressure according to its datasheet?”). A referenciát program rakta össze a gold gráfból és a PDF-ekből gyűjtött tényekből (EXP-008, EXP-052).

6. táblázat: A több adatlapos kérdések eredménye a nagy üzemen (12 kérdés, EXP-061)

Módszer	Modell	Helyes	Részben	Rossz	Hallucinált	Költség / 12 kérdés (USD)	Medián késleltetés (s)
M1	GLM-5.3 Flash	6	2	4	0	0,0371	18,2
M2	GLM-5.3 Flash	5	3	3	1	0,0568	23,9
M3	GLM-5.3 Flash	0	0	12	0	0,0127	21,0
M1	GPT-6 Luna	6	3	3	0	0,1640	33,4
M2	GPT-6 Luna	6	2	4	0	0,0875	38,1

Módszer	Modell	Helyes	Részben	Rossz	Hallucinált	Költség / 12 kérdés (USD)	Medián késleltetés (s)
M3	GPT-6 Luna	0	0	12	0	0,0907	18,4

A két gráfos módszer a kérdések felénél (5–6 kérdés a 12-ből) adott teljesen helyes választ, a gráf nélküli M3 egyetlen kérdésnél sem; az M1 és az M3 különbsége mindkét modellel +0,5 (95% CI +0,25 és +0,75 között), az M2-é GLM-mel +0,417, Lunával +0,5, szintén szignifikánsan (EXP-061). Az M3 GLM-mel 9 kérdésnél téves „nincs benne" választ adott, Lunával mind a 12 válasza rossz tartalmú volt; az M2 mindkét modellel 3-3 kérdésnél üres választ adott (lépéskorlát vagy feldolgozási hiba, EXP-062). A több elem bejárását és az elemenkénti adatlap-lekérdezést a gráfos módszerek eszközhívásai természetesen leképezik, az egyetlen prompt viszont nem.

6.8 Hibaelemzés

A gráf nélküli módszer téves „nincs benne" válaszai. A nagy rajzon a fő hiba nem a rossz érték, hanem a hamis lemondás: az M3 GLM-mel a rajzi kérdéseknél 8, a több adatlapos kérdéseknél 9 esetben állította, hogy a dokumentum nem tartalmazza a választ (EXP-062). Ez veszélyesebb, mint amilyennek látszik, mert a „nincs benne" a megválaszolhatatlan kérdéseken helyes, így a (d) családon az M3 GLM-mel hibátlan (15/15), miközben a megválaszolható kérdéseken elbukik.

Az M1 egyetlen lekérdezése. Az M1 hibáinak nagy része „részben helyes" válasz: a Cypher-szint egy szűk lekérdezéssel talál egy releváns adatpontot, a kaszkád elfogadja a nem üres eredményt, és a válaszból kimarad egy feltétel vagy egy második érték. A nagy üzemen például a 2 hüvelykes szabályozószelep teljesen nyitott Cv-értékére az M1 a változatok értékeit sorolta fel a referenciában szereplő feltétel (teljes méretű trim, egyenlő százalékos kosár, normál átfolyási irány) nélkül. Az elfogadási szabály a rajzi kérdésekre készült, ahol a nem üres sorhalmaz jó jelzés; adatlapi kérdésnél a hiányos sor is nem üres.

Az M2 eszközhívásai. Az M2 a rajzeszköznek szabad szöveges kérdést ad, ezért a válasz alakja elcsúszhat (a kis üzemen például szabályozókör helyett a szelepét adta meg, Függelék G), és a több adatlapos kérdéseknél néhányszor üres választ adott, mielőtt minden elem adatlapját lekérdezte volna (EXP-062).

A referencia és a bírálat korlátja. A (b)–(d) család referenciaválaszait egy modell írta a PDF-ből, és ember nem ellenőrizte őket; a bíráló ugyanazt a referenciát látta minden módszernél, ezért az összevetés igazságos, de az abszolút számok a referencia hibáival együtt értendők. A három bíráló között egy következetlenséget is láttunk: egy óvatoskodó válaszfajtát az egyik „részben helyes", a másik „helyes" ítélettel pontozott. Az ítéleteket nem írtuk felül.

7. Demó és esettanulmány

A mért számok azt mutatják meg, milyen gyakran helyes egy módszer, azt nem, hogyan jut el a válaszig. Ebben a fejezetben bemutatjuk a webes demót (a dolgozat ötödik hozzájárulását), majd két képernyőképen végigkövetünk két kérdést; a próba további négy kérdését a Függelék F mutatja be. A képek a demó próbáján készültek (EXP-040): hat kérdést tettünk fel a futó demón, az (a), (a), (b), (c), (d) és (e) családból, az M1, M2 és M3 módszerrel, GLM-mel; mind a hat kérdésre érdemi válasz jött. A próba nem pontossági mérés, a válaszokat nem pontoztuk.

7.1 A demó felépítése

A demó egy helyi webalkalmazás (`python -m plantqa.app`): egy FastAPI-szerver és egyetlen weboldal. A szerver ugyanazokat a módszerobjektumokat építi fel, amelyeket a mérés használ (az első kérdésnél, utána újrahasznosítja őket), így a demó válaszai pontosan azon az úton születnek, amelyet az 5. fejezetben leírtunk. Minden hívás a közös, cache-elt és költségnaplózott rétegen megy át; a `--replay-only` kapcsolóval a demó csak a gyorsítótárból válaszol, fizetős hívás nélkül.

Az oldal két részre oszlik.

- **Bal oldal: a dokumentum.** Alapállapotban a P&ID látszik, Benedek rajzexportjából: a fejléc megnevezi a korpuszt (a plantgraph 6-os seedű üzeme, EXP-002), és lapváltó gombokkal a négy lap között lehet lépkedni; a teljes rajz PDF-ben is megnyitható. Ha a felhasználó egy válasz adatlapi forrásoldalára kattint, a bal oldalon az adatlap adott oldala jelenik meg képként, a fejlécben a dokumentum azonosítójával és oldalszámával, valamint egy hivatkozással, amely a PDF-et ennél az oldalnál nyitja meg.
- **Jobb oldal: a kérdés és a válasz.** Egy szövegmezőbe kerül a kérdés; alatta választható a módszer (M1, M2 vagy M3, egy rövid leírással), a modell (`z-ai/glm-5.3-flash` vagy `openai/gpt-6-luna`) és a válaszalak (az 5. fejezetben felsorolt alakok közül). Az alapértelmezés az M2 GLM-mel, mert ez a párosítás volt a legjobb a kis üzem befagyasztott tesztjén (EXP-020: 31 helyes a 40-ből) és a nagy üzemen is (EXP-060: 51 helyes a 60-ból); ezt az oldal ki is írja. A demó a kis üzemen fut, mert annak négy lapja a képernyőn jól áttekinthető.

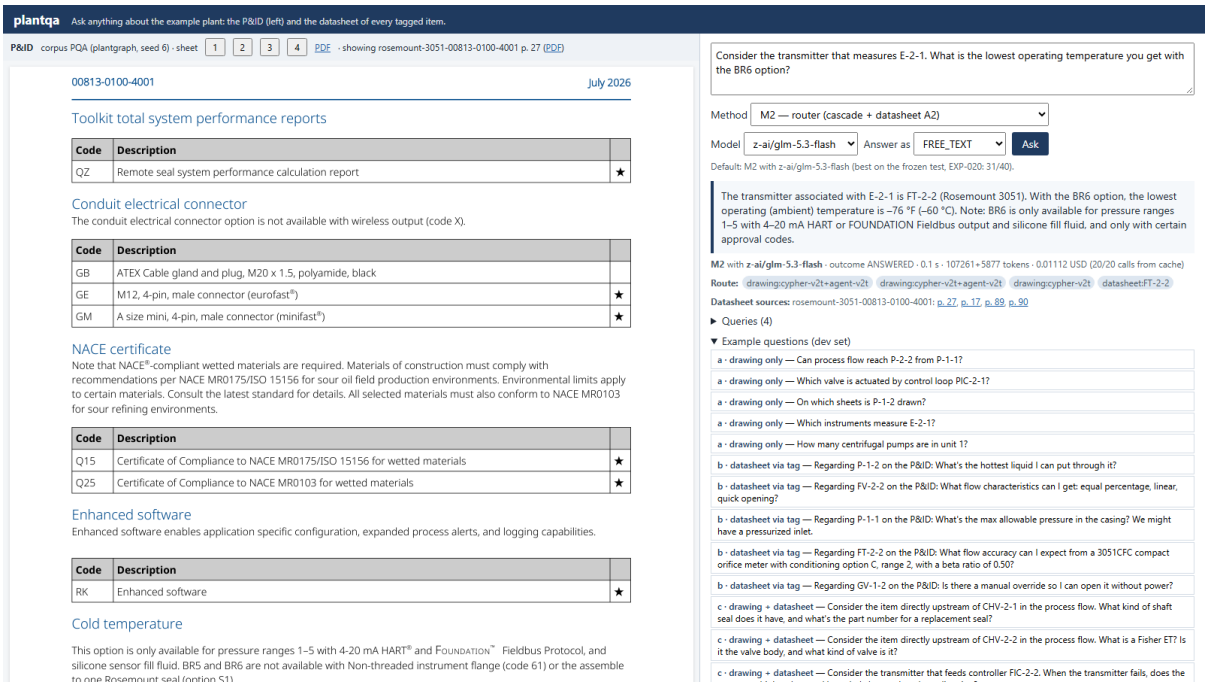
A válasz alatt a demó megmutatja a válasz nyomait: a módszert, a modellt, a kimenetelt, a késleltetést, a tokenszámot, a költséget és a gyorsítótárból jött hívások számát. Ezután következik az útvonal címkék sorozataként (az M1-nél a tierek és az adatlapi primitívhívások, az M2-nél a router eszközhívásai, az M3-nál a kontextus fajtája), az adatlapi forrásoldalak kattintható oldalszámként, és egy lenyitható blokkban a lefutott lekérdezések. Végül a dev halmaz kérdései szerepelnek példaként, családonként csoportosítva. A teszthalmaz kérdései nincsenek a példák között.

A képernyőképeket egy program készítette: minden kérdést előbb az API-n tett fel, majd fej nélküli böngészővel lefényképezte az oldalt. Ezért a képeken látható késleltetés a gyorsítótárból kiszolgált válaszé; a valódi késleltetést a 6. fejezet adja.

7.2 Két kérdés végigkövetve

Összetett kérdés a routerrel

Az első kérdés az összetett (c) családból való: „Consider the transmitter that measures E-2-1. What is the lowest operating temperature you get with the BR6 option?” A kérdés a hőcserélőt nevezi meg, a választ viszont a hőcserélőt mérő távadó adatlapja tartalmazza, és ott is csak egy rendelési opcióhoz kötve. A kérdés tehát egy topológiai lépést (melyik műszer méri az E-2-1-et?) és egy feltételes adatlapi tényt (a legalacsonyabb hőmérséklet a BR6 opcióval) kapcsol össze.

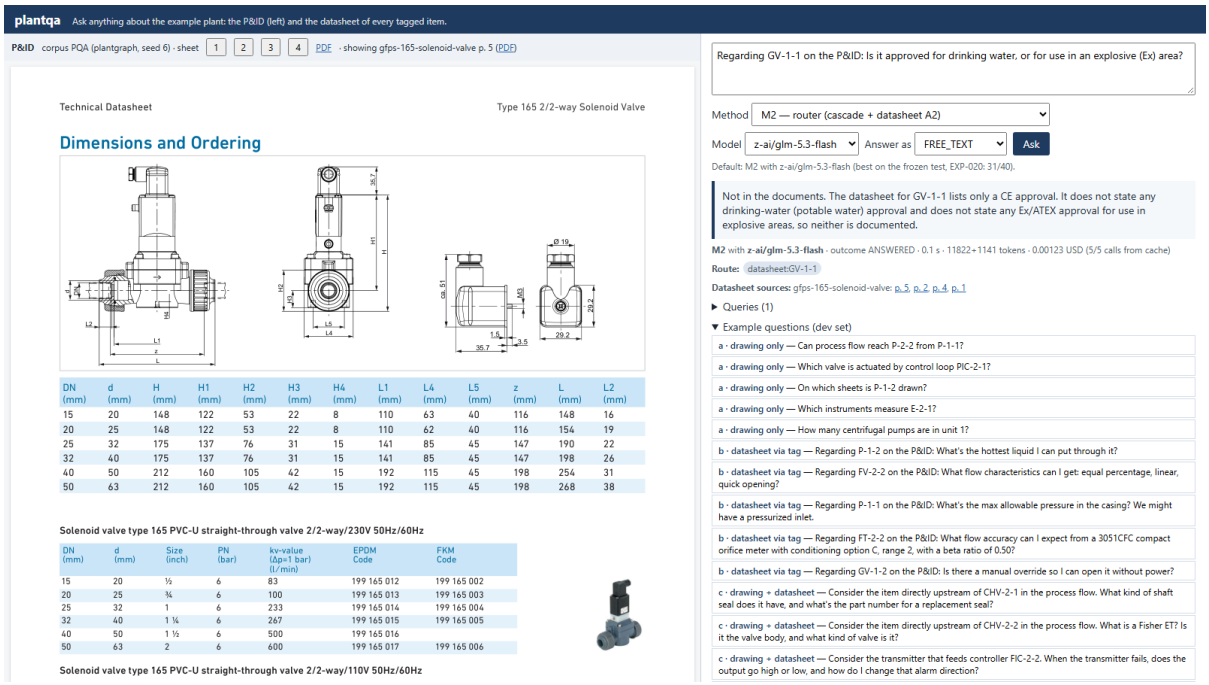


5. ábra: Összetett kérdés az M2-vel (EXP-040): a router előbb a rajzeszközt, majd a távadó adatlapját kérdezi; a bal oldalon a válasz egyik forrásoldala a Rosemount 3051 adatlapjából.

Az M2 útvonala (EXP-040): a router háromszor kérdezte a rajzeszközt, ebből kétszer a kaszkád a Cypher-szintről az ágensig jutott, egyszer a Cypher-szinten zárult; ezután az FT-2-2 adatlapját kérdezte. A válasz így kezdődik: „The transmitter associated with E-2-1 is FT-2-2 (Rosemount 3051).” Ezután megadja a BR6 opcióval elérhető legalacsonyabb környezeti hőmérsékletet Fahrenheit- és Celsius-fokban, és hozzáteszi, hogy a BR6 csak bizonyos nyomástartományokkal, kimenettel és töltőfolyadékkal rendelhető. Ez a plantdocs válaszírójának szabálya: egy érték a feltételei nélkül hibás lehet. A bal oldalon az adatlap azon oldala látszik, amely a hideg környezetre vonatkozó opció feltételeit írja le. A router tehát a tagot a rajzból szerzi meg, és az adatlapi kérdést már a tagre teszi fel, ahogy a rendszerüzenete előírja; a rajzeszköz ismételt hívása viszont a késleltetést növeli.

Megválaszolhatatlan kérdés és a részletes „nincs benne”

A második kérdés a (d) családból való, amelynek kérdéseire a dokumentumok nem adnak választ: „Regarding GV-1-1 on the P&ID: Is it approved for drinking water, or for use in an explosive (Ex) area?” A kérdés tagot nevez meg, ezért az M2 routere a rajzeszköz nélkül, közvetlenül a GV-1-1 adatlapját kérdezte (útvonal: `datasheet:GV-1-1`).



6. ábra: Megválaszolhatatlan kérdés az M2-vel (EXP-040): a router közvetlenül az adatlapot kérdezi, a válasz „nincs benne”, de megnevezi, mit tartalmaz az adatlap; a bal oldalon a GF 165 adatlap egyik forrásoldala.

A válasz „nincs benne” jelzésű, de nem áll meg ennyinél: „Not in the documents. The datasheet for GV-1-1 lists only a CE approval. It does not state any drinking-water (potable water) approval and does not state any Ex/ATEX approval…” (EXP-040). A felhasználó így azt is megtudja, mit tartalmaz az adatlap a tanúsításokról, és ellenőrizheti a forrásoldalon. Ez a megjelenítés egy hibajavítás eredménye, amelyet a demó egy korábbi próbája derített ki: a válasz megjelenítése és a bírálónak exportált jelölt szöveg a „nincs benne” jelzésnél eredetileg csak a jelzést mutatta, és elnyelte a mellette írt magyarázatot. A hibát kijavítottuk, az érintett dev-tételeket a javított szöveggel újrabíráltattuk, és a végső teszt exportja már a javított kóddal készült (`docs/dontesek.md`). A demó tehát nemcsak bemutató, hanem ellenőrző eszköz is volt: olyan hibát talált meg, amely a pontozást is érintette.

7.3 Tanulságok

A demó azt mutatja meg, amit a pontossági számok nem: az útvonal és a lekérdezések láthatók, így egy rossz válasz gyorsan felismerhető, és a forrásoldal egy kattintással a rajz helyén jelenik meg.

A demó korlátai: egy új kérdés élő LLM-hívásokba kerül, és másodpercekig tart (a gyorsítótár csak az ismétlést teszi ingyenessé); a demó egyetlen üzemet ismer, mert egy másik üzemhez a teljes összevont betöltést újra kellene futtatni; és angol nyelvű, mint a kérdéssor és a két forrásrendszer promptjai.

8. Összefoglalás

Két egyéni munkát kötöttünk össze: a P&ID-rajzokból épített üzemi gráfot és a gyártói adatlapokból épített, eszközönkénti ISO 15926 gráfokat. Egy seedelt, négylapos példaüzemen, amelynek minden tagelt fizikai eleméhez gyártói adatlap tartozik, egyetlen Neo4j-adatbázisba töltöttük a két réteget, és egy tagalapú kapcsolattal kötöttük össze őket. Három kérdés-válaszoló módszert mértünk két modellel egy 60 kérdéses, négy családra bontott kérdéssoron, befagyasztott teszthalmazzal.

8.1 Válaszok a kutatási kérdésekre

RQ1. A rajzot és az adatlapot összekötő kérdések megválaszolhatók az összevont gráfon: az M1 a teszten GLM-mel 25, Lunával 27 helyes választ adott a 40-ből (EXP-020). A két meglévő rendszert külön hívó router (M2) azonban pontosabb volt: GLM-mel 31 helyes válasszal ez lett a legjobb párosítás, és GLM-mel az M1 elmaradása mind az M2-től, mind a gráf nélküli M3-tól statisztikailag is kimutatható. Lunával a három módszer különbsége nem szignifikáns. A gráf nélküli baseline ezen a kis üzemen versenyképes volt.

RQ2. Kérdésenként az M1 volt a legdrágább (GLM-mel 0,00453, Lunával 0,00539 USD), az M2 GLM-mel körülbelül fele, Lunával 0,4-szerese ennyi (0,00234, illetve 0,00213 USD), az M3 a legolcsóbb (GLM-mel 0,00029 USD); a medián késleltetés 4 és 18 s között volt (EXP-020). A kis rajz miatt az M3 olcsó; Benedek mérései szerint a teljes rajzot promptba tevő megközelítés költsége a lapszámmal meredeken nő.

RQ3. A rajzi (a) és a megválaszolhatatlan (d) kérdéseken mindhárom módszer erős, a különbség az adatlapi (b) és az összetett (c) kérdéseken jön ki. Az M1 jellemző hibája a hiányos egylekérdezéses válasz: a kaszkád elfogadási szabálya a rajzi kérdésekre készült, és egy nem üres, de hiányos adatlapi sort is elfogad. Egyik módszer sem hallucinált a teszten. A kiegészítő, több adatlapos kérdéseken (EXP-030) a különbség még nagyobb: teljesen helyes választ csak a router adott (GLM-mel 3, Lunával 1 a 12-ből), legalább részben jót GLM-mel 9, Lunával 10 kérdésre, a gráf nélküli baseline 2, illetve 0 kérdésre.

8.2 Korlátok

- **Egy példaüzem, kis rajz.** Az eredmény egyetlen, 26 tagelt elemes, négylapos szintetikus üzemre érvényes; a rajzot Benedek v1 generátora állította elő, nem valódi rajz.
- **Modellkészítésű referenciák.** A (b)–(d) család referenciáit egy modell írta a PDF-ből, ember nem ellenőrizte őket; a bíráló is modell (vak, de nem ember).
- **Kis minta.** Családonként 10 tesztkérdés; a konfidenciaintervallumok szélesek.
- **Hiányzó szókészlet-ellenőrzés.** A POSC Caesar régi SPARQL-végpontja a mérés idején nem volt elérhető, ezért az új adatlapgráfokban csak az rds- és CFIHOS-illesztések szerepelnek.
- **A rajzot nem változtattuk.** A kaszkádot Benedek a valósághűbb v2 üzemekre hangolta; mi a v1 generátort használtuk, mert csak az szűkíthető az adatlappal rendelkező elemosztályokra.

8.3 Továbblépés

A legközvetlenebb javítás az M1 elfogadási szabályának adatlapi kérdésekre szabott változata (például a feltétel és az oldalszám meglétének ellenőrzése), és egy olyan Cypher-szint, amely a rajzi lépés után az adatlapi részt a plantdocs A2-re bízza. Hosszabb távon a mérést nagyobb, valódi rajzokon és emberileg ellenőrzött referenciákkal kell megismételni.

Irodalomjegyzék

A hivatkozott művek a két forrásrepó irodalmi jegyzeteiből származnak, az ott rögzített adatokkal. A tételek végén zárójelben áll, kinek a jegyzeteiben szerepel a mű: Szabó (plantdocs, `docs/private/10-literature/`), Kiszely (plantgraph, `docs/private/10-literature/` és `docs/Notes/`).

- [AIChE2010a] AIChE ChEnected (2010): „P&ID Part 3 – Symbology Primer". (Kiszely)
- [AIChE2010b] AIChE ChEnected (2010): „P&ID Part 4: Codes, Tags and Labels". (Kiszely)
- [Alimin2025] Alimin, Goldstein, Schulze Balhorn, Schweidtmann (2025): *Talking like Piping and Instrumentation Diagrams (P&IDs)*. arXiv 2502.18928. (Szabó, Kiszely)
- [Alimin2026] Alimin & Schweidtmann (2026): *GraphRAG for Engineering Diagrams: ChatP&ID Enables LLM Interaction with P&IDs*. arXiv 2603.22528; a folyóiratváltozat: AIChE Journal, doi 10.1002/aic.70540 (Szabó, Kiszely)
- [ArrowheadHandbook] POSC Caesar Association: Arrowhead fPVN Handbook és Use Cases (`docs.posccaesar.org/libraries-and-standards/arrowhead-handbook/`). (Kiszely)
- [CFIHOS] IOGP JIP36: CFIHOS (Capital Facilities Information Handover Specification), „Version 2.0". (Szabó, Kiszely)
- [Christensen2020] B. A. Christensen (2020): *Preparation of Process Flow Diagrams and Piping and Instrumentation Diagrams*, HNF-64103 Rev. 0. Mission Support Alliance, US DOE (Hanford). (Kiszely)
- [DEXPI2025] DEXPI e.V.: DEXPI Specification 2.0 (benne a DEXPI P&ID Specification 1.4), 2025. október. (Kiszely)
- [DEXPI2026news] DEXPI e.V. hír, 2026-03-23: a TotalEnergies a DEXPI szemantikus (BFO- és IDO-igazított) változatán dolgozik. (Kiszely)
- [Fan2026] Fan et al. (2026): GraphRAG-Router. arXiv 2604.16401. (Kiszely)
- [Gadekar2026] Gadekar, Sakhinana, Runkana (2026): *Grounded and Faithful P&ID Reasoning: Constraining Vision-Language Models with Recovered Evidence Graphs*. arXiv 2609.05880v1. (Kiszely)
- [Gjerver2025] A. Gjerver, R. Frostad, V. Barisic, M. Hodkiewicz, C. Woods, M. Fekete, A. B. Torjusen, J. W. Kluwer (2025): *Machine-interpretable Engineering Design Standards for Valve Specification*. arXiv:2510.01736, 2025-10-02. Kód és ontológia: `github.com/PCA-POSC-Caesar-Association/IDO_Use_Case_Valve_Ontology_Public` (CC BY-SA 4.0). (Szabó)
- [GoldenRetriever2024] szerzők a jegyzetben nincsenek (2024, az arXiv-azonosító szerint): Golden-Retriever. arXiv 2408.00798. (Szabó)
- [GraphCoT2024] szerzők a jegyzetben nincsenek: Graph-CoT. arXiv 2404.07103. (Kiszely)
- [Gupta2025] Mohit Gupta, Chialing Wei, Thomas Czerniawski, Ricardo Eiris (2025): *PIDQA - Question Answering on Piping and Instrumentation Diagrams*. Machine Learning and Knowledge Extraction 7(2), article 39, doi 10.3390/make7020039. (Szabó, Kiszely)
- [Hirtreiter2022] Hirtreiter, Schulze Balhorn, Schweidtmann (2022): *Towards automatic generation of P&IDs with AI*. arXiv 2211.05583; a jegyzet szerint AIChE J. 70(1) e18259. (Kiszely)

- [HyperGraphRAG2025] szerzők a jegyzetben nincsenek (2025): HyperGraphRAG. arXiv 2503.21322, NeurIPS 2025. (Szabó)
- [HyperRAG2026] szerzők a jegyzetben nincsenek (2026): HyperRAG. arXiv 2602.14470, WWW 2026. (Szabó)
- [IDO] IDO (Industrial Data Ontology), korábban ISO/TR 15926-14, most ISO 23726-3 (ISO DIS / FDIS 23726-3; „IDO v4.2 (FDIS, April 2026)"). (Szabó, Kiszely)
- [IOF] Industrial Ontologies Foundry: IOF, release 202603 (BFO-alapú, MIT). (Kiszely)
- [ISO10628-1] ISO 10628-1:2014 (folyamatábrák és P&ID-k), hivatalos előnézet, 1–5.4.3. fejezet. (Kiszely)
- [KBQAAgent2024] szerzők a jegyzetben nincsenek: Middleware / KBQA-Agent. arXiv 2402.14672. (Kiszely)
- [KGAgent2024] szerzők a jegyzetben nincsenek: KG-Agent. arXiv 2402.11163. (Kiszely)
- [Knollmeyer2025] Knollmeyer, Caymazer, Grossmann (2025): Document GraphRAG. Electronics 2025, 14(11):2102. (Szabó)
- [Kochanski2026] Kochański et al. (2026): „How Everllence Scaled P&ID Intelligence…". AWS Industries blog, 2026-05-27. (Kiszely)
- [Kumar2026] Kumar, Motiyani, Kasturi, Seefried, Movva, Ghosal (2026): *Enginuity: A Dataset and Benchmark for Vision-Language Understanding of Engineering Diagrams*. arXiv 2606.03410. (Szabó, Kiszely)
- [Lopomo2026] Lopomo et al. (2026): *Leveraging LLMs and Object Detection for Automated KG Generation from Industrial Schematics*. Big Data Cogn. Comput. 10(7):210, doi 10.3390/bdcc10070210. (Kiszely)
- [Mani2020] Mani, Haddad, Constantini, Douhard, Li, Poirier (C3.ai) (2020): *Automatic Digitization of Engineering Diagrams Using Deep Learning and Graph Search*. CVPRW 2020. (Kiszely)
- [MCPNeo4j] Neo4j `mcp-neo4j-cypher` (neo4j-contrib/mcp-neo4j), szoftver. (Kiszely)
- [OntoCAPE] RWTH Aachen AVT: OntoCAPE 2.0 (62 OWL-fájl, GPL). (Kiszely)
- [OPC30250] OPC Foundation: OPC UA for DEXPI (OPC 30250 v1.0). (Kiszely)
- [OPEN100] Energy Impact Center: OPEN 100 atomerőmű-terv P&ID-jei (www.open-100.com). (Kiszely)
- [PCARDL] POSC Caesar Association Reference Data Library: a régi `data.posccaesar.org/rdl/RDS…` és az új `rds.posccaesar.org/ontology/plm/rdl/` (equipment modul 0.9.1, CC BY-SA 4.0). (Szabó, Kiszely)
- [PID2Graph2025] Stürmer, Graumann, Koch (DLR) (2025): PID2Graph adatkészlet. Zenodo, doi 10.5281/zenodo.14803338, CC BY-SA 4.0. (Kiszely)
- [PidGraphAgent2026] GitHub `shaaz1000/pid-graph-agent` (2026), szoftver, nem lektorált. (Kiszely)
- [Prusty2025] Prusty, Agarwal, Iyenger (2025): *Advanced Integration of Discrete Line Segments in Digitized P&ID for Continuous Instrument Connectivity*. arXiv 2505.11976. (Kiszely)
- [pyDEXPI] process-intelligence-research/pyDEXPI, szoftver (AGPL-3.0). (Kiszely)
- [QUDT] QUDT (qudt.org), Release 2.1, CC BY 4.0. (Kiszely)
- [SchemaOrg] schema.org, V30.0 (2026-03-19). (Kiszely)
- [SchulzeBalhorn2025] Schulze Balhorn, Seijsener, Dao, Kim, Goldstein, Driessen, Schweidtmann (2025): *Rule-based autocorrection of Piping and Instrumentation Diagrams (P&IDs) on graphs*. arXiv 2502.18493. (Kiszely)

- [SOSASSN2017] W3C: SOSA/SSN, W3C Recommendation, 2017. október 19. (Kiszely)
- [StarE2020] szerzők a jegyzetben nincsenek (2020, az arXiv-azonosító szerint): StarE. arXiv 2009.10847. (Szabó)
- [StructRAG2025] szerzők a jegyzetben nincsenek (2025, az arXiv-azonosító szerint): Structured-data-aware RAG for technical documents. arXiv 2506.23136. (Szabó)
- [Sturmer2024] Stürmer, Graumann, Koch (DLR) (2024): *From Engineering Diagrams to Graphs: Digitizing P&IDs with Transformers*. arXiv 2411.13929, IEEE DSAA 2025. (Szabó, Kiszely)
- [Toghraei2019] M. Toghraei (2019): *Piping and Instrumentation Diagram Development*. Wiley/AIChE (2. kiadás: ISBN 9781394368587). (Kiszely)
- [Xiang2025] Xiang et al. (2025, az arXiv-azonosító szerint): GraphRAG-Bench, „When to use Graphs in RAG". arXiv 2506.05690v3. (Kiszely)
- [Zhu2026a] Baikai Zhu, Samuel Duong, Javal Vyas, Mehmet Mercangoez (2026): *From P&ID Drawings to Process Graphs: A Multimodal Language Model Approach*. arXiv 2607.19568. (Kiszely)

Függelék

A. Példakérdések családonként (dev halmaz)

7. táblázat: Két példakérdés családonként a dev halmazból, a referenciaválasz rövidítve (EXP-004)

Család	Kérdés	Referenciaválasz (rövidítve)
(a)	Can process flow reach P-2-2 from P-1-1?	no
(a)	Which valve is actuated by control loop PIC-2-1?	PV-2-1
(b)	Regarding P-1-2 on the P&ID: What's the hottest liquid I can put through it?	160 °F (71 °C) maximum liquid temperature (seal limit); the 250 psi max operating pressure applies only up to 100 °F (37 °C); consult the factory beyond.
(b)	Regarding FV-2-2 on the P&ID: What flow characteristics can I get: equal percentage, linear, quick opening?	Standard cages: quick-opening, linear or equal percentage. Whisper Trim, WhisperFlo and Cavitrol cages: linear only.
(c)	Consider the item directly upstream of CHV-2-1 in the process flow. What kind of shaft seal does it have, and what's the part number for a replacement seal?	Mechanical, self-lubricated seal: silicon carbide rotating and stationary faces, fluorocarbon (Viton or equivalent) elastomers, 316 stainless shaft sleeve and s
(c)	Consider the item directly upstream of CHV-2-2 in the process flow. What is a Fisher ET? Is it the valve body, and what kind of valve is it?	A sliding-stem, single-port globe-style control valve (body) with cage guiding, balanced valve plug and push-down-to-close plug action, for throttling or on-off
(d)	Regarding GV-1-2 on the P&ID: It hums but won't open. What could be wrong?	No troubleshooting in the datasheet. Related facts only: it needs at least 0.5 bar differential pressure to open; voltage must match the type plate (±10 %). The
(d)	Regarding PV-2-1 on the P&ID: The valve leaks through when shut. Is it the seat ring or the plug seal, and how do I check?	Not in the document (no troubleshooting).

B. Az M2 router rendszerüzenete

```
You answer questions about one industrial plant. You cannot see the documents
yourself; you have two tools:
- drawing(question): answers a question about the plant's P&ID drawing (which items exist
and
  their tags and types, what is connected to what, flow paths, upstream/downstream items,
  which instrument measures what, control loops, units, sheets).
- datasheet(tag, question): answers a question about the vendor datasheet of the item with
  this tag (its specification: pressures, temperatures, materials, sizes, options, ...).
  Items with a datasheet: <24 tags>.
If a question names an item by its position or role (e.g. "the valve downstream of P-1-
1"),
first ask the drawing tool for its tag, then ask the datasheet tool about that tag.
Each turn, reply with exactly one JSON object and nothing else:
{"tool": "drawing", "question": "..."}
{"tool": "datasheet", "tag": "...", "question": "..."}
{"final": {"answer": <answer or null>, "not_present": <true if the documents do not
contain
the answer, else false>}}
```

```
Answer only from the tool results. If the documents give only part of what is asked,
answer with that part and say which part is not stated; set not_present to true only when
they contain nothing relevant. Never add advice, procedures, causes or values that the
documents do not state.
Answer format: <Benedek answer-format sentence>
```

C. Az M1 Cypher-szintjének sémakiegészítése (eleje) és az új primitív leírása

```
DATASHEET LAYER (the same database also holds the datasheet of each tagged item)
- (:PlantItem {tag})-[:DESCRIBED_BY]->(device:Resource) joins a drawn item to the root
node of its
  datasheet graph. Several tags can share one datasheet graph (the same product). An item
without
  DESCRIBED_BY has no datasheet (e.g. a controller function).
- Every datasheet node has the property document_id (one value per datasheet) and a uri
that
  starts with 'urn:plantdocs:<document_id>:'. Parts: (part)-[:lis__partOf]->(device).
- For the facts of a tag: MATCH (p:PlantItem {tag: 'X'})-[:DESCRIBED_BY]->(dev)
  MATCH (d) WHERE d.document_id = dev.document_id AND (d:plm__PCA_100029511 OR
  d:plm__PCA_100029508 OR d:plm__PCA_100029510) ... and filter d by the words of the
question.
The datasheet graphs follow this model:
Ask the vendor datasheet of the item with this tag (pump, valve, transmitter, heat
exchanger, ...) one question about its specification, e.g. a pressure or temperature
limit, a material, a size or an option; returns the datasheet's answer with its PDF pages.
Use it for every property the drawing does not show; first find the tag on the drawing.
```

A sémakiegészítés ezután a plantdocs A2 `qa-cypher` promptjának GRAPH MODEL és RULES részét és a tagek dokumentumonkénti listáját tartalmazza (`src/plantqa/methods/m1.py`, `datasheet_schema`).

D. A két forrásfolyamat részletei

Ez a függelék a 4. fejezetben összefoglalt két forrásfolyamatot írja le olyan részletességgel, amennyi a gráfok szerkezetének megértéséhez kell. A két folyamat kódját nem módosítottuk; amit leírunk, az a két forrásrepó tervezési jegyzeteiből és kódjából származik.

A plantgraph üzemgenerátora

Benedek rendszerében a generátor egy teljes üzemet épít, a lapokra bontó (splitter) lapokra vágja, a feloldó (resolver) a lapokból megoldókulcs nélkül visszaépíti az üzemet, végül a betöltő Neo4j-be tölti. Mivel a bontást a rendszer maga végzi, pontosan tudható, melyik lapközi csatlakozó melyikkel alkot párt, és ehhez mérhető a feloldó.

A generátor minden véletlen döntést egyetlen seedelt véletlenszám-generátoron át hoz meg, ezért ugyanaz a seed ugyanazt az üzemet adja; a kimenet valódi pyDEXPI-modell. Az üzem egységekből (unit) áll. Egy egységen belül a berendezéseket sorban veszi fel, és mindegyik új berendezés véletlenszerűen választ szülőt a már meglévők közül, amelytől anyagáram fut hozzá (véletlen rekurzív fa); így elágazó, nem lánc alakú topológia jön létre. Ezt három, valószínűséggel vezérelt kiegészítés teszi valószerűbbé: egy későbbi berendezésből visszaforgató ág futhat egy korábbiba, minden új egység egy korábbi egység egyik berendezéséből kap bemenő áramot, és egy korábbi egységből kereszt-kapcsolat is futhat egy későbbi egység belsejébe.

Az áramokra szelepek kerülnek, a berendezésekhez pedig adott valószínűséggel szabályozókör tartozik: mérő (távadó), szabályozó, működtető és a szabályozott szelep. A tagek a szokásos betűket követik: a kör változója F, L, P vagy T, a távadó `FT-...`, a szabályozó `FIC-...`, a szabályozott szelep `FV-....` A generátor terve kifejezetten elveti a véletlen címkéjű véletlen gráfot: a berendezések az áramok végén állnak, a szelepek az áramokon ülnek, a szabályozókörök a berendezésekhez tartoznak, és csak ettől lesz értelme egy „mi táplálja ezt a szivattyút?" kérdésnek. Benedek két generátort készített; a mi példaüzemünk a v1 generátorral készült, mert a valósághűbb folyamatmintákat (oszlop, reaktor, biztonsági szelep) adó v2 generátor berendezésosztályai nem szűkíthetők az adatlappal rendelkező osztályokra (`docs/felmeres.md`).

A generátor minden mezőt megjelöl aszerint, hogy látható-e a vizsgált rendszer számára: látható a tag, az osztály, a vezetékszám és a csatlakozó felirata, rejtett a belső azonosító és az áram fajtája, mert ilyen jelölés egy valódi rajzon nincs. Ha egy több lapon felrajzolt berendezés minden előfordulása ugyanazt a belső azonosítót viselné, a feloldónak nem kellene semmit kitalálnia, ezért minden előfordulás átlátszatlan azonosítót kap.

A plantgraph lapokra bontója és a lapközi csatlakozók

A lapokra bontó egy teljes üzemgráfot vág lapokra egy lapkeret szerint, és minden elvágott élre egy lapközi csatlakozópárt illeszt: a forrás lapján egy kimenő, a cél lapján egy bejövő csatlakozót, amelyek felirata megnevezi a partner lapot és csatlakozót. A bontás stratégiája egy közös felület mögött cserélhető: az alapértelmezett a folyamat irányát követi, és a lapot a keretéig tölti; más stratégiák egységek szerint vagy közösségkereséssel vágnak, illetve a segédközegeket külön lapokra teszik; egy véletlen stratégia pedig kontrollként szolgál. A bontó csak lapgráfokat állít elő; a rajzexport külön komponens.

A laphatár kétféle kapcsolatot vághat el, és a bontó mindkettőt előállítja (lásd az alábbi táblázatot). A megoldókulcsot (csatlakozópárok, azonossági csoportok) külön fájlba írja, amely a vizsgált adatbázisba nem kerül be; a lapokból és a megoldókulcsból pontosan az eredeti gráfnak kell visszaállnia.

8. táblázat: A két lapközi mechanizmus (Benedek lapokra bontó tervjegyzete alapján)

	Lapközi csatlakozó	**Tag-azonosság**
Mi vágódik el	egy cső: egy él két részre	egy elem: egy csúcs két lapon
Visszaállítás	az elvágott él újraösszekötése	a duplikált csúcsok összevonása
Jel a rajzon	a csatlakozó felirata a partner lappal	az elem tagje
Ha elmarad	a gráf szétesik, a hiba látható	a gráf épnek látszik, a válaszok hiányosak

A példaüzem 4 lapja között 4 lapközi csatlakozópár van (EXP-002); a rajzexportban mind a 8 lapközi jel összekötött (EXP-003).

A plantgraph feloldója

A feloldó bemenete csak a lapok sorozata; a megoldókulcsot nem látja. A csatlakozók feliratából két csatlakozó akkor lesz pár, ha kölcsönösen egymásra hivatkoznak (mindkettő

a másik lapját és csatlakozószámát nevezi meg); a maradékot a vezetékszám és a közegkód szerint csoportosítja, és csak akkor párosít, ha egy csoportban pontosan egy kimenő és egy bejövő csatlakozó van. Minden más feloldatlan marad, megnevezett okkal; a feloldó nem találgat.

Az azonossági csoportokat a (tag, osztály) kulcs adja: ha egy ilyen kulcs két vagy több lapon fordul elő, az előfordulások egy elemet jelentenek. Alapértelmezésben csak berendezéseket von össze, és csak pontos egyezéssel. Végül az összefésülés minden csoportot a legtöbb tulajdonságot hordozó előfordulásával helyettesít, a csatlakozópárokon át újraköti az elvágott éleket, a párosítatlan csatlakozókat pedig meghagyja, hogy a hiány a kapuellenőrzésben látsszon. A legfőbb kapu az egyezés: a feloldott üzemnek az eredeti üzem látható nézetével kell megegyeznie; egy átnevezési próba pedig azt ellenőrzi, hogy az eredmény nem függ az átlátszatlan azonosítóktól. A példaüzemen a visszaépítési ellenőrzés hibátlan volt (EXP-002).

A plantdocs folyamatának lépései

A plantdocs egy gyártói adatlap PDF-jéből tíz számozott lépésben jut el az ontológia szerinti RDF-gráfig. A lépések felváltva programok és nyelvi modellek; minden nyelvimodell-lépésnek verziózott promptja van, és a kimenete csak akkor mehet tovább, ha átmegy a lépés szerződésén (egy programmal ellenőrzött formai és tartalmi feltételrendszeren). A programlépéseket egy visszamenőleges teszt újrafuttatja és összeveti a tárolt kimenettel. A lépéseket az alábbi táblázat foglalja össze.

9. táblázat: A plantdocs folyamatának lépései (a plantdocs 0007-es tervezési jegyzete alapján)

#	Ki végzi	Mit csinál
01	Azure Document Intelligence	oldalelrendezés, táblázatok és ábrák felismerése
02	nyelvi modell	rekordok: paraméter, érték, egység, a táblázatbeli útvonal
03	program, nyelvi modell, program	ábrák kivágása és osztályozása, a betű- és számjelek feloldása
04	program, nyelvi modell, program	diagramoldalak, leolvasás, vektoros ellenőrzés
05	program	a rekordok ellenőrzése a PDF szövegével
06	nyelvi modell, program	célformátum: tények, feltételek, lábjegyzetek, diagramok
07	program	az ábrákhoz tartozó lábjegyzetek
08	program, nyelvi modell, program	forrásleltár és forrásleírások, a végső célformátum
09	program, nyelvi modell, program	szókészlet: illesztés, hálózati ellenőrzés, szókészlet-térkép
10	program	RDF: IDO és POSC Caesar adatlap-ontológia

Az **01.** lépés az Azure Document Intelligence elrendezés-elemzése (bekezdések, táblázatok, ábrák); a plantdocs ezt adott eszköznek tekinti, nem kutatási hozzájárulásnak (plantdocs README). A **02.** lépésben egy nyelvi modell rekordokat ír: paraméter, érték, egység és a

táblázatbeli útvonal (táblázatcím, sor- és oszlopfejlécek) a lábjegyzetjelekkel. Ezek még lapos szövegek.

A **03.** lépés az ábrákat kivágja és osztályozza (fénykép, metszeti rajz, méretrajz, diagram), és a rajzokon a betű- és számjeleket alkatrésznevekhez vagy táblázatfejlécekhez köti; amit nem tud feloldani, azt feloldatlanként megtartja. A **04.** lépés a diagramokat olvassa le: egy szelepdiagram üzemi tartományok sokszögeiből, egy görbediagram pontsorozatokból áll; ahol lehet, a leolvasást a PDF vektoros vonalaival ellenőrzi, és a diagram fölötti címsorok feltételeit a diagramhoz rendeli. Az **05.** lépés minden rekord számát megkeresi a hivatkozott PDF-oldal szövegében.

A **06.** lépés hozza létre a célformátumot (lásd alább). Ehhez a plantdocs hibrid módszert használ: a program a rekordok útvonalát szegmensekre bontja, egy nyelvi modell táblázatonként egyszer megadja, melyik szegmens az alany, melyik a feltétel és melyik a tulajdonság (táblázatséma), és egy determinisztikus lépés ezt minden rekordra alkalmazza. Ez olcsóbb, mint rekordonként kérdezni, és egy táblázaton belül következetes. A **07.** lépés az ábrák lábjegyzeteit köti be, a **08.** lépés minden forrásról rövid leírást írat; ezek a lekérdezésnél a szakaszkatalógus sorai lesznek.

A **09.** lépés a szókészlet-illesztés. Egy nyelvi modell minden eszköztulajdonsághoz és feltétel-dimenzióhoz szabványos fogalmat keres, a program minden javasolt azonosítót újra lekérdez a hálózaton, és csak az ellenőrzött illesztés kerül a szókészlet-térképbe. A sorrend rögzített: előbb a POSC Caesar könyvtár pontos vagy tágabb fogalma, ha nincs, a CFIHOS-é; modell- vagy változatkódnál a könyvtár azonosítási osztálya; különben az IDO legáltalánosabb tulajdonság-osztálya (`Quality`) mint gyűjtő, ahol a pontos jelentést a nyomtatott címke hordozza. A gyűjtőbe kerülő tények aránya az illesztés minőségének jelzője. Az illesztés lefedettségét a plantdocs egy előzetes mérése vizsgálta: négy dokumentum eszköztulajdonságai és feltétel-dimenziói közül 88/133-hoz adott a POSC Caesar könyvtár pontos vagy tágabb fogalmat, a CFIHOS-szal együtt 101/133-hoz (a plantdocs `_results.md` szerint, EXP-0022; előzetes, kézi ellenőrzésre váró eredmény). A mi feldolgozásunkban a POSC Caesar régi SPARQL-végpontja HTTP 404-et adott, ezért a régi könyvtárral nem, csak az új végponttal és a CFIHOS-szal illesztettünk (EXP-006). Végül a **10.** lépés program: a végső célformátumot és a szókészlet-térképet RDF-gráffá alakítja, és jelentést ír a tények szintek szerinti eloszlásáról.

Az általunk feldolgozott négy adatlapon mind a 24 nyelvimodell-kimenet elsőre átment a plantdocs szerződésein (EXP-006).

A plantdocs célformátuma

A célformátum a kinyerés és a gráfépítés között álló, ontológiafüggetlen rekordformátum. Öt elvre épül (a plantdocs 0003-as tervezési jegyzete szerint):

1. Egy rekord egy tény, nem egy nyomtatott cella: ugyanannak a ténynek a két mértékegységben nyomtatott cellája egy rekord két nyomtatott értékkel.
2. A feltételek elsőrendű elemek, egy lista, nem egy név része. Egy tény a feltételei nélkül nem hiányos, hanem hibás.

3. Semmit nem javít csendben: a nyomtatott forma megmarad, a gyanús elírás jelzőt kap, és nem íródik felül.
4. Minden visszakövethető a forrásrekordokig és a PDF-oldalig.
5. A mutató nem érték: a kereszthivatkozás és a lábjegyzetjel típusos, hogy a gráfban él lehessen belőle.

Egy tényrekord vázlata a következő (a mezőnevek a plantdocs formátumáé, az értékek helyén leírás áll):

```
{
  "subject":    {"label": "<az alany, ahogy nyomtatva van>", "kind": "<alkatrész
fajtája>"},
  "property":   {"label": "<a tulajdonság nyomtatott neve>", "key": "<rövid kulcs>"},
  "value_type": "quantity | code | text | reference | not_limiting | expression",
  "values":     [{"value": "<szám>", "unit": "<egység>", "printed": "<ahogy nyomtatva
van>"}],
  "conditions": [{"dimension": "<feltétel-dimenzió>", "any_of": ["<megengedett
értékek>"]}],
  "footnotes":  ["<lábjegyzetrekordok azonosítói>"],
  "flags":      ["<például gyanús elírás, a mértékegység-pár nem egyezik>"],
  "source":     {"document": "<dokumentum>", "page": "<PDF-oldal>", "table": "<táblázat>"}
}
```

Az értéktípus megkülönbözteti a mennyiséget (erre illeszkedik a QUDT), a kódot (anyagjel, nyomásosztály), a szabad szöveget, a hivatkozást (egy másik táblázatra mutat, értéke nincs), a „nem korlátozó” jelölést (ami információ, nem hiány) és a képletet. A kimeneti fájl hat listát tartalmaz: tények, lábjegyzetek, ábrák, ábra–alkatrész kapcsolatok, diagramok és indoklással kihagyott rekordok; minden bemeneti rekord pontosan egy helyre kerül, semmi nem veszhet el csendben. A lábjegyzetben kimondott tények önálló tények, amelyek a lábjegyzetükre is visszamutatnak.

A plantdocs RDF-modellje

A plantdocs ontológiai döntése (ADR-0005) az ISO 15926 vonal: az IDO a felső ontológia, a POSC Caesar könyvtára az eszköz- és referenciaszótár, a mértékegység QUDT. A döntés mellett szólt, hogy szabványos és nyílt, és hogy a DEXPI is innen indul; ellene a tanulási görbe, és hogy a könyvtár eszközmodulja nem ad teljes tulajdonságkatalógust. A legfontosabb megkötés az, hogy saját, kézzel írt szókészlet nem lehet: minden osztály és tulajdonság szabványos azonosító, ami pedig a dokumentumból jön (címke, érték, feltétel), az adat, nem szókészlet. Ha nincs pontos szabványos fogalom, a legközelebbi tágabb kerül a gráfba, a pontos jelentést a dokumentum szövege hordozza. A rétegeket az alábbi táblázat mutatja.

10. táblázat: Az adatlapgráf rétegei (a plantdocs 0006-os tervezési jegyzete alapján)

Réteg	Szabvány	Mire
Nyelvtan	IDO, `lis:` előtag	fizikai tárgy, rész–egész, információs tárgy, érték és egység
Adatlap-szerkezet	POSC Caesar adatlap-ontológia	adatlap, bejegyzés (datum), alany, attribútum, eset, szakasz
Eszközosztály	POSC Caesar könyvtár	például szolenoidszelep, centrifugálszivattyú
Tulajdonság, feltétel-dimenzió	POSC Caesar könyvtár, ahol nincs: CFIHOS	például névleges átmérő

Réteg	Szabvány	Mire
Mértékegység	POSC Caesar egységmodul és QUDT	azonosító, illetve mennyiségfajta és átváltás
Egyéb	Dublin Core, SKOS, schema.org	leírás, jelölés, oldalszám

A leképezés a célformátumból a gráfba a következő. Az eszköz egy `lis:PhysicalObject` csúcs a POSC Caesar eszközosztályával; az alkatrészek szintén fizikai tárgyak, `lis:partOf` kapcsolattal az eszközre. Egy mennyiségi tény mennyiségi adatpont (Quantity Datum) a számmal, a mértékegységgel és tartomány esetén alsó és felső határral; egy szöveges vagy kód jellegű tény attribútum-adatpont (Attribute Datum); ha az érték maga szabványos osztály (például egy anyag), osztályozó adatpont (Classification Datum). Minden adatpont hordozza a nyomtatott címkét és értéket, a PDF-oldalt, az alanyát és, ha van, a szabványos attribútumát.

A feltételek együttese egy esetcsúcs (Case), amelyet a POSC Caesar úgy határoz meg, mint egy helyzetet, amelyen belül bizonyos attribútumértékek érvényesek. A tény egy kapcsolattal az esetre mutat, az eset címkéje felsorolja a feltételeket, és minden egyes feltétel maga is adatpont, amely ugyanerre az esetre mutat, a dimenzió szabványos attribútumával. A forrás (táblázat, ábra, diagram, szövegrész) szakaszcsúcs (Section Datum) a címmel, a 08. lépés leírásával és az oldalszámmal; a lábjegyzet külön adatpont, amelyre a tény kapcsolattal mutat. A diagramok pontjai pontonként egy-egy esetbe kerülnek.

Miért eset, és nem valami más? A feltételes tény n-áris, ezért kell egy csúcs, amely a feltételeket összefogja (2. fejezet). A plantdocs megvizsgált egy saját tény-csúcsot is, de a POSC Caesar adatlap-mintája ugyanezt szabványosan tudja, a saját szókészlet pedig ki volt zárva. Mérlegelte az IDO áram-mintáját is, amely az üzemi környezetet (nyomás, hőmérséklet, közeg) egy áramként modellezi, amelynek a szelep résztvevője; ez azonban egy üzemi helyre vonatkozó előírást ír le, nem egy gyártói adatlap feltételeit. A döntés végül az egységesség volt: minden feltétel-kombináció eset. Ennek ára, hogy az „eset” szót a szabvány elsősorban feltételezett helyzetekre használja, a plantdocs pedig termékváltozatokra és üzemi feltételekre is.

E. A módszerek részletei

Ez a függelék az 5. fejezetben leírt módszerek egyes lépéseit részletezi.

Az ágens primitívjei

Benedek ágense hat általános, egymással komponálható primitívet hív (ADR-0034). A primitívek a feloldó kimenetéből a memóriában épített elemgráfon futnak, amelyben a lapközi csatlakozók és a többszörösen felrajzolt elemek már össze vannak vonva; ez a gráf a betöltött üzemi réteggel egyezik. Az ágens tehát nem látja a laphatárokat, csak az üzemet.

11. táblázat: Az üzemi primitívek (Benedek ADR-0034-e alapján)

Primitív	Mit ad vissza
`find`	a szűrőnek megfelelő elemek (osztálycímke, osztály, egység, lap, tag, fajta szerint)

Primitív	Mit ad vissza
`neighbours`	egy elem közvetlen szomszédai egy relációcsoport mentén
`traverse`	bejárás egy kiinduló elemtől, megállási és szűkítő feltétellel
`path`	út két elem között
`filter`	egy korábbi eredmény szűkítése a közös szűrőnyelvvel
`aggregate`	egy korábbi eredmény csoportosítása vagy összesítése

A primitívek eredményei hivatkozást (handle) kapnak, így egy korábbi lépés eredménye a következő bemenete lehet. A szűrőnyelv mind a hat primitívnél ugyanaz, és ugyanazokat a címkeneveket használja, mint a Cypher-szint sémaszövege; a V2T ezt az elem fajtájával és a vonalnézet relációcsoportjával bővítette. A tervezési döntés lényege, hogy az eszközök száma a gráfsémából következik, nem a kérdéstípusokból: a hat primitív a séma szókincsén értelmezett szokásos gráfműveletek (kiválasztás, kiterjesztés, lezárás, legrövidebb út, szűkítés, csoportosítás), ezért egy új kérdéstípus egy új kompozíció, nem egy új eszköz. Az egyszerű JSON-akciók minden modellen ugyanúgy működnek, és a gyorsítótár változtatás nélkül vissza tudja játszani őket.

Az adatlapoldali A2 lépései

A plantdocs A2-módszere egy eszköz egy kérdésére a következő lépésekben válaszol.

1. **Kontextus.** A rendszerüzenet a plantdocs gráfmodelljének leírását (a 4. fejezetben bemutatott adatpont-, eset-, szakasz- és lábjegyzetcsúcsokat az előtagos neveikkel), az eszköz gráfjának leltárát (az eszköz és alkatrészei, a leggyakoribb adatpontcímkék, a források oldallal) és a forrásszakaszok katalógusát tartalmazza; a katalógus soronként egy táblázat, ábra, diagram vagy szövegrész a címével, típusával, oldalával, sorainak számával és a 08. lépésben írt leírásával.
2. **Lekérdezésírás.** Egy LLM alacsony gondolkodási szinttel egyetlen csak olvasó Cypher-lekérdezést ír, és mellette legfeljebb három forrásszakaszt választ, amelynek a teljes tartalmára a válasznak valószínűleg szüksége lesz. A lekérdezési szabályok széles keresést kérnek: a kérdés egy szava a címkében, a nyomtatott értékben, az eset címkéjében (a feltételekben) vagy egy forrásszakasz címében és leírásában is lehet; a lekérdezésnek mindig vissza kell adnia a nyomtatott értéket, a címkét, az esetet, a lábjegyzetet, a forrást és az oldalt.
3. **Futtatás és javítás.** Ha a lekérdezés hibát ad, üres, vagy túl sok sort ad vissza, a modell egy javítókörben megkapja a problémát („javítsd vagy bővítsd”, illetve „szűkítsd a legjellemzőbb szavakra”). Ha a választott szakaszokból jött sor, javítókör nincs; ha a javítás üres eredményt ad, az első, nem üres eredmény marad.
4. **Teljes szakaszok.** A kiválasztott szakaszok minden sora a lekérdezés sorai mellé kerül; ez azt az esetet fedi le, amikor a táblázat fejlécei nem a kérdés szavait használják.
5. **Vektoros keresés.** A lekérdezésírással párhuzamosan a kérdés beágyazásvektorához legközelebbi 30 adatpont kerül elő a gráf vektorindexéből, mindegyik az esetével, a lábjegyzetével, az oldalával és a forrásszakaszával. Mivel párhuzamosan fut, a késleltetéshez nem ad hozzá.
6. **Válaszírás.** A válaszíró csak a megtalált tényekből fogalmaz: előbb egy-két mondatban a közvetlen választ, utána az értékeket az egységükkel és azokkal a

feltételekkel, amelyek mellett érvényesek, oldalhivatkozással. A kérdést abban az értelemben kell olvasnia, ahogy az adatlap használja a szavait; egy szakkifejezést néhány szóval megmagyarázhat, de új tényt, értéket vagy eljárást nem tehet hozzá; ha a kérdés egy része nincs a tények között, ezt kimondja. A forrásoldalakat a program a felhasznált sorokból gyűjti össze.

Az M1 sémakiegészítésének felépítése

A sémakiegészítés első része az összekötést írja le (a `DESCRIBED_BY` nélküli elemnek, például egy szabályozófunkciónak nincs adatlapja; minden adatlapcsúcsnak van `document_id` tulajdonsága; egy tag tényei a fenti mintával érhetők el). Ezt követi a plantdocs A2-promptjának gráfmodell-része szó szerint, a dokumentumok és tagjeik listája, végül a plantdocs lekérdezési szabályai, amelyek a második fejlesztési iterációban kerültek be (EXP-011). A sémakiegészítés elejét a Függelék C mutatja.

Az M2 router protokollja

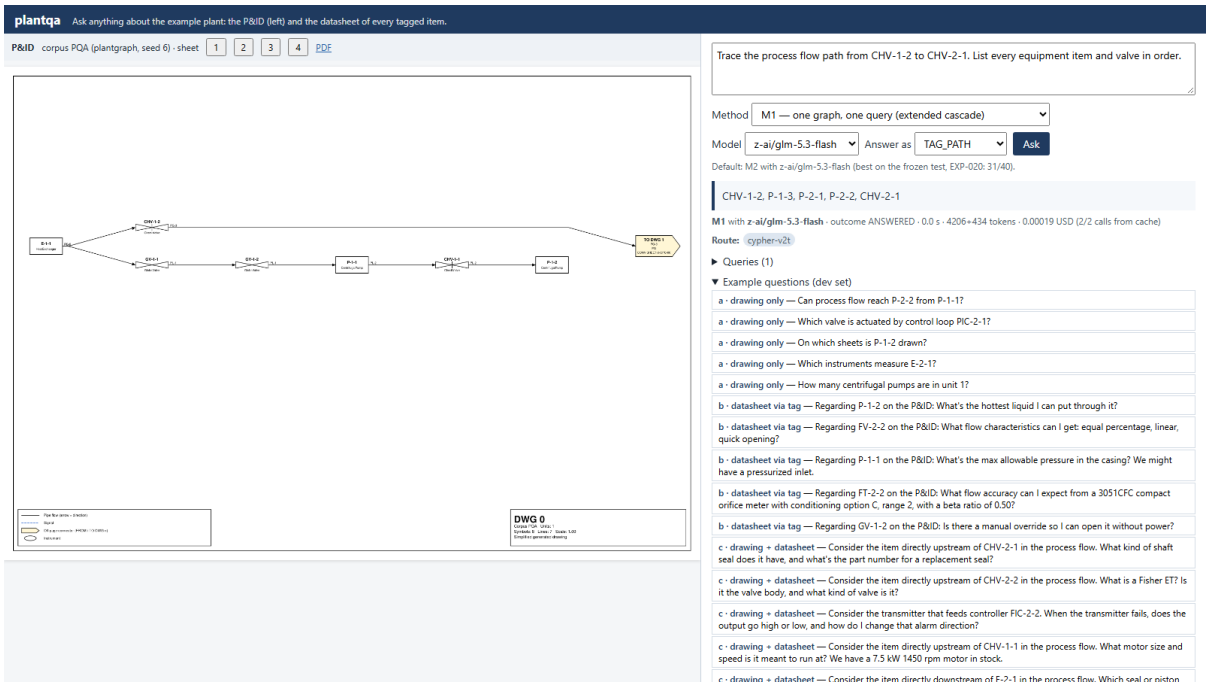
A rendszerüzenet leírja a két eszközt, felsorolja az adatlappal rendelkező tageket, megadja a három megengedett JSON-alakot (rajzeszköz-hívás, adatlap-hívás, végső válasz a „nincs benne” jelzővel) és a válaszalakot. A router minden lépésben pontosan egy JSON-objektumot ír; a program végrehajtja a hívást, és az eredményt egy új üzenetben („Tool result:”) adja vissza. Érvénytelen akcióra a router javító üzenetet kap; ha a lépéskeret elfogy, a kérdés lépéskorlát-eredménnyel zárul. Szolgáltatói hibánál (például hálózati hibánál) a hívás egyszer újrapróbálkozik, ahogy Benedek kaszkádja is; ha ez is hibás, a kérdés szolgáltatói hibával zárul, és rossznak számít. A router alacsony gondolkodási szinttel fut. A rendszerüzenet teljes szövegét a Függelék B tartalmazza.

F. További demó-képernyőképek

A 7. fejezetben bemutatott demópróba (EXP-040) további kérdései közül kettőt képernyőképpel, kettőt képernyőkép nélkül követünk végig.

Rajzi útvonal egyetlen lekérdezéssel (M1)

A demó próbájának egy további kérdése a rajzi (a) családból való, rendezett út válaszalakkal: „Trace the process flow path from CHV-1-2 to CHV-2-1. List every equipment item and valve in order.” Az M1-gyel feltéve a kaszkád a Cypher-szinten zárult (útvonal: `cypher-v2t`), egyetlen lekérdezéssel, és a válasz egy tagsorozat: „CHV-1-2, P-1-3, P-2-1, P-2-2, CHV-2-1” (EXP-040).

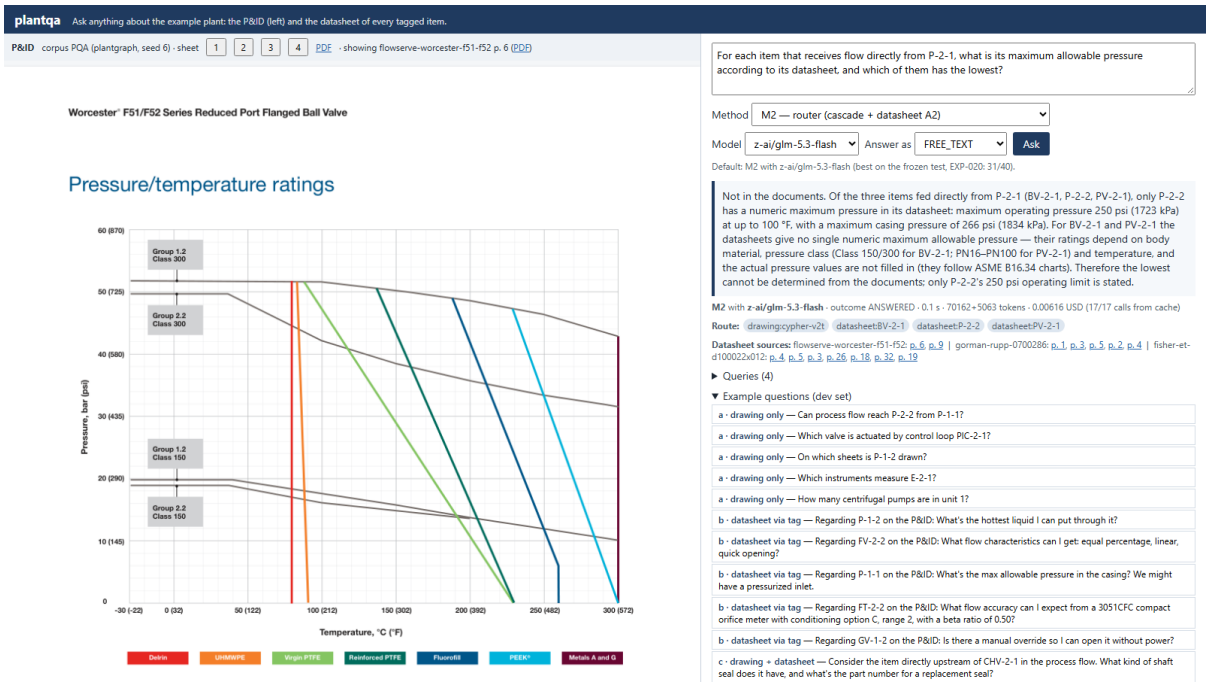


7. ábra: Rajzi útvonal az M1-gyel (EXP-040): a Cypher-szint egyetlen lekérdezéssel adja a rendezett utat; a bal oldalon a P&ID egyik lapja, a jobb szélén a lapközi csatlakozóval.

A bal oldalon a rajz egyik lapja látszik. A CHV-1-2 szelepből induló vezeték a lap jobb szélén egy lapközi csatlakozóban végződik, vagyis az út egy másik lapon folytatódik. A rajzon ezt az olvasónak kell követnie; az üzemi rétegben viszont a laphatár átlépése egyetlen él (4. fejezet), ezért a Cypher-szint egyetlen lekérdezéssel megtalálta a teljes utat, és a kaszkád az elfogadási szabálya szerint (válaszolt, nem tartózkodott, van sor, nem csonka) elfogadta.

Több adatlapos kérdés (M2)

Egy másik kérdés a külön mért, több adatlapos (e) családból való (EXP-009): „For each item that receives flow directly from P-2-1, what is its maximum allowable pressure according to its datasheet, and which of them has the lowest?” A kérdés egy halmazt kér a rajzból (mi kap közvetlenül áramot a P-2-1-ből?), majd a halmaz minden elemére egy adatlapi értéket, végül egy összevetést.



8. ábra: Több adatlapos kérdés az M2-vel (EXP-040): egy rajzi hívás után három adatlapi hívás; a bal oldalon a Worcester gömbcsap adatlapjának nyomás–hőmérséklet diagramja.

Az M2 útvonala (EXP-040): egy rajzeszköz-hívás, amely a Cypher-szinten zárult, majd három adatlap-hívás a BV-2-1, a P-2-2 és a PV-2-1 tagre, vagyis egy gömbcsap, egy szivattyú és egy szabályozószelep adatlapjára. A válasz „nincs benne” jelzésű részválasz: „Of the three items fed directly from P-2-1 (BV-2-1, P-2-2, PV-2-1), only P-2-2 has a numeric maximum pressure in its datasheet…” A folytatás szerint a másik két elem adatlapja nem ad egyetlen számszerű határt, mert a névleges nyomás a testanyagtól, a nyomásosztálytól és a hőmérséklettől függ, ezért a legkisebb érték a dokumentumokból nem dönthető el. A bal oldali nyomás–hőmérséklet diagram éppen ezt a függést mutatja.

Ez a válasz az 5. fejezetben leírt válaszszabály működését mutatja: a módszer a meglévő részt adja, és megnevezi a hiányzót, ahelyett hogy egy értéket találna ki. Hogy a válasz helyes-e, azt a próba nem pontozta.

Két további kérdés képernyőkép nélkül

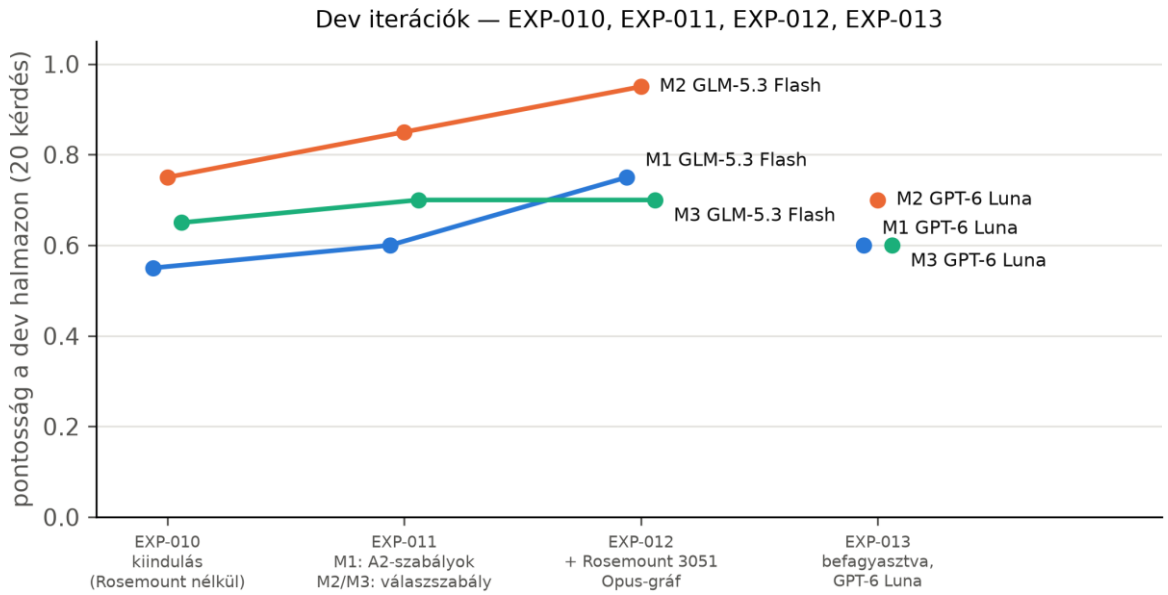
Az adatlapi (b) kérdésre („Regarding P-1-3 on the P&ID: What's the max allowable pressure in the casing? …”) az M1 a Cypher-szinten, egyetlen lekérdezéssel válaszolt; a rajzi (a) kérdésre („Which instruments measure E-2-1?”) az M3 egyetlen hívással az FT-2-2 tagot adta (EXP-040).

G. A kis üzem mérései

A módszereket a négylapos kis üzemen fejlesztettük és fagyasztottuk be; ez a szakasz a kis üzemen végzett mérések teljes leírása (a dolgozat korábbi változatának kiértékelése, változatlan számokkal).

Fejlesztési iterációk

A dev halmazon (20 kérdés) négy iterációt mértünk (lásd az alábbi ábrát). Az első iterációban (EXP-010) a Rosemount 3051 Opus-gráfja még nem készült el, ezért a nyomás- és áramlástávadóra vonatkozó adatlapi kérdések egyik gráfos módszerrel sem voltak megválaszolhatók. A második iterációban (EXP-011) az M1 Cypher-szintje megkapta a plantdocs A2 lekérdezési szabályait (széles keresés, eset, lábjegyzet és oldal visszaadása), az M2 és az M3 pedig egy válaszszabályt (részválasznál a meglévő rész és a hiányzó rész megnevezése, a dokumentumon túli tanács tilalma); az M2 és az M3 hallucinációi ezzel eltűntek. A harmadik iterációban (EXP-012) a Rosemount-gráf is bekerült: az M1 pontossága 0,60-ról 0,75-re, az M2-é 0,85-ről 0,95-re nőtt, az M3-é nem változott, mert nem használja a gráfot. A negyedik iterációban (EXP-013) a befagyasztott módszereket GPT-6 Lunával mértük: M1 0,60, M2 0,70, M3 0,60.



9. ábra: A dev halmazon mért pontosság iterációnként (EXP-010–EXP-013).

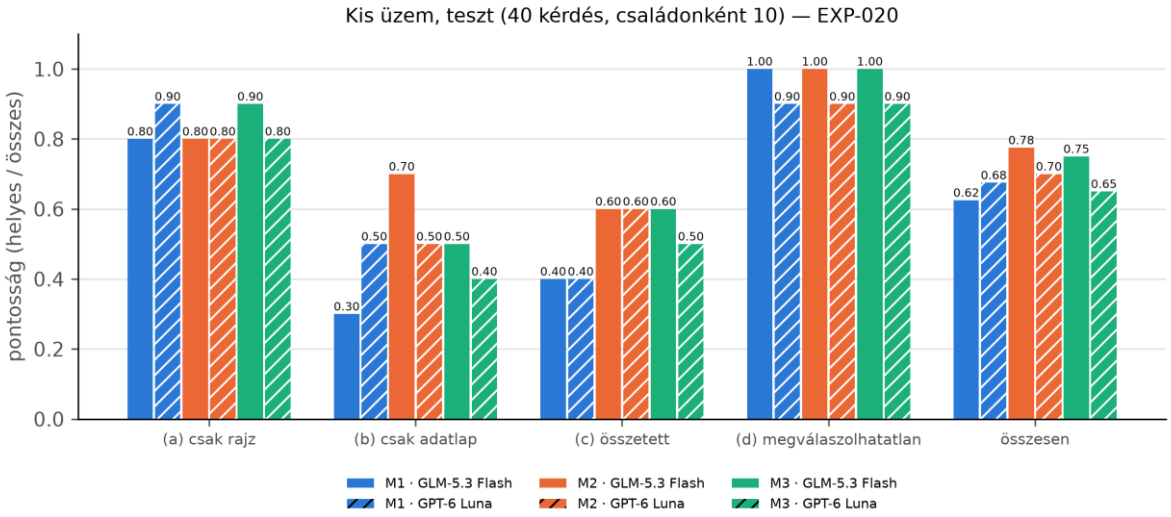
Végső mérés a teszthalmazon

A befagyasztott teszthalmaz (40 kérdés, családonként 10) mindegyik párosításon egyszer futott le (EXP-020). Az eredményt az alábbi táblázat és ábra mutatja.

12. táblázat: A végső teszt eredménye párosításonként és családonként (EXP-020)

Módszer	Modell	Helyes	Részben	Rossz	Hallucinált	Pontosság [95% CI]	(a)	(b)	(c)	(d)
M1	GLM-5.3 Flash	25	9	6	0	0,625 [0,475–0,775]	8/10	3/10	4/10	10/10
M2	GLM-5.3 Flash	31	6	3	0	0,775 [0,625–0,900]	8/10	7/10	6/10	10/10
M3	GLM-5.3 Flash	30	1	9	0	0,750 [0,600–0,875]	9/10	5/10	6/10	10/10
M1	GPT-6 Luna	27	6	7	0	0,675 [0,525–0,825]	9/10	5/10	4/10	9/10

Módszer	Modell	Helyes	Részben	Rossz	Hallucinált	Pontosság [95% CI]	(a)	(b)	(c)	(d)
M2	GPT-6 Luna	28	7	5	0	0,700 [0,550–0,850]	8/10	5/10	6/10	9/10
M3	GPT-6 Luna	26	6	8	0	0,650 [0,500–0,800]	8/10	4/10	5/10	9/10



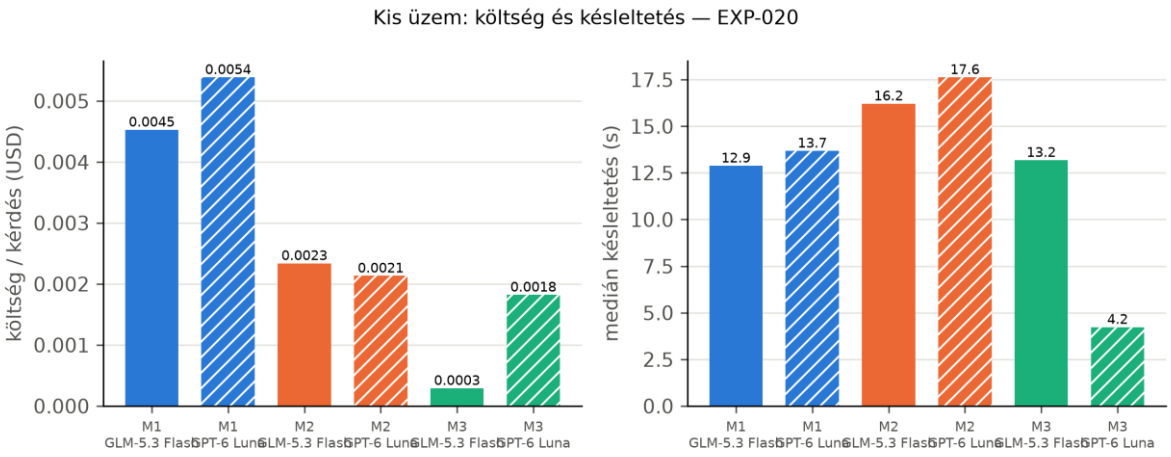
10. ábra: A végső teszt pontossága családonként, a hat párosításon (EXP-020).

A legjobb párosítás az M2 GLM-mel (31 helyes a 40-ből). GLM-mel az M1 szignifikánsan elmarad mind az M2-től (párosított különbség −0,150, 95% CI −0,275 és −0,025 között), mind az M3-tól (−0,125; −0,225 és −0,025 között), az M2 és az M3 különbsége viszont nem szignifikáns (+0,025; −0,075 és +0,125 között). Lunával egyik különbség sem szignifikáns. Egyik párosítás sem hallucinált a teszten; a megválaszolhatatlan kérdéseken (d) mindegyik módszer 9 vagy 10 helyes választ adott. A különbség a (b) és (c) családon jön ki: az adatlapi kérdéseken az M2 GLM-mel 7/10, az M1 GLM-mel 3/10.

Költség és késleltetés

13. táblázat: Költség, késleltetés és tokenhasználat kérdésenként a végső teszten (EXP-020)

Módszer	Modell	Költség / kérdés (USD)	Medián késleltetés (s)	Átlagos bemeneti token / kérdés	Átlagos kimeneti token / kérdés
M1	GLM-5.3 Flash	0,00453	12,9	81 492	3 940
M2	GLM-5.3 Flash	0,00234	16,2	33 068	2 221
M3	GLM-5.3 Flash	0,00029	13,2	13 264	1 820
M1	GPT-6 Luna	0,00539	13,7	56 398	1 578
M2	GPT-6 Luna	0,00213	17,6	35 765	1 115
M3	GPT-6 Luna	0,00182	4,2	12 901	425

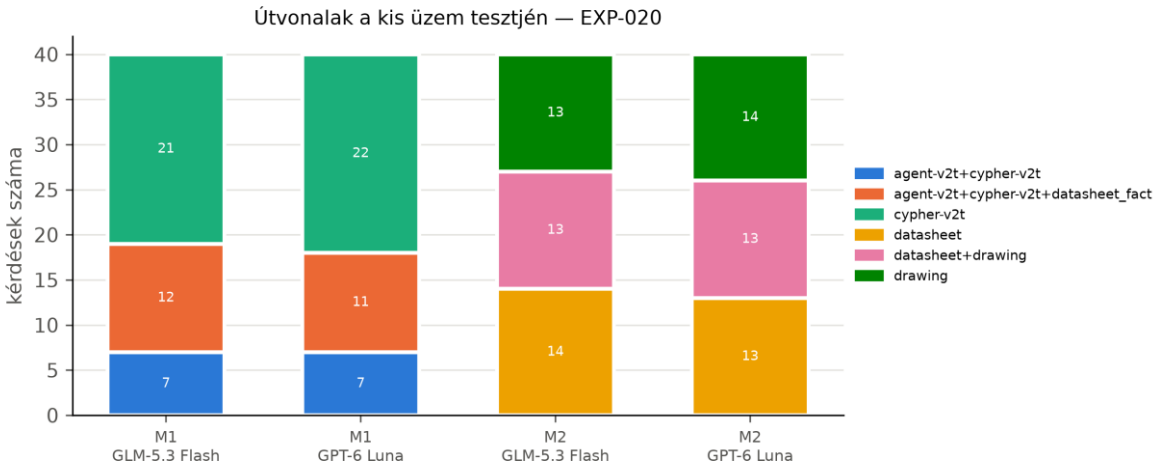


11. ábra: Kérdésenkénti költség és medián késleltetés (EXP-020); két külön panel, mert a két mennyiség skálája eltér.

A legdrágább az M1: a kaszkád első szintje a teljes kétrétegű sémát kapja promptban, és ha nem fogadják el a válaszát, az ágens is lefut, amely tagenként külön adatlap-hívásokat indít. Az M2 GLM-mel körülbelül feleannyiba kerül (0,00234 vs. 0,00453 USD), Lunával 40%-ába (0,00213 vs. 0,00539 USD), mert csak a szükséges eszközt hívja. Az M3 a legolcsóbb, és Lunával a leggyorsabb is: egyetlen hívás, de a teljes rajzot és tizenkét adatlap-darabot viszi magával. Ez a példaüzemen olcsó, mert a rajz kicsi (36 csúcs); Benedek mérései szerint a ContextRAG költsége a lapszámmal meredeken nő (a v2 üzemeken 1 lapon a kaszkád 3,79-szerese, 11 lapon 21,57-szerese, és kb. 62 lap fölött a rajz már nem fér a promptba; plantgraph EXP-0007-R4), ezért az M3 előnye nagyobb üzemen nem várható.

Útvonalak

Az M1 GLM-mel a 40 tesztkérdésből 21-et a Cypher-szinten zárt le, 7-hez az ágens is kellett adatlap-hívás nélkül, 12-höz az ágens és legalább egy `datasheet_fact` hívás; Lunával ugyanez 22, 7 és 11 (EXP-020). Az M2 GLM-mel 13 kérdésnél csak a rajzot, 14-nél csak az adatlapot, 13-nál mindkettőt kérdezte; Lunával 14, 13 és 13.



12. ábra: Az M1 és az M2 útvonalai a végső teszten (EXP-020).

Összetett, több adatlapos kérdések

A végső teszt után egy kiegészítő mérést is végeztünk 12 olyan kérdésen, amelyekhez a rajzon egy utat, egy elemhalmazt vagy két topológiai lépést kell bejárni, és két-három különböző adatlapot kell összevetni (például „Along the process flow path from E-1-1 to CHV-2-1, which item has the lowest maximum allowable pressure according to its datasheet?"). A referenciát program rakta össze a gold gráfból és egy vak Opus-agent által a PDF-ekből gyűjtött tényekből (EXP-008, EXP-009); négy kérdésnél a helyes válasz az, hogy a rajz nem mondja meg a beépített változatot, ezért a legkisebb érték nem dönthető el. A kérdéseket futtatás előtt befagyasztottuk, és a módszereken semmit nem változtattunk.

14. táblázat: Az összetett, több adatlapos kérdések eredménye (12 kérdés, EXP-030)

Módszer	Modell	Helyes	Részben	Rossz	Hallucinált	Költség / 12 kérdés (USD)	Medián késleltetés (s)
M1	GLM-5.3 Flash	0	5	6	1	0,0636	61,9
M2	GLM-5.3 Flash	3	6	3	0	0,0537	34,3
M3	GLM-5.3 Flash	0	2	10	0	0,0046	25,6
M1	GPT-6 Luna	0	6	6	0	0,0880	28,2
M2	GPT-6 Luna	1	9	2	0	0,1280	38,6
M3	GPT-6 Luna	0	0	12	0	0,0276	13,6

Ezek a kérdések mindegyik módszernek nehezek: teljesen helyes választ csak a router adott (GLM-mel 3, Lunával 1 kérdésre), a bíráló pedig „részben helyes" ítéletet adott, ha egy elemnél a második érték vagy a feltétel hiányzott. Ha a részben helyes válaszokat is számítjuk, a router GLM-mel 9, Lunával 10 kérdésnél adott legalább részben jó választ, az M1 5, illetve 6, a gráf nélküli baseline 2, illetve 0 kérdésnél. A különbség itt a legnagyobb: több adatlap összevetéséhez a rajzon kell bejárni az elemeket, majd mindegyik adatlapját külön lekérdezni, és ezt a router eszközhívásai természetesen leképezik, az egyetlen lekérdezés (M1) és az egyetlen prompt (M3) viszont nem.

Hibaelemzés

Az M1 egyetlen lekérdezése. Az M1 hibáinak nagy része „részben helyes" válasz: a Cypher-szint egy szűk lekérdezéssel talál egy releváns adatpontot, a kaszkád elfogadja a nem üres eredményt, és a válaszból kimarad egy feltétel vagy egy második érték. A dev halmazon (EXP-012) például a szivattyú 266 psi-s burkolatnyomása megvolt, a 100 °F-ig érvényes 250 psi-s üzemi határ nem. Az elfogadási szabály a rajzi kérdésekre készült, ahol a nem üres sorhalmaz jó jelzés; adatlapi kérdésnél a hiányos sor is nem üres.

A rajzi kérdések közös hibái. A teszt (a) családjában három kérdést több párosítás is elrontott. Az izolációs kérdésnél („To isolate P-1-5 from all upstream equipment, which valves must be closed?") a gold válasz egyetlen szelep, a módszerek többsége a felfelé eső összes szelepet felsorolta. A szabályozókörös kérdésnél („Which control loops act on valves

directly connected to P-2-1?") az M2 mindkét modellel a szelepet (PV-2-1) adta meg a kör (PIC-2-1) helyett: a router a rajzeszköznek szabad szöveges kérdést ad, és a válasz alakja ott elcsúszott. A P-2-1-ből lefelé eső elemek halmazánál az M1 GLM-mel és az M3 Lunával hiányos listát adott.

Megválaszolhatatlan kérdések. GLM-mel mindhárom módszer mind a 10 kérdést felismerte, Lunával 9-et; hallucináció nem volt. A három Luna-hiba: az M3 egy nem létező tagre (P-2-4) utat adott meg, az M2 egy nem létező tagre (FV-2-3) üres listát adott a „nincs benne" jelzés nélkül, az M1 pedig egy adatlapban nem szereplő tényre jelzés nélkül válaszolt (részben helyes).

A referencia korlátja. A (b)–(d) család referenciaválaszait egy modell írta a PDF-ből, és ember nem ellenőrizte őket; a bíráló ugyanazt a referenciát látta minden módszernél, ezért az összevetés igazságos, de az abszolút számok a referencia hibáival együtt értendők.