Budapesti Műszaki és Gazdaságtudományi Egyetem

Villamosmérnöki és Informatikai Kar

Távközlési és Mesterséges Intelligencia Tanszék

Tudásgráf-építés műszaki rajzokból és adatlapokból skálázható Q&A rendszerhez

Knowledge Graph Construction from Engineering Drawings and Datasheets for a Scalable Q&A System

Tudományos Diákköri Konferencia dolgozat

Szerzők: Szabó Zsombor István, Kiszely Benedek László

Témavezető: Hollósi Gergely László

Budapest, 2026

Kivonat

Egy ipari üzemet sokféle dokumentum ír le: a csővezeték- és műszerezési rajzok (P&ID-k) azt mutatják meg, hogyan kapcsolódnak egymáshoz a berendezések, a gyártói adatlapok pedig azt, mire képes az egyes eszköz. A mérnöki kérdések gyakran mindkettőt igénylik, például ha egy szivattyú utáni szelep megengedett nyomására vagyunk kíváncsiak. A nagy nyelvi modellek csak akkor válaszolnak megbízhatóan az ilyen kérdésekre, ha a dokumentumok szerkezete (melyik cső hová vezet, melyik érték milyen feltétellel érvényes) megmarad. Ezt a szerkezetet egy tudásgráf, vagyis a kapcsolatokat is tároló adatbázis képes megőrizni.

A munka két részre épül. A rajzoldali rész egy üzem összes rajzlapjából épít tudásgráfot, amelyben a laphatáron elvágott vezetékek újra összekapcsolódnak, és ezen egy kétlépcsős rendszerrel válaszol: előbb egyetlen adatbázis-lekérdezéssel, szükség esetén pedig egy gráfbejáró eszközöket hívó modellel. Az adatlapoldali rész egy eszköz PDF-adatlapjából olyan gráfot épít, amelyben minden érték mellett megmarad a mértékegysége, az érvényességi feltétele és a forrásoldala. A dolgozatban a kettőt összekapcsoljuk: a rajzi elemeket az azonosítójuk (tag-jük) alapján egy közös adatbázisban az adatlapgráfokhoz kötjük, majd három kérdés-válaszoló módszert vetünk össze: az összevont gráfon dolgozó rendszert (M1), a két meglévő rendszert külön hívó irányítót (M2) és egy gráf nélküli alapmódszert (M3).

Az első prototípust egy négylapos üzemen készítettük el. A közös rendszert két szintetikus, 30 és 50 lapos üzemen hangoltuk, majd befagyasztva egy 100 és egy 1000 lapos, a hangolás során nem használt üzemen mértük meg, üzemenként 60 kérdésen és 12, több adatlap összevetését igénylő kérdésen, két nyelvi modellel (GLM-5.3 Flash és GPT-6 Luna). Mindkét tesztüzemen az irányító bizonyult a legjobbnak a GLM-5.3 Flash modellel (60-ból 51, illetve 48 helyes válasz); az összevont gráfon dolgozó módszer ugyanezzel a modellel 50, illetve 43 helyes választ adott, a különbség nem szignifikáns. A gráf nélküli alapmódszer a 100 lapos üzemen kevesebb helyes választ adott, és a GPT-6 Luna modellel kérdésenként tízszer annyiba került, mint az irányító; az 1000 lapos rajz pedig már nem fér el a modellek kontextusában, így ott ez a módszer nem is futtatható. A gráfos módszerek kérdésenkénti költsége a tízszer nagyobb rajzon legfeljebb a kétszeresére nőtt. Az eredmények szintetikus üzemekre és modell által írt referenciaválaszokra érvényesek.

Kulcsszavak: tudásgráf, GraphRAG, nagy nyelvi modellek, P&ID, műszaki adatlapok, kérdés-válaszolás, ipari dokumentáció.

Abstract

An industrial plant is described by many kinds of documents: piping and instrumentation diagrams (P&IDs) show how the equipment is connected, vendor datasheets say what each device can do. Engineering questions often need both, for example the allowed pressure of the valve after a pump. Large language models answer such questions reliably only if the structure of the documents (which pipe leads where, which value holds under which condition) is kept. A knowledge graph, a database that stores these relations, can keep it.

The work has two parts. The drawing part builds a knowledge graph from all sheets of a plant, reconnecting the lines cut at sheet borders, and answers over it with a two-stage system (a database query first, then a model that calls graph-walking tools if needed). The datasheet part turns one device's PDF datasheet into a graph in which every value keeps its unit, its validity condition and its source page. In this thesis we connect the two: the drawing items are linked to the datasheet graphs by their identifiers (tags) in one database, and we compare three question-answering methods: a system over the merged graph (M1), a router that calls the two existing systems separately (M2), and a graph-free baseline (M3).

We built a first prototype on a four-sheet plant, tuned the joint system on two synthetic plants of 30 and 50 sheets, froze it, and measured it on a 100-sheet and a 1000-sheet plant not used during tuning, on 60 questions and 12 questions that compare several datasheets per plant, with two language models (GLM-5.3 Flash and GPT-6 Luna). On both test plants the router with GLM-5.3 Flash was best (51 and 48 of 60 correct); the method over the merged graph gave 50 and 43 correct answers with the same model, and the difference is not significant. On the 100-sheet plant the graph-free baseline gave fewer correct answers and, with GPT-6 Luna, cost ten times as much per question as the router; the 1000-sheet drawing no longer fits into the models' context, so the baseline cannot run there. The per-question cost of the graph-based methods at most doubled on the ten times larger drawing. The results hold for synthetic plants and model-written reference answers.

Keywords: knowledge graph, GraphRAG, large language models, P&ID, technical datasheets, question answering, industrial documentation.

Tartalomjegyzék

Kivonat ... 2
Abstract ... 3
Tartalomjegyzék ... 4
1. Bevezetés ... 7
1.1 Kutatási kérdések és hozzájárulások ... 8
1.2 Munkamegosztás ... 8
1.3 A dolgozat felépítése ... 8
2. Háttér és kapcsolódó munkák ... 10
2.1 P&ID-k és gyártói adatlapok ... 10
A P&ID mint dokumentum ... 10
A DEXPI és a pyDEXPI ... 10
A gyártói adatlap ... 11
Szabványok az adatlapi tények ábrázolására ... 11
Tulajdonsággráf és RDF ... 12
Feltételes tények ... 12
2.2 Kérdés-válaszolás P&ID-ken ... 12
Visszakeresés a rajz gráfján ... 12
A rajzok gráffá alakítása ... 13
Üzemi méretű kérdés-válaszolás: a plantgraph ... 13
2.3 Kérdés-válaszolás műszaki dokumentumokon ... 13
2.4 GraphRAG és visszakeresési stratégiák ... 14
2.5 Összevetés ... 14
3. Adatok és feladat ... 16
3.1 A példaüzemek ... 16
3.2 Adatlapok ... 18
3.3 A kérdéssor ... 18
3.4 Pontozás ... 19
4. Az összevont tudásgráf ... 20
4.1 A rajzi réteg ... 20
4.2 Az adatlapi réteg ... 21
4.3 Az összekötés ... 22
5. Kérdés-megválaszolási módszerek ... 24
5.1 Közös építőelemek ... 24
A rajzoldali kaszkád ... 24
Az ágens gráfműveletei ... 25
Az adatlapoldali A2 ... 25
5.2 M1: egy gráf, egy lekérdezés ... 26

5.3 M2: irányító a két rendszer fölött ... 26
5.4 M3: gráf nélküli alapmódszer ... 27
5.5 Hangolás a fejlesztési üzemeken ... 27
5.6 Költség és mérés ... 28
6. Kiértékelés ... 29
6.1 Beállítás ... 29
6.2 Az első prototípus a kis üzemen ... 29
6.3 Hangolás a fejlesztési üzemeken ... 29
6.4 A gráf nélküli módszer az 1000 lapos üzemen ... 30
6.5 Eredmény a két tesztüzemen ... 30
6.6 Költség ... 32
6.7 Több adatlapos kérdések ... 32
6.8 Hibaelemzés ... 33
7. Demó és esettanulmány ... 34
7.1 A demó felépítése ... 34
7.2 Két kérdés végigkövetve ... 34
Összetett kérdés az irányítóval ... 34
Megválaszolhatatlan kérdés és a részletes „nincs benne” ... 35
7.3 Tanulságok ... 36
8. Összefoglalás ... 37
8.1 Válaszok a kutatási kérdésekre ... 37
8.2 Korlátok ... 38
8.3 Továbblépés ... 38
Irodalomjegyzék ... 39
Függelék ... 41
A. Példakérdések családonként (fejlesztési halmaz) ... 41
B. Az M2 irányító rendszerüzenete ... 41
C. Az M1 sémakiegészítésének eleje és az adatlap-eszköz leírása ... 42
D. A két forrásfolyamat részletei ... 42
A plantgraph üzemgenerátora ... 42
A plantgraph lapokra bontója és a lapközi csatlakozók ... 43
A plantgraph feloldója ... 43
Az adatlapok PDF-jei ... 44
A plantdocs folyamatának lépései ... 44
A plantdocs célformátuma ... 45
A plantdocs RDF-modellje ... 46
E. A módszerek részletei ... 47
Az ágens gráfműveletei ... 47
Az adatlapoldali A2 lépései ... 48

Az M1 sémakiegészítésének felépítése 49
Az M2 irányító protokollja 49
A módszerek várható erősségei és gyengeségei 49
Útvonalak a tesztüzemeken 50
F. További demó-képernyőképek 50
Rajzi útvonal egyetlen lekérdezéssel (M1) 50
Több adatlapos kérdés (M2) 51
Két további kérdés képernyőkép nélkül 52
G. A kis üzem mérései 52
Fejlesztési iterációk 52
Végső mérés a teszthalmazon 53
Költség és késleltetés 54
Útvonalak 55
Összetett, több adatlapos kérdések 55
Hibaelemzés 56

1. Bevezetés

Egy ipari üzemet több ezer oldalnyi, sokféle dokumentáció ír le. A csővezeték- és műszerezési rajzok (angol rövidítéssel P&ID-k) azt mutatják meg, hogyan kapcsolódnak egymáshoz a berendezések, szelepek és műszerek; a gyártói adatlapok pedig az egyes eszközök műszaki jellemzőit adják meg. A rajzon minden elemnek egyedi azonosítója, tag-je van (például P-101 egy szivattyú), és ez köti össze a rajzot az eszköz adatlapjával. Az üzemeltető és a tervező mérnökök kérdései gyakran mindkét dokumentumfajtát érintik: „Mekkora a megengedett legnagyobb nyomás azon a szelepen, amely a P-101 szivattyú nyomóoldalát elzárja?" A válaszhoz előbb a rajzon kell megtalálni a szelepet (a vezeték akár egy másik rajzlapon is folytatódhat), majd a tag-je alapján az adatlapját, és abban a megfelelő feltételhez tartozó értéket. Ma ezt kézzel végzik.

A nagy nyelvi modellek (angol rövidítéssel LLM-ek) kézenfekvő segítségnek tűnnek, az üzemi dokumentáció azonban nehéz terep számukra. A lényeges információ jelentős része nem egyetlen elemben van, hanem a kontextusban: egy táblázat fejlécében, egy értéket korlátozó lábjegyzetben vagy egy lapközi csatlakozóban, amely egy csővezetéket egy másik rajzlapon folytat. Ezt a szerkezetet egy tudásgráf teheti explicitté. A tudásgráf olyan adatbázis, amelyben a dolgok csúcsok, a köztük lévő kapcsolatok élek; a gráfalapú, visszakereséssel kiegészített generálás (GraphRAG) során a modell a kérdéshez tartozó részt visszakeresi a gráfból, és ebből fogalmazza meg a választ. Ez azonban csak akkor működik, ha a gráf megőrzi a kontextust.

Közös munkánk ugyanennek a dokumentációnak két, egymást kiegészítő oldalát vizsgálja. A rajzoldali rész, Kiszely Benedek László egyéni munkája (a továbbiakban **plantgraph**), egy egész üzem rajzlapjaiból épít tudásgráfot: a berendezések és műszerek csúcsok, a csövek és jelvezetékek élek, és a lapok határán megszakadó vezetékek újra összekapcsolódnak. Erre a gráfra építve egy kétlépcsős rendszer, a **kaszkád** válaszol a kérdésekre: először egyetlen adatbázis-lekérdezéssel próbálkozik, és ha ez nem elég, egy gráfbejáró eszközöket hívó nyelvi modell, egy úgynevezett ágens veszi át a kérdést. Az adatlapoldali rész, Szabó Zsombor István egyéni munkája (a továbbiakban **plantdocs**), egy-egy eszköz PDF-adatlapjából épít tudásgráfot, amelyben minden érték mellett megmarad a mértékegysége, az érvényességi feltétele (például „csak 100 °F alatt") és a forrásoldala, vagyis az adatlapnak az az oldala, ahol az érték nyomtatva szerepel. A feltételt azért kell megőrizni, mert egy feltétel nélküli érték nem hiányos, hanem hibás. A plantdocs a gráf lekérdezésére két módszert hasonlított össze; ebben a munkában a jobbat, az **A2**-t használjuk, amely a gráfra egy nyelvi modell által írt adatbázis-lekérdezéssel és jelentés szerinti (vektoros) kereséssel válaszol.

A két munka együtt ugyanazt a kérdést járja körül: hogyan őrizhető meg a szerkezet és a kontextus, amikor az ipari dokumentációt gráffá alakítjuk. Mindkettő egyetlen dokumentumfajtára szorítkozik, így természetes továbblépés, hogy az eszközönkénti adatlapgráfokat a rajzokon szereplő berendezésekhez kössük, és az egész üzemről egyetlen lekérdezhető modell jöjjön létre. Ez a dolgozat ezt a lépést teszi meg, és megméri, mennyire jól válaszolnak az így kapott rendszerek a két dokumentumfajtát együtt igénylő kérdésekre.

1.1 Kutatási kérdések és hozzájárulások

A dolgozat három kérdésre keres választ. Először arra, hogy a rajzokból és az adatlapokból külön épített tudás összeköthető-e egyetlen lekérdezhető tudásgráfban úgy, hogy közben a rajz kapcsolatai és az adatlapi értékek feltételei is megmaradjanak (RQ1). Másodszor arra, hogy egy ilyen gráf fölött működő kérdés-válaszoló rendszer megbízhatóan megválaszolja-e a mindkét dokumentumfajtát igénylő kérdéseket, és hogyan viszonyul két kézenfekvő alternatívához: a két meglévő rendszer külön hívásához és a gráf nélküli megoldáshoz, amely a teljes rajzot a modell elé teszi (RQ2). Harmadszor arra, hogy hogyan változik a pontosság és a költség, ha az üzem mérete egy nagyságrenddel nő (RQ3).

A válaszokhoz négy lépésben jutottunk el, és ezek adják a dolgozat hozzájárulásait. Először áttekintettük a mérnöki tervezési dokumentumok, elsősorban a P&ID-k és a gyártói adatlapok gépi feldolgozásáról és a rajtuk működő kérdés-válaszolásról szóló szakirodalmat; ebben nem találtunk olyan munkát, amely a kettőt összekötné (2. fejezet). Másodszor megvizsgáltuk, hogy a P&ID-kból és a hozzájuk tartozó adatlapokból építhető-e integrált tudásgráf: a rajzi üzemi réteget és hét eszköz adatlapgráfját egy adatbázisba töltöttük, és a tag-ek alapján összekötöttük, a két forrásrendszer módosítása nélkül (4. fejezet). Harmadszor erre a gráfra kérdés-válaszoló rendszert, vagyis chatbotot építettünk három változatban, és egy webes demóban mindegyiket kipróbálhatóvá tettük a válasz útvonalával és forrásoldalaival együtt (5. és 7. fejezet). Negyedszer a rendszert működőképességre és skálázhatóságra teszteltük öt, ugyanazzal a generátorral készült üzemen, a 4 lapostól az 1000 laposig, üzemenként 60 kérdésen és 12, több adatlapot összevető kérdésen, két nyelvi modellel; a hangoláshoz és a teszthez külön üzemeket használtunk (3. és 6. fejezet).

1.2 Munkamegosztás

A rajzoldali rendszert (az üzemgenerátort, a lapokra bontást és a visszaépítést, az üzemi gráfot és a kaszkádot) Kiszely Benedek László, az adatlapoldali rendszert (a feldolgozó folyamatot, az ISO 15926 szerinti adatlapgráfot és az A2-lekérdezést) Szabó Zsombor István készítette egyéni munkaként. Ebben a dolgozatban mindkét rendszert változtatás nélkül használjuk. Az összevonást, a kérdéssort, a három kérdés-válaszoló módszert, a méréseket és a demót közösen készítettük. A továbbiakban a két rendszerre a nevükkel (plantgraph, plantdocs) hivatkozunk.

1.3 A dolgozat felépítése

A 2. fejezet a hátteret és a kapcsolódó munkákat foglalja össze. A 3. fejezet a mérés tárgyát mutatja be: a példaüzemeket, az adatlapokat, a kérdéssort és a pontozást. A 4. fejezet leírja, hogyan épül fel az összevont tudásgráf, az 5. fejezet pedig a rá épülő három kérdés-válaszoló módszert. A 6. fejezet a mért eredményeket, a 7. fejezet a demót mutatja be két végigkövetett kérdéssel, a 8. fejezet pedig összefoglalja a kutatási kérdésekre adott válaszokat és a munka korlátait. A függelékek a példakérdéseket (A), az M2 és az M1 promptjainak részleteit (B, C), a két forrásfolyamat részletes leírását (D), a módszerek

lépéseinek részleteit (E), további demó-képernyőképeket (F) és az első, négylapos prototípus méréseit (G) tartalmazzák.

2. Háttér és kapcsolódó munkák

Mielőtt a két rendszer összekötésére rátérnénk, áttekintjük, mit kell tudni a két dokumentumfajtáról, milyen szabványok írják le őket gépileg értelmezhető formában, és mit ért el eddig a szakirodalom a rajzokon és a műszaki dokumentumokon végzett kérdés-válaszolásban. A fejezet végén egy táblázatban vetjük össze a kapcsolódó munkákat, és megmutatjuk, melyik lépés hiányzik.

2.1 P&ID-k és gyártói adatlapok

A P&ID mint dokumentum

A csővezeték- és műszerezési rajz (P&ID) az üzem központi tervdokumentuma: megmutatja, mely berendezések, szelepek és műszerek vannak az üzemben, és hogyan kapcsolódnak egymáshoz [1], [2].

A rajzi elemeket a tag azonosítja (például P-101, FT-202). A tag betűi az elem fajtáját és szerepét jelölik. A műszereknél az első betű a mért változó (F áramlás, P nyomás, L szint, T hőmérséklet), a további betűk a funkció (például T távadó, IC szabályozó), és a betűk a hurokszámmal együtt adnak egyedi azonosítót [3]. Az FT-202 például így olvasható: F = a mért változó az áramlás, T = a műszer távadó, 202 = a szabályozókör (hurok) száma; ugyanennek a körnek a szabályozója FIC-202. A csővezetékek azonosítója, a vezetékszám szokás szerint névleges átmérőből, közegkódból, sorszámból, csőosztályból és szigetelésből áll [4]. A példaüzemeink tag-jei ugyanezt a betűrendszert követik, de a hurokszám helyett az egység és a sorszám áll bennük: a P-1-3 az 1. egység harmadik szivattyúja, az FT-2-2 a 2. egység második szabályozókörének áramlástávadója.

Egy valódi üzem rajza sok lapra tagolódik. A laphatáron átmenő vezetéket lapközi csatlakozó (off-page connector) folytatja: a lap szélén álló, feliratozott jel, amely megnevezi a másik lapot, és amelyhez a másik lapon egy párja tartozik. A rajzi szabályok szerint a többlapos rajzok vezetékvégei kölcsönösen hivatkoznak egymásra [5], és a rajzok közötti hivatkozó jelek jól strukturált rajzszámot hordoznak, amely akár reguláris kifejezésekkel is összeköthető [6].

A laphatár két különböző kapcsolatot vághat el, és ezek elmulasztása más-más hibát okoz. Ha egy csövet vág el, két csatlakozó jelzi, hogy a vezeték a másik lapon folytatódik; ha a gráf építője nem köti össze őket, az út megszakad, és ez egy egyszerű ellenőrzéssel észrevehető, mert a csatlakozó párja nélkül marad. Ha viszont egy elemet vág el, ugyanaz a berendezés több lapon is megjelenik, az egyiken teljes adataival, a többin csak a tag-jével. Ha ezeket az előfordulásokat a gráf építője nem vonja össze, ugyanaz a berendezés két külön csúcsként kerül a gráfba, mindkét csúcsnak vannak kapcsolatai, és a gráf épnek látszik. Egy, a berendezésről szóló kérdés (például „mi táplálja ezt a hőcserélőt?”) azonban csak az egyik csúcs kapcsolatait látja, így a válasz hiányos lesz, és ezt semmi nem jelzi.

A DEXPI és a pyDEXPI

A rajzok digitális cseréjének szabványa a DEXPI, amely egy UML információs modell saját XML-formátummal [7]. Érdemes három szintet megkülönböztetni: a rajzi szabvány (például

az ISO 10628) azt mondja meg, hogyan néz ki egy szimbólum; az információs modell azt, milyen osztályok és attribútumok vannak; az ontológia pedig ugyanezt formális logikával és globális azonosítókkal írja le. A DEXPI információs modell, ontológiaformája nincs, de az osztályai az ISO 15926 szabvány referenciakönyvtárából származnak, így jelentésük rögzített [7]. Egy DEXPI-modell egyetlen rajzot ír le; azt, hogy két lapon lévő elem ugyanaz, nem modellezi.

A DEXPI szemantikus változata épülőben van: a TotalEnergies a DEXPI ontológiai alapokra helyezésén dolgozik [8], a POSC Caesar egy kézikönyve pedig a DEXPI tulajdonságmodelljét igazítja egy ipari ontológiához, egyelőre egyetlen kézzel írt példán [9]; az OPC UA ipari kommunikációs szabvány felé is van leképezés [10]. Ezért ebben a dolgozatban nem építünk P&ID-ontológiát, hanem a kapcsolódó munkákhoz hasonlóan a DEXPI osztályneveit használjuk a rajzi elemek típusaként. A DEXPI Python-megvalósítása a pyDEXPI, amely a rajzot gráffá is tudja alakítani [11]; a ChatP&ID és elődje is ennek osztályneveit teszi a gráfcsúcsokra [12], [13], és a plantgraph generátora is pyDEXPI-modellt épít, ezért a példaüzemek elemei is ezeket az osztályneveket viselik (például CentrifugalPump, CheckValve).

A gyártói adatlap

A rajz csak a kapcsolatokat mutatja; az egyes eszközök műszaki jellemzőit (nyomás- és hőmérséklethatár, anyag, méret, rendelhető opciók) a gyártói adatlapok tartalmazzák. Egy adatlap néhány oldalastól több mint száz oldalasig terjedő PDF, táblázatokkal, lábjegyzetekkel, feltételekhez kötött értékekkel és diagramokkal.

Az adatlapi tény ritkán egyetlen szám. Egy szabályozószelep adatlapján egy hőmérsékleti határ csak egy adott testanyagra és csatlakozóméret-tartományra érvényes, egy lábjegyzet tovább szűkíti, és ugyanaz az érték két mértékegységben is ki van nyomtatva. Ha egy rendszer ebből csak a számot és az egységet őrzi meg, a válasza nem hiányos, hanem hibás lehet. A plantdocs végső mérésén éppen a feltételes kérdéseken volt nagy a két lekérdezési módszer különbsége: a 31 feltételes kérdésből az A1 21-re, az A2 28-ra, a 17 több feltételt kombináló kérdésből 7-re, illetve 15-re adott helyes választ.

Szabványok az adatlapi tények ábrázolására

Az adatlapi tények gépileg értelmezhető leírására több, egymásra épülő szabvány létezik. Az alapfogalmakat (fizikai tárgy, rész és egész, információ, érték és mértékegység) az IDO (Industrial Data Ontology) adja; ez OWL 2 nyelven írt ontológia, korábban ISO/TR 15926-14 volt, ma ISO 23726-3 néven szabványosítják [14]. A konkrét berendezés-, cső- és műszerosztályokat és tulajdonságaikat a POSC Caesar szervezet referenciakönyvtára (PCA RDL) sorolja fel [15]. A CFIHOS azt írja le, milyen adatokat kell átadni egy üzem átadásakor (tag-ek, berendezésosztályok jellemzői, dokumentumadatok) [16], a QUDT pedig a mértékegységeket és a mennyiségfajtákat [17]. Más szókészletek (OntoCAPE [18], SOSA/SSN [19], IOF [20], schema.org [21]) erre a célra nem alkalmasak: vagy régóta nem frissülnek, vagy nem írják le a folyamatüzemi berendezéseket. A plantdocs ezért az ISO 15926 vonalat választotta, és ugyanerre épül egy friss munka is, amely a szelepek tervezési

szabványait IDO-alapú ontológiává alakítja [22]. Mivel a DEXPI osztályai is az ISO 15926-ból származnak, a rajzi és az adatlapi oldal ugyanarra a szemantikai alapra épül.

Tulajdonsággráf és RDF

A tudásgráfok két elterjedt formája az RDF és a tulajdonsággráf. Az RDF-ben minden állítás egy alany–állítmány–tárgy hármas, az azonosítók globálisak, és az élnek nincs saját tulajdonsága. A tulajdonsággráfban (legismertebb megvalósítása a Neo4j adatbázis, amelynek lekérdezőnyelve a Cypher) a csúcsoknak és az éleknek is lehetnek tulajdonságaik, az azonosítók pedig helyiek. A ChatP&ID szerzői az attribútumokban gazdag mérnöki adat miatt a tulajdonsággráfot választották [12], és a plantgraph is Neo4j-re épül. A plantdocs adatlapgráfja RDF-ben készül (mert az IDO is RDF-alapú ontológia), de egy bővítménnyel (neosemantics) Neo4j-be is betölthető; ez a híd teszi lehetővé, hogy a két réteg egy adatbázisba kerüljön.

Feltételes tények

Az adatlapi tények jelentős része több szereplős: egy érték egy alanyról, egy tulajdonságról és több feltételről egyszerre szól. Az ilyen tények egyszerű hármasokra bontása elveszíti a feltételt [23]. Erre a hiper-relációs tudásgráfok és a hipergráfos RAG ad ábrázolást: a tényekhez fűzött minősítők javítják a hiányzó kapcsolatok előrejelzését [24], a HyperGraphRAG pedig a több szereplős tényeket hiperélekként tárolja [25]. A tárolás kérdése tehát elvben megoldott. A nehézség a kiolvasás: a PDF a feltételt gyakran csak az elrendezésével fejezi ki, például egy táblázat fejlécével, egy lábjegyzettel vagy azzal, hogy egy érték egy diagram melyik tartományába esik. Hogy a mi adatlapgráfunk hogyan tárolja a feltételeket, azt a 4. fejezet mutatja be.

2.2 Kérdés-válaszolás P&ID-ken

Visszakeresés a rajz gráfján

A legközelebbi előzmény a ChatP&ID [12]: DEXPI-rajzokat alakít Neo4j-gráffá, és egy ágens négy visszakeresési módszer közül választ. A ContextRAG az egész (sűrített) gráfot szövegként a promptba teszi, keresés nélkül. A VectorRAG a kérdéshez jelentés szerint leghasonlóbb csúcsok leírását adja. A PathRAG egy így talált csúcsból lépésenként bejárja a szomszédokat. A CypherRAG-ban a modell a kérdést Cypher-lekérdezéssé fordítja, az adatbázis lefuttatja, és az eredmény kerül a promptba. Egyetlen lapon, 19 kérdésen a ContextRAG adta a legjobb eredményt; a szerzők szerint viszont ez a módszer többlapos rajzoknál nem skálázódik. Egy korábbi munka ugyanettől a csoporttól a sűrített gráfot visszakeresés nélkül adja a modellnek, egy folyamatábrán, három kérdésen értékelve [13]. A legnagyobb közölt P&ID-kérdéskészlet a PIDQA-é: 500 szintetikus rajzlapon 64 000 programmal előállított kérdés-válasz pár; a rajzból képfelismeréssel Neo4j-gráf készül, a kérdést egy nyelvi modell fordítja Cypher-lekérdezéssé, és minden kérdés egyetlen lapra vonatkozik [26].

Raszteres rajzokon Gadekar és társai előbb visszanyerik a folyamatgráfot, majd a látás-nyelvi modell a topológiai kérdésekre csak hét, tényt visszaadó gráfműveleten keresztül válaszolhat [27]; ez a megkötés jelentősen javítja a pontosságot, de egylapos, szintetikus

rajzokon. Egy nyílt forráskódú ágens hét általános gráfeszközzel kérdez DEXPI-fájlokon, kérdésenként egy fájlon [28], egy ipari esettanulmány pedig olyan tudásgráfot ír le, amely helyreállítja a lapok közötti kapcsolatokat, de kiértékelést nem közöl [29].

A rajzok gráffá alakítása

A rajzok digitalizálását mi nem végezzük el, de a kérdés-válaszolás bemenete ennek a kimenete. Egy transzformeres módszer a szimbólumokat és a kapcsolataikat együtt ismeri fel, és ehhez kiadta a PID2Graph adatkészletet, amelynek gráfjai címkék és lapok közötti megoldókulcs nélküliek [30], [31]. Javasoltak automatikus tudásgráf-építést ipari rajzokból [32], szabályalapú javítást a rajz gráfján [33], mesterséges rajzgenerálást [34], a töredezett vonalszakaszok folytonos gráffá egyesítését [35] és multimodális nyelvi modellel végzett, kétlépéses digitalizálást [36] is. Valódi, többlapos, nyilvános rajzsorozatból kevés van; az OPEN100 sorozat 12 lapja ezek közé tartozik [37].

Üzemi méretű kérdés-válaszolás: a plantgraph

A fenti munkák egy-egy rajzlapot vizsgálnak, és a rajzon kívüli dokumentumokat nem kapcsolják be. A plantgraph a rajzi kérdés-válaszolást üzemi méretben vizsgálja. Mivel nincs nyilvános, a lapok közötti kapcsolatok megoldókulcsával ellátott többlapos rajzkészlet, szintetikus üzemeket generál: egy véletlenszám-generátor dönt az üzem felépítéséről, és ennek kezdőértéke, a seed, egyértelműen meghatározza az üzemet (ugyanaz a seed mindig ugyanazt az üzemet adja). A kérdéseket és a referenciaválaszokat program számolja ki az ismert üzemgráfból, és a válaszokat is program pontozza; a pontosság a helyes válaszok aránya. A generátornak két változata van: egy egyszerűbb és egy valósághűbb, amelynek üzemeiben oszlopok, reaktorok, biztonsági szelepek és a berendezések között sok jelöletlen idom is van.

A plantgraph mérései két tanulsággal szolgálnak ehhez a dolgozathoz. Az első, hogy a teljes rajz promptba tétele (a ContextRAG) nem skálázódik. Az egyszerűbb generátor üzemein ennek pontossága 1 lapról 30 lapra 0,824-ről 0,658-ra csökkent, miközben a kaszkádé 0,941-ről 0,947-re változott, és kérdésenként 1 lapon 1,8-szer, 30 lapon 41,5-ször annyiba került, mint a kaszkád. A szövegként leírt rajz egy bizonyos méret fölött el sem fér a modell promptjában; ez a határ az egyszerűbb generátor üzemein körülbelül 143, a valósághűbbén körülbelül 62 lap. A második tanulság, hogy a kaszkád nagy üzemen is működik. A valósághűbb generátorra hangolt és befagyasztott kaszkád a hangolás során nem használt üzemeken kb. 100 lapon 440 kérdésből 401-re (0,911), kb. 1000 lapon 392-re (0,891) adott helyes választ. A −0,020-es különbség nem szignifikáns: a 95%-os konfidenciaintervallum, vagyis az a tartomány, amelyben a valódi különbség nagy valószínűséggel van, −0,059 és +0,018 között van, tehát a nullát is tartalmazza. A kérdésenkénti költség 0,00137, illetve 0,00148 USD volt. Ezt a hangolt kaszkádot használjuk mi is (5. fejezet); a számokat nem mérjük újra, a 6. fejezetben háttérként szolgálnak.

2.3 Kérdés-válaszolás műszaki dokumentumokon

Gyártási dokumentumokon a Document GraphRAG a dokumentum saját szerkezetéből és egy automatikusan épített gráfból dolgozik [38]; a szerzők elismerik, hogy szakterületen az

automatikus tudásgráf-építés pontatlan, ezért ma is főleg kézi munka. Ipari tudásbázison a Golden-Retriever a visszakeresés előtt azonosítja és tisztázza a szakzsargont és a rövidítéseket [39]. A táblázatokat és a szerkezetet külön kezelő RAG-módszerek [40] azt jelzik, hogy az adatlapi táblázatok a sima szövegdarabolástól eltérő kezelést igényelnek. Mérnöki rajzokat és kézikönyveket feldolgozó látás-nyelvi modellek egy friss mérésen megtalálják a tételeket, de gyakran pontatlanul írják le őket, és a szövegátfedésen alapuló metrikák alulmérik a képességüket, ezért a szerzők nyelvi modellel bíráltatják a válaszokat [41]. A szabad szöveges válaszokat mi is bírálóval pontozzuk (3. fejezet).

A plantdocs egyetlen eszköz adatlapjából épít ISO 15926 és QUDT szerinti tudásgráfot, amelyben a feltételek és a kereszthivatkozások külön elemek maradnak. Két lekérdezési módszert hasonlított össze: az A1 a gráf RDF-formáját kérdezi, az A2 a Neo4j-be töltött gráfot, vektoros kereséssel kiegészítve. A végső mérésen (a Rosemount 3051 távadó adatlapjának 200 befagyasztott kérdésén, vak bírálóval) az A1 141, az A2 172 kérdésre adott helyes választ, ezért ebben a munkában az A2 az adatlapoldal alapja.

2.4 GraphRAG és visszakeresési stratégiák

A gráfalapú visszakeresés nem mindig jobb a szövegalapúnál. Egy szöveges korpuszon végzett mérés szerint kis korpuszon a sima RAG nyer, és a gráf előnye a korpusz méretével jelenik meg [42]. A ChatP&ID egylapos eredménye és a plantgraph üzemi méretű mérései ugyanezt a mintát mutatják a rajzokon, ezért kis üzemen a gráf nélküli módszer erős ellenfél.

Ha több visszakeresési stratégia áll rendelkezésre, kérdésenként lehet közöttük választani. A GraphRAG-Router megerősítéses tanulással tanított irányítója kérdésenként választ a módszerek és a modellek között [43]; a mi M2 irányítónk ennek egyszerű, tanítás nélküli változata, amelyben egy nyelvi modell dönti el lépésenként, melyik meglévő rendszert hívja. A tudásgráfon végzett kérdés-válaszolás bevett mintája az ágens, amely lépésenként eszközöket hív a gráfon, és az eredményekből állítja össze a választ. A KBQA-Agent hét tudásbázis-eszközt ad, és minden lépés eredménye nevet kap, így egy későbbi lépés név szerint visszautalhat rá [44]; hasonló mintát követ a KG-Agent [45] és a Graph-CoT [46]. A skála másik végén a szabad lekérdezés áll: a Neo4j modellekhez készült szervere csak sémalekérdező, olvasó és író Cypher-eszközt ad, a lekérdezést a modell írja [47]. A plantgraph ágense a KBQA-Agent családjába tartozik, a kaszkád pedig a kettőt kombinálja: a kérdést előbb a legolcsóbb lépcsőnek, egyetlen lekérdezésnek adja, és csak akkor viszi tovább az ágenshez, ha a válasz gyanús. A gyanú forrása önjelzés, vagyis olyan jel, amelyet a lépcső maga ad a válaszáról a helyes válasz ismerete nélkül, például a hibát dobó vagy üres lekérdezés. Az ilyen szabály nem illeszt paramétert a mért adatra, ezért kevésbé hajlamos a túlillesztésre.

2.5 Összevetés

Az alábbi táblázat azt foglalja össze, hogy a kapcsolódó munkák a probléma mely részeit fedik le; a kiértékelés méretét a forrás szerint adjuk meg.

1. táblázat: A kapcsolódó munkák összevetése

Munka	Rajz	Adatlap	Több lap	Gráf	Kiértékelés mérete
ChatP&ID [12]	igen (DEXPI)	nem	nem, egy lap	Neo4j	19 kérdés
Talking like P&IDs [13]	igen (DEXPI)	nem	nem	sűrített gráf a promptban	3 kérdés, egy folyamatábra
PIDQA [26]	igen (szintetikus, raszteres)	nem	nem, kérdésenként egy lap	Neo4j, Cypher	64 000 kérdés, 500 lap
Gadekar és társai [27]	igen (raszteres)	nem	nem	visszanyert folyamatgráf, 7 művelet	3000 kérdés, szintetikus lapok
pid-graph-agent [28]	igen (DEXPI)	nem	nem, kérdésenként egy fájl	gráfeszközös ágens	15 + 37 saját kérdés
Everllence-esettanulmány [29]	igen	nem	igen	Neo4j, ágens	nem közöl
Lopomo és társai [32]	igen (126 rajz)	nem	nincs adat	automatikusan épített tudásgráf	gráfépítés, nem kérdés-válaszolás
Document GraphRAG [38]	nem	gyártási dokumentumok	–	dokumentumszerkezet és példánygráf	nincs adat
Enginuity [41]	mérnöki rajzok	kézikönyvek, alkatrésztáblák	–	nincs	6940 oldal
plantgraph	igen (szintetikus)	nem	igen, kb. 100 és 1000 lap	Neo4j, üzemi réteg	460 kérdés a lezárt teszten
plantdocs	nem	igen, egy eszköz	–	ISO 15926 / QUDT, RDF és Neo4j	200 kérdés
Jelen munka	igen (4–1000 lapos szintetikus üzemek)	igen, 7 adatlap	igen	összevont Neo4j-gráf	üzemenként 60 + 12 kérdés

A rajzoldali munkák szinte mind egylaposak, és egyikük sem kapcsolja be az eszközök adatlapjait; az egyetlen többlapos ipari példa kiértékelést nem közöl. A dokumentumoldali munkák pedig nem használják a rajz topológiáját. Egy mérnöki kérdés gyakran mindkettőt igényli, az általunk áttekintett irodalomban azonban nem találtunk olyan munkát, amely a rajzi gráfot és az eszközönkénti adatlapgráfokat egy lekérdezhető modellben kötné össze, és ezt mérné. A következő fejezetekben ezt a hiányzó lépést tesszük meg, kezdve azokkal az adatokkal, amelyeken mérünk.

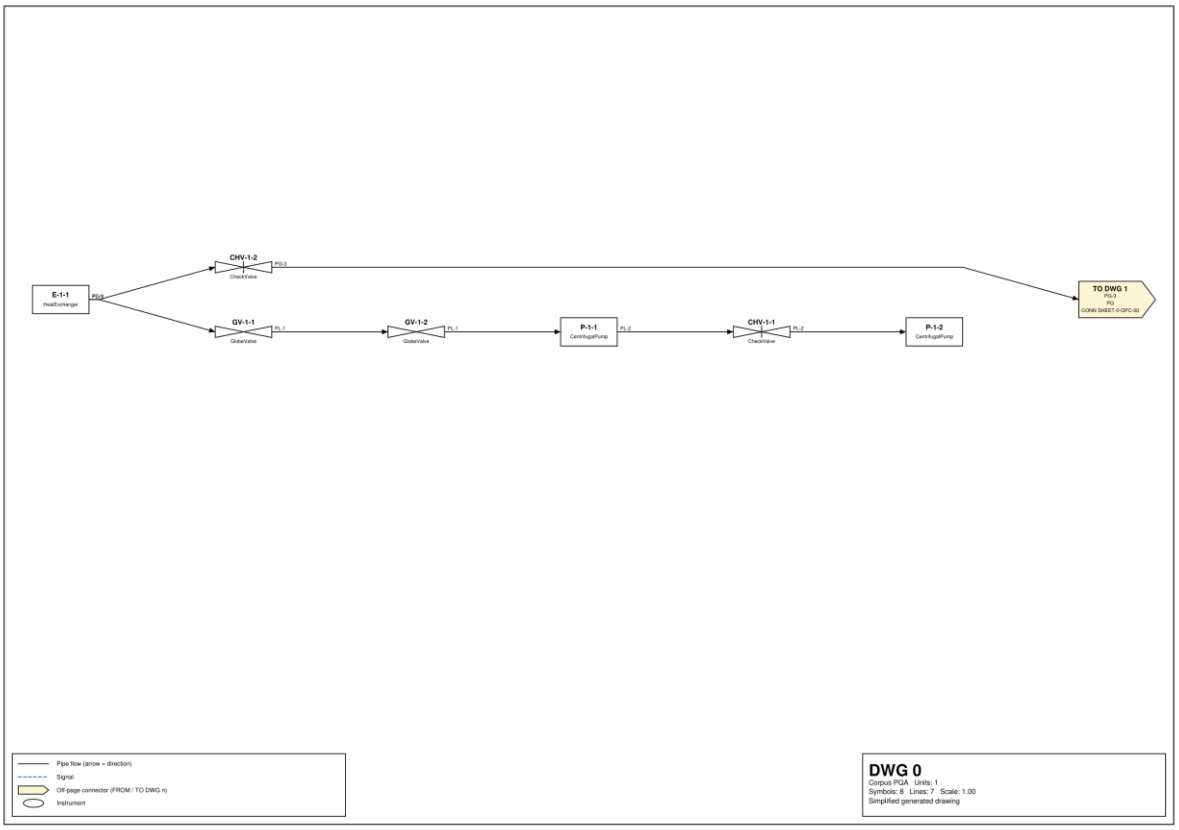
3. Adatok és feladat

Egy összevont tudásgráf értékét csak olyan kérdéseken lehet lemérni, amelyeknek ismert a helyes válasza. Ebben a fejezetben bemutatjuk a mérés tárgyát: a példaüzemek rajzát, a tagelt elemekhez tartozó gyártói adatlapokat, az üzemenként 60 kérdésből álló kérdéssort és azt, hogyan pontozzuk a válaszokat. Az üzemeket három célra használtuk. Az első prototípus egy kis, négylapos üzemen készült; a közös rendszert ezután két fejlesztési üzemen (30 és 50 lap) hangoltuk; végül a hangolt és befagyasztott rendszert két tesztüzemen (100 és 1000 lap) mértük meg, amelyeket a hangolás során nem használtunk.

3.1 A példaüzemek

Mind az öt üzemet a plantgraph generátorának egyszerűbb, első változatával készítettük. A két változat abban különbözik, hogy az első hat berendezésosztállyal (centrifugálszivattyú, kompresszor, tartály, nyomástartó edény, oszlop, hőcserélő) és háromféle szeleppel (globe, golyós, visszacsapó) dolgozik, a berendezéseket véletlen faszerkezetben köti össze, és műszer csak a szabályozókörökben van. A későbbi változat valódi folyamategységek mintáiból építi az üzemet (például oszloprendszer, kompresszorfokozat, tartálypark), a berendezések köré a szokásos kiegészítő elrendezéseket rajzolja (biztonsági szelep, leürítők, légtelenítők), és az elemek között jelöletlen idomok is állnak. Ez valószerűbb rajzot ad, de csak az első változatban lehet a generált berendezésosztályokat azokra szűkíteni, amelyekhez van gyártói adatlapunk, és erre a hozzárendeléshez szükség van.

A generátort nem módosítottuk, csak két ponton szűkítettük a kimenetét. Először csak olyan berendezésosztályokat engedtünk meg, amelyekhez van adatlap (centrifugálszivattyú, hőcserélő). Másodszor a szabályozóköröket szűrtük. A generátor minden köre egy változót szabályoz (áramlást, szintet, nyomást vagy hőmérsékletet), és a kör távadójához adatlap kell; egyetlen távadó-adatlapunk (Rosemount 3051) viszont nyomás- és nyomáskülönbség-távadóé, amely a nyomás és az áramlás mérését lefedi, a szintét és a hőmérsékletét nem. A kis prototípus-üzemhez ezért csak olyan üzemet fogadtunk el, amelynek minden köre áramlás- vagy nyomásszabályozó kör. A seedeket sorban (1, 2, 3, …) kipróbáltuk, és az első olyan üzemet fogadtuk el, amely ezen felül 20–40 tagelt elemet és 2–4 lapot tartalmaz, és amelyben minden adatlaptípus szerepel; ez a 6-os seed volt. Az üzem 26 tagelt elemből és 4 lapból áll, a lapok között 4 lapközi csatlakozópár van, és a lapokból visszaépített üzem hibátlanul egyezett a generálttal.



1. ábra: A kis példaüzem egyik lapja. A jobb szélen a lapközi csatlakozó.

Négy lap egy valódi üzemnél nagyságrendekkel kevesebb, ezért a közös rendszert négy nagyobb üzemen hangoltuk és mértük. A két fejlesztési üzem pontosan 30 és 50, a két tesztüzem pontosan 100 és 1000 lapos. Mind a négyet ugyanazokkal a beállításokkal és ugyanazzal a hét adatlappal generáltuk; az egységek számát (17, 28, 57, illetve 600) úgy választottuk, hogy a lapszám pontosan elérhető legyen, és az elfogadás feltétele a pontos lapszám volt. A nagyobb üzemeknél nem követeltük meg, hogy minden kör áramlás- vagy nyomásszabályozó legyen, mert ennyi körnél szinte minden üzemben van szint- és hőmérséklet-szabályozó kör is, így egyetlen seed sem felelt volna meg. Ehelyett a szint- és hőmérséklet-távadók egyszerűen nem kapnak adatlapot, ahogy egy valódi üzemben sincs minden elem adatlapja kéznél.

2. táblázat: A fejlesztési és a tesztüzemek

Szerep	Lap	Egység	Tagelt elem	Adatlappal	Szabályozófunkció adatlap nélkül	Szint- vagy hőmérséklet-távadó adatlap nélkül
fejlesztési	30	17	206	174	19	13
fejlesztési	50	28	378	324	40	14
teszt	100	57	772	644	87	41
teszt	1000	600	7854	6641	821	392

Elsőre furcsának tűnhet, hogy több ezer rajzi elemhez csak hét adatlap tartozik, de ez nem ellentmondás: egy adatlap egy eszköztípust (egy gyártó katalógusában szereplő modellt) ír

le, és az azonos típusú rajzi elemek ugyanazt az adatlapot kapják. A 30 lapos üzemen például 53 szivattyú kapja ugyanazt a Gorman-Rupp adatlapot, ahogy egy valódi üzemben is ugyanaz a szivattyúmodell sok helyen be van építve. Az üzemek nem létező üzemek rajzai: a generátor szabályokra épül (egységek, berendezések, csővezetékek, szabványos tag-ek, szabályozókörök, lapközi csatlakozók), de a kapcsolások véletlenszerűek, és a technológia nincs méretezve. A rajz tehát véletlenszerű, de belsőleg következetes és teljesen ismert: a generátor minden elemet, kapcsolatot és szabályozókört pontosan ismer. Éppen ezért lehet minden kérdéshez egyértelmű, ellenőrizhető választ számolni; ehhez nem szükséges, hogy a technológia valószerű legyen.

3.2 Adatlapok

A tagelt elemek osztálya és szerepe határozza meg az adatlapot (lásd az alábbi táblázatot); a hozzárendelést program állítja elő a generátor kimenetéből. A szabályozókör által működtetett globe szelep a Fisher ET szabályozószelep, a kör nélküli globe szelep a GF 165 mágnesszelep (kétutas, globe kialakítású nyitó-záró szelep). A szabályozófunkciókhoz (például FIC, PIC) nem rendeltünk adatlapot, mert ezek a folyamatirányító rendszer funkciói, gyártói adatlapjuk nincs.

3. táblázat: Elemosztályok és adatlapok a kis példaüzemben

Elemosztály (szerep)	Tag-ek	Adatlap	Oldal
centrifugálszivattyú	P-1-1 … P-2-3 (8 db)	Gorman-Rupp VGH (0700286)	6
hőcserélő	E-1-1, E-2-1, E-2-2, E-2-3	Alfa Laval M3	2
globe szelep (szabályozókörben)	FV-2-2, PV-2-1	Fisher ET (D100022X012)	36
globe szelep (kör nélkül)	GV-1-1, GV-1-2, GV-2-2	GF Type 165 mágnesszelep	6
golyóscsap	BV-2-1	Flowserve Worcester F51/F52	12
visszacsapó szelep	CHV-1-1 … CHV-2-2 (4 db)	Swagelok MS-01-176	16
távadó	FT-2-2, PT-2-1	Rosemount 3051 (00813-0100-4001)	114

Az adatlapokból a plantdocs feldolgozó folyamata épít tudásgráfot (4. fejezet). A Fisher, a GF 165 és a Gorman-Rupp adatlapjának gráfja a plantdocs-ból származik; a másik négy adatlapot (Rosemount 3051, Alfa Laval M3, Worcester F51/F52, Swagelok MS-01-176) mi dolgoztuk fel ugyanezzel a folyamattal. Az így kapott gráfok mérete 91 202 (Rosemount 3051), 1102 (Alfa Laval M3), 16 281 (Worcester F51/F52) és 66 747 (Swagelok MS-01-176) hármas.

3.3 A kérdéssor

Minden üzemhez egy 60 kérdésből álló, négy családra bontott kérdéssor tartozik (lásd az alábbi táblázatot). Az (a) család csak a rajzról kérdez, a (b) csak egy adatlapról (a tag megnevezésével), a (c) a kettőt köti össze, a (d) pedig olyan kérdéseket tartalmaz, amelyekre a dokumentumok nem adnak választ, és ezért a helyes válasz annak kimondása,

hogy nincs benne. A kis üzemen családonként 5 kérdés a fejlesztési, 10 a teszthalmazba került; a teszthalmazt az első prototípus fejlesztése előtt rögzítettük, és csak a végső mérésnél futtattuk. A fejlesztési és a tesztüzemek kérdéssorát ugyanaz a program, ugyanazzal a seeddel állította elő; a fejlesztési üzemek kérdéseit a hangoláshoz használtuk, a tesztüzemekét a hangolás alatt nem futtattuk, ott mind a 60 kérdés tesztkérdés. Minden üzemhez tartozik továbbá 12 olyan kérdés is, amelyhez a rajzon több elemet kell bejárni, és több adatlapot kell összevetni (az (e) család); ezeket külön értékeljük.

4. táblázat: A kérdéscsaládok

Család	Mit kérdez	Referenciaválasz forrása	Fejlesztési / teszt (kis üzem)
(a) csak rajz	kapcsolat, áramlási út, felső források, műszerek, típus, egység, lapok	program számolja a generált üzem pontos leírásából	5 / 10
(b) csak adatlap, tag-en át	„Regarding P-1-3 on the P&ID: …”	a plantdocs kérdés–válasz párjai	5 / 10
(c) összetett	egy topológiai lépés és egy adatlapi tény	program rakja össze az (a) és a (b) referenciáiból	5 / 10
(d) megválaszolhatatlan	nem létező tag, a dokumentumban nem szereplő tény	a generátor, illetve a plantdocs „nincs benne” párjai	5 / 10

Az összetett kérdések topológiai lépését a generált üzem pontos leírásából program számolja. Csak egyértelmű lépés marad (például „a P-1-1 előtt közvetlenül álló elem”, „az E-2-1-et mérő távadó”, „a PIC-2-1 kör által működtetett szelep”), és csak olyan, amelynek cél-eleméhez van referenciaválasszal ellátott adatlapi kérdés; a kérdés szövege a lépés és az adatlapi kérdés összefűzése. A rajzi kérdések referenciáját tehát program számolja, az adatlapi kérdésekét egy nyelvi modell írta az adatlap PDF-jéből, és ezeket ember nem ellenőrizte; ezt a korlátot a 8. fejezetben tárgyaljuk.

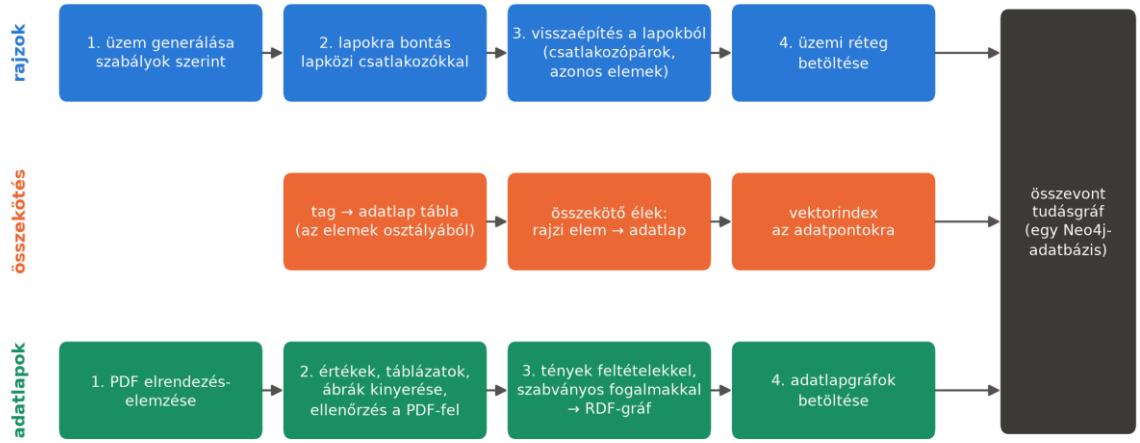
3.4 Pontozás

Ahol a válasz programmal ellenőrizhető, programmal pontozunk. A rajzi és a rajzra vonatkozó megválaszolhatatlan kérdések válaszát egy program a válasz típusa szerint veti össze a referenciával: egy tag-halmaznak halmazként pontosan egyeznie kell, egy útnak ugyanazokat az elemeket kell tartalmaznia ugyanabban a sorrendben, egy számnak és egy igen/nem válasznak egyeznie kell, a megválaszolhatatlan kérdésekre pedig a „nincs benne” a helyes válasz. A szabad szöveges kérdéseknél a válasz programmal helyes, ha a referencia minden kötelező eleme számot tartalmaz, és minden szám a mértékegységével együtt megjelenik a válaszban.

A többi választ egy vak bíróként működő nyelvi modell pontozza, rögzített utasítással. A bíró csak a kérdést, a referenciát és a jelölt választ látja, kevert sorrendben, és nem tudja, melyik módszer és melyik modell adta a választ. Négy ítélet lehetséges: helyes, részben helyes, rossz és hallucinált (a válasz olyan tényt állít, amely nincs benne a dokumentumokban). Pontosságnak a helyes válaszok arányát tekintjük. Ezzel a mérés tárgya rögzített; a következő fejezet azt mutatja be, hogyan épül fel az a gráf, amelyen a kérdésekre válaszolunk.

4. Az összevont tudásgráf

Az előző fejezetben leírt kérdések egy része csak úgy válaszolható meg, ha a rajz és az adatlap egyszerre elérhető. Ebben a fejezetben bemutatjuk, hogyan épül fel az a tudásgráf, amely mindkettőt tartalmazza. A két forrásrendszer két külön gráfot épít: a plantgraph a rajzokból egy üzemi réteget, a plantdocs az adatlapokból eszközönként egy-egy adatlapgráfot. Az összevonás célja, hogy a kettő egyetlen adatbázisba kerüljön, és egyetlen lekérdezés mindkettőt elérje. A folyamat három ágát az alábbi ábra foglalja össze: a felső ág a rajzokból, az alsó az adatlapokból épít gráfot, a középső ág pedig összeköti a kettőt. A három ág kimenete ugyanabba a Neo4j-adatbázisba kerül. A fejezetben sorra vesszük a három ágat; a két forrásfolyamat részletes leírása a Függelék D-ben található.



2. ábra: A tudásgráf felépítése. Felül a rajzi, alul az adatlapi folyamat, középen a kettő összekötése; mindhárom ág ugyanabba az adatbázisba tölt.

4.1 A rajzi réteg

A rajzi ág négy lépésből áll. Először a generátor szabályok szerint felépít egy teljes üzemet: egységeket, bennük berendezéseket, a köztük futó csővezetékeket a szelepekkel, és a berendezésekhez tartozó szabályozóköröket. Másodszor egy lapokra bontó program az üzemet rajzlapokra vágja, és minden elvágott csőre lapközi csatlakozópárt illeszt, ahogy egy valódi rajzon is történik; azt, hogy melyik csatlakozó melyikkel alkot párt, külön megoldókulcsba írja, amely a vizsgált adatbázisba nem kerül be. Harmadszor egy visszaépítő program csak a lapokból, a megoldókulcs nélkül állítja vissza az üzemet: a csatlakozókat a feliratuk kölcsönös hivatkozása alapján párosítja, a több lapon felrajzolt elemeket a tag-jük és az osztályuk alapján egy elemmé vonja össze, és bizonytalan esetben nem találgat. Mivel a bontást a rendszer maga végezte, a visszaépítés eredménye a megoldókulccsal összevethető; a prototípus-üzemen hibátlan volt. Negyedszer a visszaépített üzem bekerül az adatbázisba.

Az adatbázisban minden rajzi elem pontosan egy csúcs lesz, akkor is, ha több lapon is szerepel. A csúcs több szinten is hordozza az elem típusát: egy centrifugálszivattyú egyben szivattyú és berendezés is, így egy lekérdezés bármelyik szinten rákereshet. Az elemek

közötti csöveket az áramlás irányába mutató élek írják le, és ha egy cső átlépi a laphatárt, az is egyetlen él, amely ezt a tényt megjegyzi. A jelvezetékeknek, a mérésnek (melyik távadó melyik elemet méri) és a beavatkozásnak (melyik szabályozó melyik szelepet működteti) külön éltípusa van, és minden elem kapcsolatban áll azzal a lappal, amelyen szerepel, és azzal az egységgel, amelyhez tartozik.

Erre épül a vonalnézet: egy rövidítő él, amely két berendezést vagy szelepet közvetlenül köt össze, és átugorja a köztük lévő kisebb csőidomokat. Így az olyan kérdés, mint „mi a szivattyú utáni következő szelep?”, egyetlen lépésben megválaszolható, a csövenkénti élek pedig a részletes nézethez megmaradnak. A vonalnézet a generátor valósághűbb változatához készült, ahol sok jelöletlen idom áll az elemek között; a mi üzemeinkben ilyen idom nincs, de a kaszkád lekérdezési szabályai erre a nézetre épülnek, ezért ezt használjuk. A kis prototípus-üzem rajzi rétege 36 csúcsból és 116 élből áll.

4.2 Az adatlapi réteg

Az adatlapi ágban a plantdocs egy gyártói adatlap PDF-jéből tíz számozott lépésben állítja elő az adatlapgráfot. Az ábra négy dobozában ezek a lépések csoportosítva szerepelnek: az első doboz az 1. lépés, a második a 2–5., a harmadik a 6–10. lépés, a negyedik a betöltés.

1. elrendezés-elemzés az Azure Document Intelligence szolgáltatással (bekezdések, táblázatok, ábrák);
2. rekordok: egy nyelvi modell a táblázatokból paraméter–érték–egység rekordokat ír, a táblázatbeli helyükkel együtt;
3. ábrák: kivágás, osztályozás és a rajzokon lévő jelek feloldása;
4. diagramok leolvasása;
5. ellenőrzés: minden rekord számának megkeresése a PDF szövegében;
6. célformátum: a rekordokból tények és a hozzájuk tartozó feltételek;
7. lábjegyzetek: az ábrákhoz tartozó lábjegyzetek bekötése;
8. forrásleírások: minden forrásról (táblázatról, ábráról, szövegrészről) rövid leírás;
9. szókészlet-illesztés: a tulajdonságokhoz és feltételekhez szabványos fogalmak rendelése;
10. az RDF-gráf előállítása.

A lépések felváltva programok és nyelvi modellek. Egy nyelvimodell-lépés kimenete csak akkor mehet tovább, ha átmegy egy programmal ellenőrzött formai és tartalmi feltételrendszeren; az általunk feldolgozott négy adatlapon minden ilyen kimenet elsőre átment. A folyamat legfontosabb elve, hogy egy rekord egy tény, nem egy nyomtatott cella, és a tény feltételei önálló elemek. A gráf a 2. fejezetben bemutatott ISO 15926 vonalat követi: az alapfogalmakat az IDO, az eszköz- és tulajdonságosztályokat a POSC Caesar könyvtára, a mértékegységeket a QUDT adja, és saját, kézzel írt szókészlet nem lehet benne.

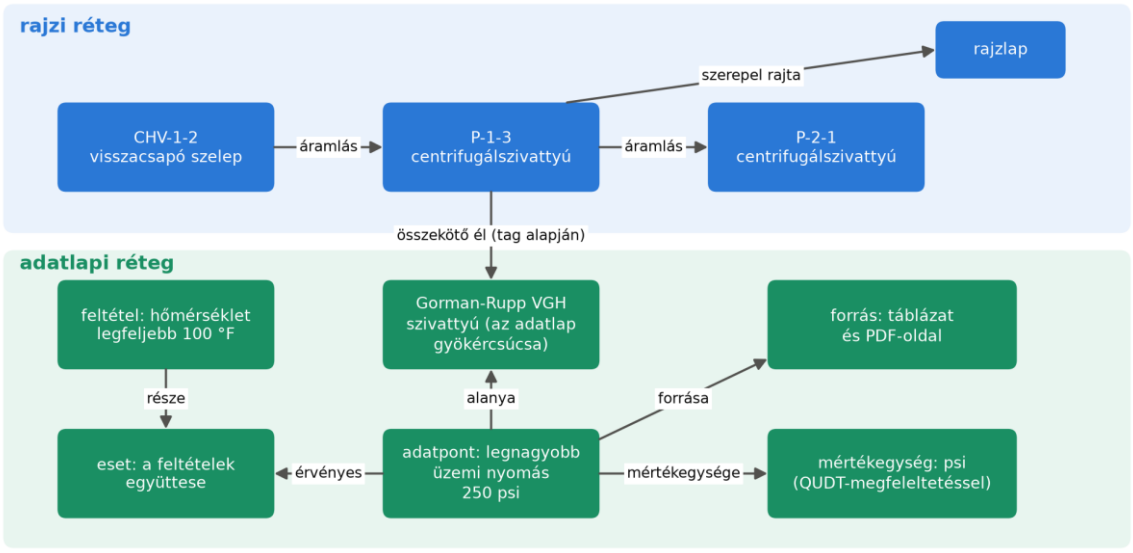
Hogy ez a gyakorlatban mit jelent, azt a második ábra alsó fele mutatja. Az adatlap gyökércsúcsa maga az eszköz (itt a Gorman-Rupp VGH szivattyú). Egy mennyiségi tény egy adatpont-csúcs, amely a nyomtatott címkét és értéket hordozza, és élekkel mutat az alanyára (az eszközre vagy egy alkatrészére), a mértékegységére és a forrására, vagyis arra a táblázatra, ábrára vagy szövegrészre, ahonnan származik, az oldalszámmal együtt. A feltételek együttese egy külön esetcsúcs: a tény erre az esetre mutat, és minden egyes

feltétel (például „a hőmérséklet legfeljebb 100 °F”) maga is adatpont, amely ugyanerre az esetre mutat. A lábjegyzet szintén külön adatpont. Ez a szerkezet őrzi meg, hogy egy érték milyen feltétel mellett és melyik oldalon érvényes; a példában a 250 psi-s legnagyobb üzemi nyomás csak 100 °F-ig érvényes, és a gráfból ez a feltétel is kiolvasható.

Az adatlapgráfokat egy bővítmény tölti be a Neo4j-be, amely az RDF-hármasokat csúcsokká és élekké alakítja. A hét eszközgráf együtt 27 615 csúcsból és 103 366 élből áll; ehhez jön 221 közös szókészlet-csúcs (mértékegységek, eszközosztályok, szabványos tulajdonságok), amelyeken az adatlapok osztoznak.

4.3 Az összekötés

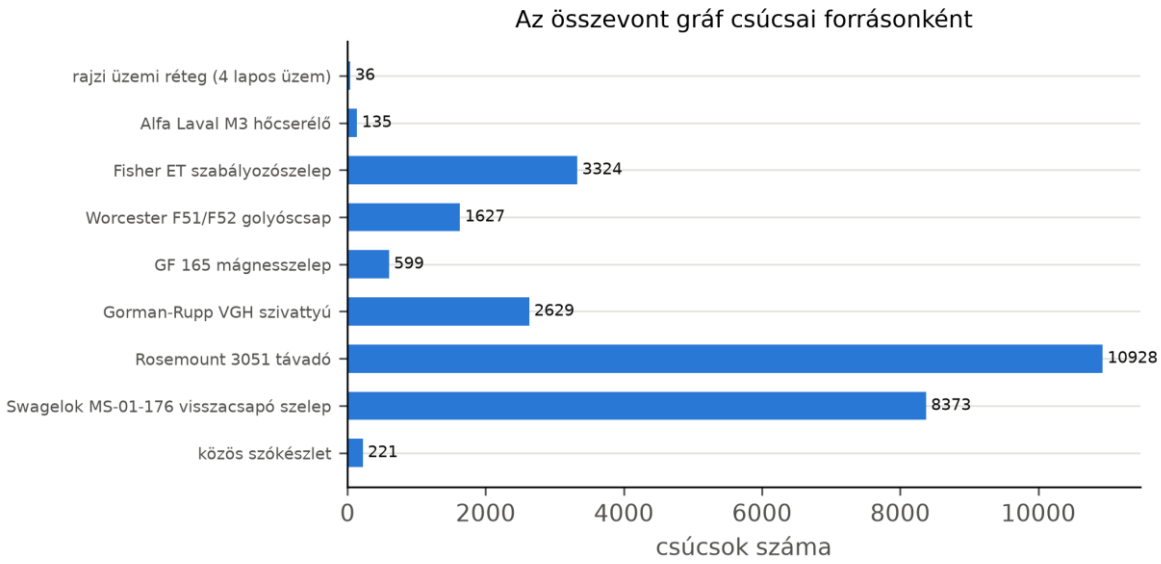
A középső ág köti össze a két réteget. Első lépése egy tábla, amely minden tagelt rajzi elemhez megadja az adatlapját. Ezt a táblát program állítja elő a generátor kimenetéből, az elem osztálya és szerepe alapján (3. fejezet); valódi üzemben ez az eszközlista vagy az átadási adatbázis dolga volna. A tábla alapján minden adatlappal rendelkező rajzi elemtől egy összekötő él fut az adatlapgráf gyökércsúcsához. A kis üzem 26 tagelt eleméből 24-nek van adatlapja, ennyi összekötő él jön létre. Több tag mutathat ugyanarra az adatlapgráfra: a nyolc szivattyú mind a Gorman-Rupp adatlapot kapja, mert ugyanaz a típus. Az adatlapok csúcsai nem keverednek össze, mert minden csúcs azonosítója a dokumentum azonosítójával kezdődik, és minden csúcs külön tulajdonságként is hordozza a dokumentumazonosítót, így egy lekérdezés egyetlen adatlapra szűkíthető. Az utolsó lépés egy vektorindex az adatlapi adatpontokra, amely a jelentés szerinti kereséshez kell: minden adatpont szövegéhez egy beágyazásvektor készül, és a kérdéshez legközelebbi vektorok gyorsan megkereshetők.



3. ábra: Az összevont gráf szerkezete egy példán. Felül a rajzi réteg (két áramlási él és a lap), középen az összekötő él, alul a szivattyú adatlapgráfjának egy adatpontja a feltételével, mértékegységével és forrásával.

Az ábra azt is megmutatja, hogyan válaszolható meg így egy összetett kérdés egyetlen bejárással. A „mekkora a CHV-1-2 szelep utáni szivattyú legnagyobb üzemi nyomása?”

kérdéshez a rajzi rétegben a CHV-1-2-től az áramlás irányában egy lépést teszünk, és megtaláljuk a P-1-3 szivattyút; az összekötő élen átlépünk az adatlapjára; ott kiolvassuk az adatpontot a feltételével és a forrásoldalával együtt. Nincs szükség arra, hogy a rajzi és az adatlapi rendszer szövegesen adja át egymásnak az eredményt.



4. ábra: Az összevont gráf csúcsai forrásonként a négylapos prototípus-üzemen.

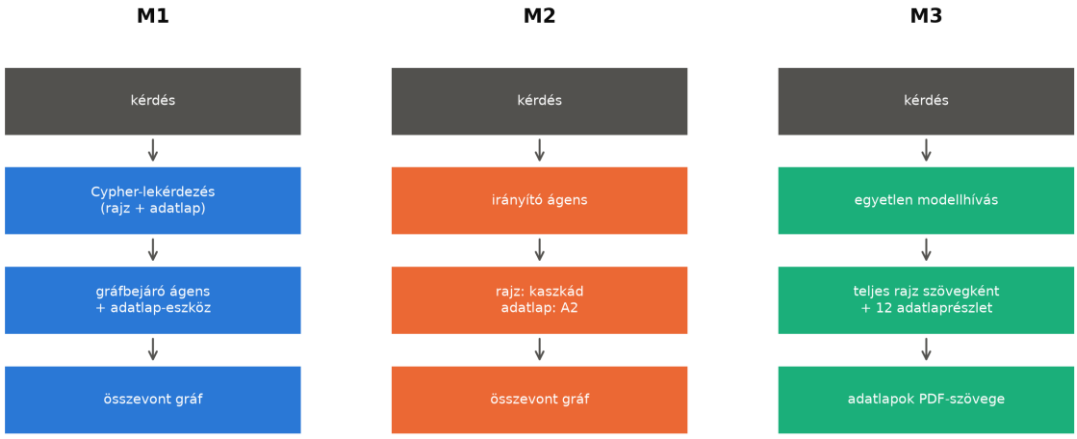
A fenti oszlopdiagram a prototípus-üzem összevont gráfjának összetételét mutatja. Minden oszlop azt adja meg, hány csúcs származik az adott forrásból: az első a rajzból épített üzemi réteg 36 csúcsa, a következő hét egy-egy adatlap gráfja, az utolsó a közös szókészlet. Az adatlapgráfok mérete az adatlap terjedelmét követi: a 114 oldalas Rosemount 3051 adatlapból 10 928, a kétoldalas Alfa Laval M3-ból 135 csúcs lesz. Az adatlapi réteg tehát a kis üzemen nagyságrendekkel nagyobb a rajzinál, és mérete nem függ az üzemtől; a nagyobb üzemeken csak a rajzi réteg és az összekötő élek száma nő (6. fejezet).

Az összekötés módját több lehetőség közül választottuk. A legegyszerűbb az lett volna, ha az adatlapi tényeket tulajdonságként a rajzi csúcsra másoljuk; ez azonban éppen a feltételeket, a lábjegyzeteket és az oldalszámot veszítené el, amelyekért az adatlapgráf készült. Két külön adatbázis között egy lekérdezés nem járhat át, az egész gráf RDF-formában pedig a Neo4j-re írt kaszkád átírását igényelte volna. A tag alapján húzott él a legkisebb beavatkozás: egyik réteg szerkezete sem változik, és a kapcsolat a gyakorlatot követi, ahol a tag köti össze a rajzot a többi dokumentummal. Az így kapott gráf a kiindulópont; a következő fejezet azt mutatja be, hogyan válaszol rajta a három kérdés-válaszoló módszer.

5. Kérdés-megválaszolási módszerek

Az összevont gráf önmagában még nem válaszol: kell egy módszer, amely a kérdésből lekérdezést, abból pedig választ készít. Ebben a fejezetben három ilyen módszert mutatunk be. Az M1 közvetlenül az összevont gráfot használja, az M2 a két meglévő rendszert külön hívja, és egy irányító köti össze az eredményüket, az M3 pedig gráf nélküli alapmódszer, amely azt mutatja meg, mennyit ad hozzá a gráf. A három módszer a két meglévő rendszerre épül, azokat nem módosítja.

Mindhárom módszer ugyanazt kapja: a kérdés szövegét és az elvárt válaszalakot. A válaszalak lehet szabad szöveg, egy tag vagy tag-ek halmaza, egy rendezett út, igen/nem válasz, darabszám, egy egység neve vagy egy osztálynév; az alakot egy rögzített mondat írja le, amelyet mindhárom módszer szó szerint ugyanígy lát. A válasz mindhárom esetben ugyanolyan szerkezetű: maga a válasz és egy jelző, amely azt mondja meg, hogy a dokumentumok nem tartalmazzák a választ. Mindhárom módszert két nyelvi modellel mérjük, a GLM-5.3 Flash és a GPT-6 Luna modellel, a rajzoldali rendszerben rögzített beállításokkal. A fejezetben előbb a közös építőelemeket, majd a három módszert, végül a fejlesztési üzemeken végzett hangolást írjuk le.



5. ábra: A három módszer felépítése. Bal: M1 (egy összevont gráf); közép: M2 (irányító a két rendszer fölött); jobb: M3 (gráf nélküli alapmódszer).

5.1 Közös építőelemek

A rajzoldali kaszkád

A kaszkád két szintből áll, és a pontosságot helyezi előtérbe. Az első szinten egy nyelvi modell egyetlen Cypher-lekérdezést ír a rajzi rétegre. A prompt leírja a gráf szerkezetét (a csúcsok fajtáit, az éleket és a tulajdonságokat), tartalmaz egy rövid, általános bevezetőt a P&ID-k olvasásához, és néhány lekérdezési szabályt: korlátlan hosszúságú utat nem szabad keresni, egy halmazhoz különböző végpontokat kell kérni, egy útvonalhoz a legrövidebb utat, egy elérhetőséghez pedig a vonalnézet mentén kell vizsgálni, létezik-e út. A lekérdezés csak olvashat, 30 másodperces időkorláttal és legfeljebb 1000 sorral fut. Ha hibát ad, a modell megkapja az adatbázis hibaüzenetét, és egyszer újraírhatja; egy program emellett

azt is ellenőrzi, hogy a kérdésben szereplő tag-ek léteznek-e. A kapott sorokból egy közös válaszlépés fogalmazza meg a választ.

A kaszkád akkor fogadja el az első szint válaszát, ha minden önjelzés rendben van: a lépés válaszolt, érdemben felelt (nem azt mondta, hogy nincs benne), a lekérdezés adott sort, és az eredmény nem csonka, vagyis nem érte el a sorkorlátot. Egyik jelhez sem kell ismerni a helyes választ, ezért a szabály a teszten is alkalmazható, és nincs a mért adatra illesztett paramétere. Ha bármelyik jel hiányzik, a kérdés a második szintre kerül.

A második szinten egy ágens lépésenként, legfeljebb 40 lépésben gráfműveleteket hív. Minden lépésben egy rögzített formájú utasítást ír (egy művelet hívását a paramétereivel, vagy a munka befejezését), és a művelet eredményét szövegként kapja vissza. A végén ugyanaz a közös válaszlépés fogalmaz az összegyűjtött eredményekből, amely az első szint válaszát is írja. A válaszlépés szabályai szerint egy berendezés- és szeleplistában csak ezek szerepelhetnek, a kiinduló elem nem kerül a listába, és ha egy kérdezett tag nem létezik, a válasz „nincs benne”.

A kaszkád egyetlen kivételt tesz: a felfelé vagy lefelé eső első szelepet kérdező kérdések rögtön az ágensnél indulnak. Az ilyen kérdésekre írt lekérdezések ugyanis jellemzően az összes szelepet kérik az első helyett, és ha gyorsan lefutnak, a kaszkád ezt a rossz, de nem üres eredményt elfogadná. A lekérdezést író lépés és a válaszlépés alacsony, az ágens magas gondolkodási szinttel fut.

Az ágens gráfműveletei

Az ágens hat általános gráfműveletet használhat, amelyek egymással kombinálhatók: a szűrőnek megfelelő elemek keresését, egy elem szomszédainak lekérdezését, a bejárást egy kiinduló elemtől, az utat két elem között, egy korábbi eredmény szűkítését és egy korábbi eredmény összesítését. A műveletek a rajzi réteggel egyező gráfon futnak, ezért az ágens nem látja a laphatárokat, csak az üzemet. Minden eredmény hivatkozást kap, így egy korábbi lépés eredménye a következő lépés bemenete lehet: az ágens például előbb megkeresi egy szivattyú szomszédait, majd ezek közül kiszűri a szelepeket. A tervezési döntés lényege, hogy a műveletek száma a gráf szerkezetéből következik, nem a kérdéstípusokból: egy új kérdéstípushoz nem új művelet kell, hanem a meglévők új kombinációja (részletesen: Függelék E).

Az adatlapoldali A2

Az A2 egy eszköz egy kérdésére a következőképpen válaszol. A modell megkapja az adatlapgráf szerkezetének leírását, az eszköz gráfjának tartalomjegyzékét és a forrásszakaszok (táblázatok, ábrák, szövegrészek) katalógusát. Ebből egyetlen, csak olvasó, széles keresésű Cypher-lekérdezést ír, és legfeljebb három forrásszakaszt választ, amelyeknek minden sora a lekérdezés eredménye mellé kerül; hibás, üres vagy túl sok sort adó lekérdezésnél egy javítókör következik. Ezzel párhuzamosan a kérdés jelentéséhez legközelebbi 30 adatpont is előkerül a vektorindexből. A válaszíró csak a megtalált tényekből fogalmaz: a közvetlen válasz után az értékeket az egységükkel, a feltételeikkel és oldalhivatkozással adja meg, új tényt, értéket vagy eljárást nem tehet hozzá (részletesen: Függelék E).

Az A2-t eredetileg egyetlen adatlap gráfjára tervezték, az összevont gráfban viszont hét eszköz gráfja van egyszerre. Ezért a plantdocs módosítása nélkül három illesztésre volt szükség. A tartalomjegyzék elé egy sor kerül, amely megnevezi a kérdezett dokumentumot, és előírja, hogy minden csúcsot a dokumentumazonosító szerint kell szűkíteni. A lekérdezést futtató program csak olyan lekérdezést enged, amely a dokumentum azonosítóját tartalmazza, és semmilyen írást nem enged. A vektoros keresés pedig egy nagyobb jelöltkészletből csak a kérdezett dokumentum csúcsait tartja meg. A másik lehetőség az lett volna, hogy kérdésenként újratöltjük az adatbázist a kérdezett eszköz gráfjával; ez azonban az összevont gráfot tönkretenné, és értelmetlenné tenné az egész összevonást.

5.2 M1: egy gráf, egy lekérdezés

Az M1 a kaszkád az összevont gráfon, két kiegészítéssel. Az első, hogy a lekérdezést író lépés a rajzi réteg mellett az adatlapi réteg leírását is megkapja: az összekötő élt, az A2 gráfleírását és lekérdezési szabályait, valamint azt, hogy melyik tag melyik dokumentumhoz tartozik. Így egyetlen lekérdezés követheti a rajzot, és olvashatja az adatlapot; például a P-1-3 szivattyútól az összekötő élen át eljut az adatlapjához, és ott a kérdés szavaira (például „casing pressure”) szűrve visszaadja az adatpontok címkéjét, értékét és oldalszámát. A kiegészítés elejét a Függelék C mutatja.

A második kiegészítés, hogy az ágens egy hetedik műveletet kap, az adatlap-eszközt. Ez egy tag-ből megkeresi a hozzá tartozó adatlapot, és az A2-vel megválaszoltat róla egy kérdést; az eredmény a dokumentum azonosítóját, az első forrásoldalakat és az A2 válaszát tartalmazza. Az ágens ezt a műveletet ugyanúgy látja és hívja, mint a többi hatot. Ha egy tag-hez nincs adatlap, a művelet nem hibát jelez, hanem szövegesen közli ezt, így az ágens folytathatja a munkát. A művelet leírása arra kéri az ágenst, hogy a rajzon nem látható tulajdonságokhoz ezt használja, és előbb a rajzon keresse meg a tag-et.

Az M1 útvonala a lefutott szintekből és az adatlapi hívásokból áll: egy kérdés vagy már az első szinten lezárul, vagy az ágenshez kerül, amely szükség szerint egy vagy több adatlapot is megkérdez. A válaszlépés a kaszkád változatlan válaszlépése; az M2-ben és az M3-ban bevezetett válaszszabályt (lásd alább) ezért az M1 nem kapta meg.

5.3 M2: irányító a két rendszer fölött

Az M2 egy irányító ágens két eszközzel: a rajzeszköz a változatlan kaszkádot kérdezi a rajzról, az adatlap-eszköz pedig egy tag-hez tartozó eszköz adatlapját az A2-vel. Az irányító minden lépésben pontosan egy utasítást ír (rajzeszköz-hívás, adatlap-hívás vagy végső válasz a „nincs benne” jelzővel), a program végrehajtja a hívást, és az eredményt visszaadja. Legfeljebb 16 lépése van, és ha ez a keret elfogy, egy utolsó hívásban köteles végső választ adni a már összegyűjtött eredményekből. Ha a kérdés egy elemet a helyével vagy a szerepével nevez meg (például „a P-1-1 utáni szelep”), az irányító előbb a rajzeszköztől kérdezi meg a tag-et, és csak utána az adatlapot. Alacsony gondolkodási szinttel fut; a rendszerüzenetét a Függelék B közli.

Az M2 és az M3 egy közös válaszszabályt is kap: ha a dokumentumok a kérdésnek csak egy részére adnak választ, a módszer ezt a részt adja meg, és megnevezi a hiányzó részt; a „nincs benne” jelzőt csak akkor állítja, ha semmi releváns nincs; tanácsot, eljárást, okot vagy értéket, amelyet a dokumentumok nem mondanak ki, nem tehet hozzá. A szabály bevezetése után az M2 és az M3 hallucinációi eltűntek (Függelék G).

Az M2-ben mindkét rendszer abban a beállításban fut, amelyre hangolták, és a két rendszer egymásról nem tud; az összekötést az irányító végzi a kérdés szövegének értelmezésével. Ennek két következménye van. A rajzeszköz szabad szöveges kérdést kap, a kérdéscsalád megjelölését nem, ezért a kaszkád az „első szelep” kérdéseket is az első szinten kezdi, és a válasz alakja eltérhet attól, amit az eredeti kérdés kért; ezt a hibát a 6. fejezetben egy szabályozókörös kérdésen látjuk is. A másik következmény, hogy egy összetett kérdés legalább két egymás utáni eszközhívást igényel, amelyek mindegyike maga is több modellhívás, ezért a válaszidő nagyobb.

5.4 M3: gráf nélküli alapmódszer

Az M3-ban nincs gráf. A modell egyetlen promptban megkapja a teljes rajzot szövegként, a ChatP&ID ContextRAG-módszerének megfelelően, és a hét adatlap PDF-szövegéből a kérdéshez jelentés szerint legközelebbi 12 részletet, ugyanazzal a beágyazómodellel (Qwen3-Embedding-8B, 512 dimenzió), amelyet az A2 is használ. A válasz egyetlen hívás, magas gondolkodási szinttel.

A szövegként leírt rajz lapról lapra minden szimbólumot felsorol a tag-jével és az osztályával, megadja a köztük futó csöveket és jelvezetékeket, és a lapokat a lapközi csatlakozókon át köti össze. Az M3 modelljének tehát magának kell követnie a csatlakozókat a laphatáron át; az összevont rajzi réteget nem látja. Az adatlaprészletek a PDF-ek szövegéből készülnek oldalanként, bekezdéshatáron vágva, és mindegyik hordozza a dokumentum azonosítóját és az oldalszámot. A prompt azt is megadja, melyik tag-hez melyik adatlap tartozik.

Az alapmódszert szándékosan erősnek választottuk: a négylapos prototípus-üzem rajza elfér a promptban, és a ChatP&ID mérése szerint egyetlen lapon éppen ez a módszer nyert [12]. Ha az M3 felveszi a versenyt a gráfos módszerekkel, az arra utal, hogy az adott méreten a gráf előnye legfeljebb a feltételek megőrzésében jelentkezhet.

5.5 Hangolás a fejlesztési üzemeken

Az első prototípust a négylapos üzemen fejlesztettük (Függelék G). A 30 és 50 lapos fejlesztési üzemen három változtatásra volt szükség; az M3-at nem hangoltuk. Az M2 lépéskerete 6-ról 16-ra nőtt, és bekerült a kötelező végső válasz, mert a 30 lapos üzemen a 24 több adatlapos válaszból 10 azért maradt üres, mert az irányító elérte a lépéskorlátot. Az M1 lekérdezési szabályai egy újjal bővültek, mert sok válasza csak részleges volt: az adatlapi tényeket tágan kell szűrni, és minden értéket a feltételével és az oldalszámával együtt kell visszaadni. Végül a kaszkád kérdésenkénti időkorlátja 120 másodpercről 240 másodpercre nőtt, mert egy kérdés túllépte a korábbit. A hangolás után a módszereket befagyasztottuk, és a tesztüzemeken már nem változtattunk rajtuk.

5.6 Költség és mérés

Minden modellhívás egy közös, naplózott rétegen megy át, amely a válaszokat el is tárolja, így egy ismételt futás nem fizet újra. A teljes projekt kerete 25 USD volt, és 23 USD felett új mérés nem indulhatott. Kérdésenként mérjük a felhasznált tokeneket, a szolgáltató által jelentett költséget (eltárolt válasznál az eredeti hívás árát), a válaszidőt és az útvonalat, vagyis azt, hogy melyik szint vagy eszköz kellett a válaszhoz. A következő fejezet ezeknek a méréseknek az eredményét mutatja be.

6. Kiértékelés

Az előző két fejezetben felépített gráfot és módszereket most a 3. fejezetben leírt kérdéseken mérjük meg. A fejezet a kutatási kérdések sorrendjét követi: előbb azt mutatjuk be, hogy az összevont gráf a nagy üzemeken is felépíthető, majd azt, hogyan teljesítenek rajta a módszerek a két tesztüzemen, végül azt, hogyan változik a pontosság és a költség az üzem méretével, és milyen hibák jellemzők az egyes módszerekre.

6.1 Beállítás

Mindhárom módszert mindkét modellel futtattuk: a GLM-5.3 Flash (a továbbiakban GLM) és a GPT-6 Luna (a továbbiakban Luna) modellt az OpenRouter szolgáltatón át értük el, a rajzoldali rendszer rögzített beállításaival. A pontosság a helyes válaszok aránya. A konfidenciaintervallumokat bootstrap-módszerrel számoltuk: a kérdéseket 10 000-szer újramintavételeztük visszatevéssel, és az így kapott pontosságok középső 95%-a adja az intervallumot. Két módszer különbségét ugyanazokon a kérdéseken, párosítva számoltuk; ha a különbség intervalluma tartalmazza a nullát, a különbség nem szignifikáns. A teljes projekt fizetős költése 18,8923 USD volt; ebből a fejlesztési üzemek mérése és a hangolás az 50 lapos üzemen 1,2599 USD, a két tesztüzem mérése 2,8544 USD.

Az összevont gráf a nagy üzemeken is gond nélkül felépült. Mérete az üzemmel nő, az adatlapi réteg változatlan (27 615 csúcs, 103 366 él): a 30 lapos üzemen 274 rajzi csúcs, 931 rajzi él és 174 összekötő él jött létre, az 50 lapos üzemen 498, 1713 és 324, a 100 lapos üzemen 1018, 3515 és 644, az 1000 lapos üzemen 10 277, 35 603 és 6641. Az 1000 lapos üzem betöltése 80,7 másodpercig tartott.

6.2 Az első prototípus a kis üzemen

A kis üzem 20 kérdéses fejlesztési halmazán négy iterációban alakítottuk ki a módszerek első változatát; a 40 kérdéses teszthalmazon a legjobb az M2 volt GLM-mel (31 helyes), a gráf nélküli M3 30, az M1 25 helyes választ adott. A részleteket a Függelék G írja le.

6.3 Hangolás a fejlesztési üzemeken

A prototípus módszereit a 30 és az 50 lapos fejlesztési üzem mind a 60 kérdésén és 12 több adatlapos kérdésén futtattuk. Az alábbi táblázat a hangolás előtti eredményt mutatja; a gráf nélküli M3-at nem hangoltuk, ezért csak a 30 lapos üzemen futott.

5. táblázat: A fejlesztési üzemek eredménye a hangolás előtt (helyes válaszok, 60 kérdés; (e): 12 kérdés)

Módszer	Modell	30 lap	50 lap	(e), 30 lap	(e), 50 lap
M1	GLM-5.3 Flash	45	47	2	3
M2	GLM-5.3 Flash	50	52	3	5
M3	GLM-5.3 Flash	41	–	0	–
M1	GPT-6 Luna	49	44	2	0
M2	GPT-6 Luna	46	43	2	4
M3	GPT-6 Luna	38	–	0	–

A hibák elemzése az 5. fejezetben leírt három javítást hozta. Az M2 a több adatlapos kérdéseknél minden elem adatlapját külön lekérdezi, és a hatlépéses keret a 30 lapos üzemen a 24 ilyen válaszból 10-et, az 50 lapos üzemen 8-at üresen hagyott; ezért nőtt a keret 16 lépésre, és került be a kötelező végső válasz. Az M1 hibáinak nagy része hiányos feltételű részválasz volt, ezért bővültek a lekérdezési szabályai, és egy sok adatlap-hívást igénylő kérdés miatt nőtt a kaszkád időkorlátja. A javítást az 50 lapos üzem több adatlapos kérdésein ellenőriztük: az M2 üres válaszai modellenként 4-ről 2-re csökkentek, a teljesen helyes válaszok száma az M2-nél GLM-mel 5-ről 6-ra nőtt, Lunával 4 maradt, az M1-nél GLM-mel 3 maradt, Lunával 0-ról 2-re nőtt. Ezután a módszereket befagyasztottuk.

6.4 A gráf nélküli módszer az 1000 lapos üzemen

Az M3 a teljes rajzot szövegként kapja meg a promptban. Ez a szöveg a 100 lapos üzemen 474 716, az 1000 lapos üzemen 4 793 987 karakter. Egy korábbi, 98 lapos próbaüzemen végzett mérésben egy ekkora rajz kérdésenként átlagosan kb. 194 ezer prompttokent jelentett, ezzel az aránnyal az 1000 lapos rajz kérdésenként kb. 1,96 millió token lenne. Ez meghaladja mindkét modell kontextusát (GLM: 1 048 576, Luna: 1 050 000 token az OpenRouter modellistája szerint), ezért az M3-at az 1000 lapos üzemen nem lehetett lefuttatni; ott csak a két gráfos módszert mértük. Ez maga is eredmény: a teljes rajz promptba tétele egy valódi méretű üzemnél nem csak drága, hanem kivitelezhetetlen, a gráfos módszerek viszont ugyanúgy működnek.

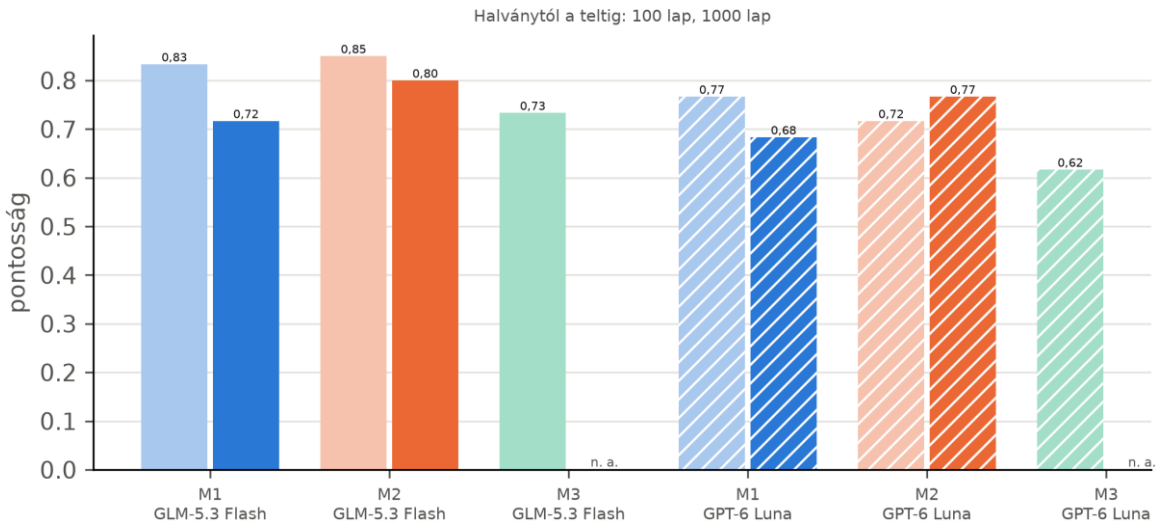
6.5 Eredmény a két tesztüzemen

A hangolt, befagyasztott módszereket mindkét tesztüzem 60 kérdésén (családonként 15) mindegyik párosításon egyszer futtattuk. Az eredményt az alábbi táblázat és ábra mutatja.

6. táblázat: Eredmény a két tesztüzemen párosításonként és családonként (60-60 kérdés; az 1000 lapos üzemen az M3 nem futtatható)

Módszer	Modell	Lap	Helyes	Részben	Rossz	Halluc.	Pontosság [95% CI]	(a)	(b)	(c)	(d)
M1	GLM-5.3 Flash	100	50	4	6	0	0,833 [0,733–0,917]	13	13	9	15
M1	GLM-5.3 Flash	1000	43	6	10	1	0,717 [0,600–0,833]	12	12	5	14
M2	GLM-5.3 Flash	100	51	5	4	0	0,850 [0,750–0,933]	13	12	11	15
M2	GLM-5.3 Flash	1000	48	4	8	0	0,800 [0,700–0,900]	12	10	11	15
M3	GLM-5.3 Flash	100	44	2	14	0	0,733 [0,617–0,833]	11	8	10	15
M1	GPT-6 Luna	100	46	10	4	0	0,767 [0,650–0,867]	14	9	8	15

Módszer	Modell	Lap	Helyes	Részben	Rossz	Halluc.	Pontosság [95% CI]	(a)	(b)	(c)	(d)
M1	GPT-6 Luna	1000	41	14	5	0	0,683 [0,567–0,800]	14	6	6	15
M2	GPT-6 Luna	100	43	10	7	0	0,717 [0,600–0,833]	10	8	10	15
M2	GPT-6 Luna	1000	46	9	5	0	0,767 [0,650–0,867]	12	10	9	15
M3	GPT-6 Luna	100	37	9	14	0	0,617 [0,483–0,733]	13	3	9	12



6. ábra: A pontosság a 100 lapos (halvány oszlop) és az 1000 lapos tesztüzemen (telt oszlop), párosításonként; az 1000 lapos üzemen az M3 nem futtatható (n. a.).

A 100 lapos tesztüzemen GLM-mel az M2 a legjobb párosítás (51 helyes a 60-ból), szorosan mögötte az M1 (50; a különbség −0,017, 95% CI −0,083 és +0,050 között, nem szignifikáns). GLM-mel az M2 szignifikánsan jobb a gráf nélküli M3-nál (+0,117, +0,033 és +0,217 között), az M1 a határon (+0,100, 0,000 és +0,217 között); Lunával az M1 szignifikánsan jobb az M3-nál (+0,150, +0,033 és +0,267 között), az M2 nem (+0,100, −0,033 és +0,233 között).

Az 1000 lapos tesztüzemen is az M2 GLM-mel a legjobb párosítás (48 helyes), utána az M2 Lunával (46), az M1 GLM-mel 43, Lunával 41 helyes választ adott; az M1 és az M2 különbsége egyik modellel sem szignifikáns (GLM-mel −0,083, 95% CI −0,217 és +0,033 között, Lunával −0,083, −0,183 és +0,017 között). A tízszer nagyobb rajzon az M2 GLM-mel 3 kérdéssel, az M1 GLM-mel 7, Lunával 5 kérdéssel kevesebbet oldott meg, mint a 100 lapos üzemen, az M2 Lunával 3-mal többet; a visszaesés főleg az összetett (c) családból jön (az M1 GLM-mel 9 helyett 5 helyes).

A hangolás hatása a tesztüzemen kicsi: a 100 lapos üzemen a hangolás előtti módszerekkel is lefutott ugyanez a mérés, és a helyes válaszok száma párosításonként legfeljebb hárommal tért el (az M2 GLM-mel 54 és 51, Lunával 42 és 43; az M1 GLM-mel 50 és 50,

Lunával 45 és 46). A hangolás tehát a fejlesztési üzemeken látott üres válaszokat csökkentette, a pontosságot a tesztüzemen mérhetően nem változtatta; ez a kis mintán belüli ingadozás nagyságrendje.

6.6 Költség

7. táblázat: Kérdésenkénti költség a két tesztüzemen (USD)

Módszer	Modell	100 lap	1000 lap
M1	GLM-5.3 Flash	0,00416	0,00592
M2	GLM-5.3 Flash	0,00451	0,00866
M3	GLM-5.3 Flash	0,00757	–
M1	GPT-6 Luna	0,01089	0,01272
M2	GPT-6 Luna	0,00248	0,00385
M3	GPT-6 Luna	0,02501	–

A gráfos módszereknél a modellhez csak a lekérdezés eredménye jut el, ezért a kérdésenkénti költségük sokkal lassabban nő, mint a rajz: a 100 és az 1000 lapos üzem között az M2 GLM-mel 0,00451-ről 0,00866 USD-re, Lunával 0,00248-ról 0,00385 USD-re, az M1 GLM-mel 0,00416-ról 0,00592 USD-re, Lunával 0,01089-ről 0,01272 USD-re nőtt, vagyis a tízszer nagyobb rajzon legfeljebb a kétszeresére; ennek okát részletesen nem vizsgáltuk. Az M3 a 100 lapos üzemen GLM-mel 0,00757, Lunával 0,02501 USD-be került kérdésenként, Lunával tízszer annyiba, mint az M2 (0,00248 USD), kevesebb helyes válasszal; a fejlesztési üzemek közül a 30 lapos üzemen még 0,00206, illetve 0,00731 USD volt, az 1000 lapos rajz pedig már nem fér a modellek kontextusába. A késleltetést a tesztüzemeken nem hasonlítjuk össze, mert a válaszok egy része (az M3 válaszai és az M2 rajzi hívásainak egy része) a korábbi futások eltárolt válaszaiból jött.

6.7 Több adatlapos kérdések

Mindkét tesztüzemen lefuttattuk a 12 kérdéses (e) családot is, amelyben a rajzon egy utat, egy elemhalmazt vagy két topológiai lépést kell bejárni, és kettő–hat különböző adatlapot kell összevetni (például: „Along the process flow path from P-2-1 to E-38-1, which item has the lowest maximum allowable pressure according to its datasheet?”, a 100 lapos üzemen). A referenciát program rakta össze a generátor hibátlan gráfjából és a PDF-ekből gyűjtött tényekből.

8. táblázat: A több adatlapos kérdések eredménye a két tesztüzemen (12-12 kérdés)

Módszer	Modell	Helyes, 100 lap	Részben, 100 lap	Helyes, 1000 lap	Részben, 1000 lap
M1	GLM-5.3 Flash	5	2	1	3
M2	GLM-5.3 Flash	4	4	3	5
M3	GLM-5.3 Flash	0	3	–	–
M1	GPT-6 Luna	0	4	0	5
M2	GPT-6 Luna	0	7	1	8
M3	GPT-6 Luna	0	3	–	–

A gráf nélküli M3 a 100 lapos üzemen egyik kérdésre sem adott teljesen helyes választ. GLM-mel a gráfos módszerek 4–5 kérdést oldottak meg teljesen (az M1 és az M3 különbsége +0,417, 95% CI +0,167 és +0,667 között, az M2-é +0,333, +0,083 és +0,583 között), Lunával egyet sem, csak részben (4, illetve 7 kérdés). Az 1000 lapos üzemen ezek a kérdések még nehezebbek lettek: teljesen helyes választ az M2 GLM-mel 3, Lunával 1, az M1 GLM-mel 1, Lunával egy kérdésre sem adott. Az M2 üres válaszai a hangolás után is megmaradtak, de ritkábbak: a 100 lapos üzemen modellenként 2 (a hangolás előtt 3), az 1000 lapos üzemen GLM-mel egy sem, Lunával 1.

6.8 Hibaelemzés

Téves „nincs benne" válaszok. A gráf nélküli módszer jellemző hibája a hamis lemondás, főleg a több adatlapos kérdéseken: az M3 GLM-mel a 30 lapos fejlesztési üzemen 7, a 100 lapos tesztüzemen 5 esetben állította, hogy a dokumentum nem tartalmazza a választ. Ez veszélyesebb, mint amilyennek látszik, mert a „nincs benne" a megválaszolhatatlan kérdéseken helyes, így a (d) családon az M3 jól szerepel, miközben a megválaszolható kérdéseken elbukik.

Az M1 egyetlen lekérdezése. Az M1 hibáinak nagy része „részben helyes" válasz: a kaszkád első szintje egy szűk lekérdezéssel talál egy releváns adatpontot, a kaszkád elfogadja a nem üres eredményt, és a válaszból kimarad egy feltétel vagy egy második érték (példa a Függelék G-ben). Az elfogadási szabály a rajzi kérdésekre készült, ahol a nem üres sorhalmaz jó jelzés; adatlapi kérdésnél a hiányos sor is nem üres.

Az M2 eszközhívásai. Az M2 a rajzeszköznek szabad szöveges kérdést ad, ezért a válasz alakja elcsúszhat (a kis üzemen például a szabályozókör helyett a szelepét adta meg, Függelék G), és a több adatlapos kérdéseknél többször üres választ adott, mielőtt minden elem adatlapját lekérdezte volna (lépéskorlát vagy feldolgozási hiba). A hangolás után ezek ritkábbak lettek (a 100 lapos tesztüzemen modellenként 2).

A referencia korlátja. Az (e) család referenciája óvatos: ha valamelyik elemnek van olyan változata, amelyhez az adatlap nem ad számot, a „legkisebb" elem nem dönthető el, és a bíráló ilyenkor a konkrét elemet megnevező választ is rossznak ítéli. A referenciák általános korlátait a

1. fejezet foglalja össze.

7. Demó és esettanulmány

A mért számok azt mutatják meg, milyen gyakran helyes egy módszer, azt nem, hogyan jut el a válaszig. Ebben a fejezetben bemutatjuk a webes demót, amelyben a három módszer kipróbálható, majd két képernyőképen végigkövetünk két kérdést; a próba további négy kérdését a Függelék F mutatja be. A képek a demó próbáján készültek: hat kérdést tettünk fel a futó demón, az (a), (a), (b), (c), (d) és (e) családból, az M1, M2 és M3 módszerrel, GLM-mel; mind a hat kérdésre érdemi válasz jött. A próba nem pontossági mérés, a válaszokat nem pontoztuk.

7.1 A demó felépítése

A demó egy helyi webalkalmazás: egy webszerver és egyetlen weboldal. A szerver ugyanazokat a módszerobjektumokat építi fel, amelyeket a mérés használ (az első kérdésnél, utána újrahasznosítja őket), így a demó válaszai pontosan azon az úton születnek, amelyet az 5. fejezetben leírtunk. A korábban feltett kérdésekre a demó a már eltárolt válaszokkal is tud felelni, új, fizetős modellhívás nélkül.

Az oldal két részre oszlik.

- **Bal oldal: a dokumentum.** Alapállapotban a P&ID látszik, a generátor rajzexportjából: a fejléc megnevezi a korpuszt (a plantgraph 6-os seedű üzeme), és lapváltó gombokkal a négy lap között lehet lépkedni; a teljes rajz PDF-ben is megnyitható. Ha a felhasználó egy válasz adatlapi forrásoldalára kattint, a bal oldalon az adatlap adott oldala jelenik meg képként, a fejlécben a dokumentum azonosítójával és oldalszámával, valamint egy hivatkozással, amely a PDF-et ennél az oldalnál nyitja meg.
- **Jobb oldal: a kérdés és a válasz.** Egy szövegmezőbe kerül a kérdés; alatta választható a módszer (M1, M2 vagy M3, egy rövid leírással), a modell (GLM-5.3 Flash vagy GPT-6 Luna) és a válaszalak (az 5. fejezetben felsorolt alakok közül). Az alapértelmezés az M2 GLM-mel, mert ez a párosítás volt a legjobb a kis üzem tesztjén (31 helyes a 40-ből; ezt az oldal ki is írja) és a 100 lapos tesztüzemen is (51 helyes a 60-ból). A demó a kis üzemen fut, mert annak négy lapja a képernyőn jól áttekinthető.

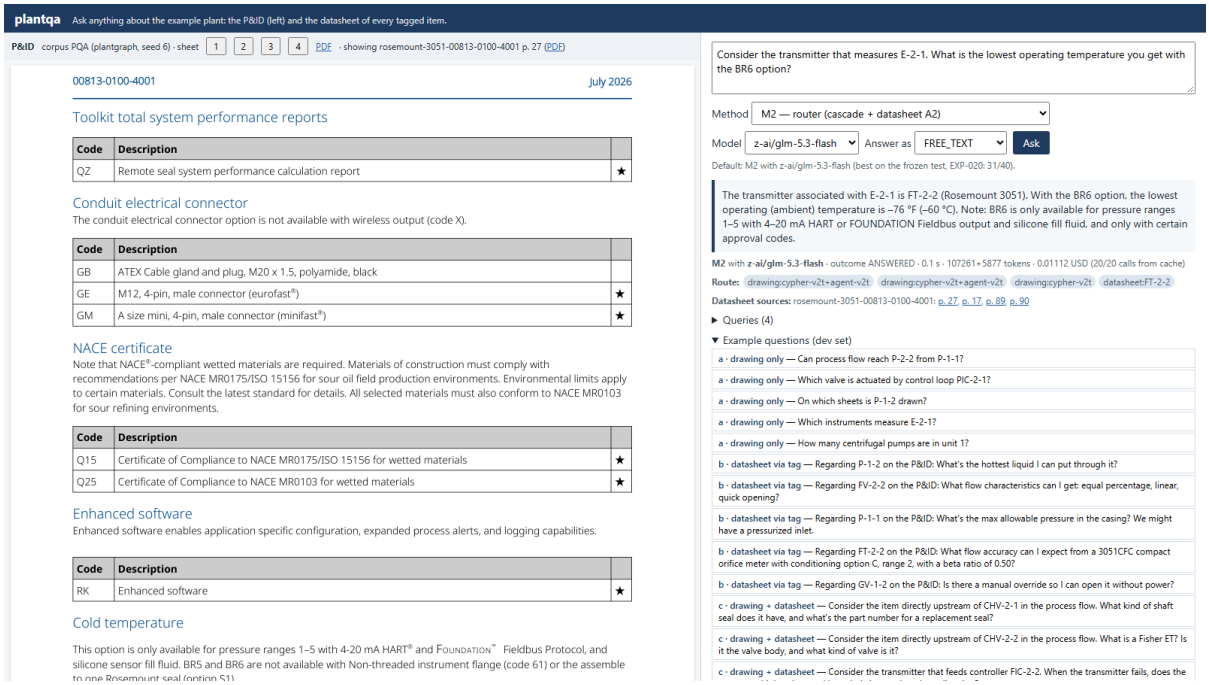
A válasz alatt a demó megmutatja a válasz nyomait: a módszert, a modellt, a kimenetelt, a késleltetést, a tokenszámot, a költséget és a gyorsítótárból jött hívások számát. Ezután következik az útvonal címkék sorozataként (az M1-nél a lefutott szintek és az adatlapi hívások, az M2-nél az irányító eszközhívásai, az M3-nál a kontextus fajtája), az adatlapi forrásoldalak kattintható oldalszámként, és egy lenyitható blokkban a lefutott lekérdezések. Végül a fejlesztési halmaz kérdései szerepelnek példaként, családonként csoportosítva. A teszthalmaz kérdései nincsenek a példák között.

A képernyőképeket egy program készítette: minden kérdést előbb az API-n tett fel, majd fej nélküli böngészővel lefényképezte az oldalt. Ezért a képeken látható késleltetés a gyorsítótárból kiszolgált válaszé; a valódi késleltetést a 6. fejezet adja.

7.2 Két kérdés végigkövetve

Összetett kérdés az irányítóval

Az első kérdés az összetett (c) családból való: „Consider the transmitter that measures E-2-1. What is the lowest operating temperature you get with the BR6 option?” A kérdés a hőcserélőt nevezi meg, a választ viszont a hőcserélőt mérő távadó adatlapja tartalmazza, és ott is csak egy rendelési opcióhoz kötve. A kérdés tehát egy topológiai lépést (melyik műszer méri az E-2-1-et?) és egy feltételes adatlapi tényt (a legalacsonyabb hőmérséklet a BR6 opcióval) kapcsol össze.

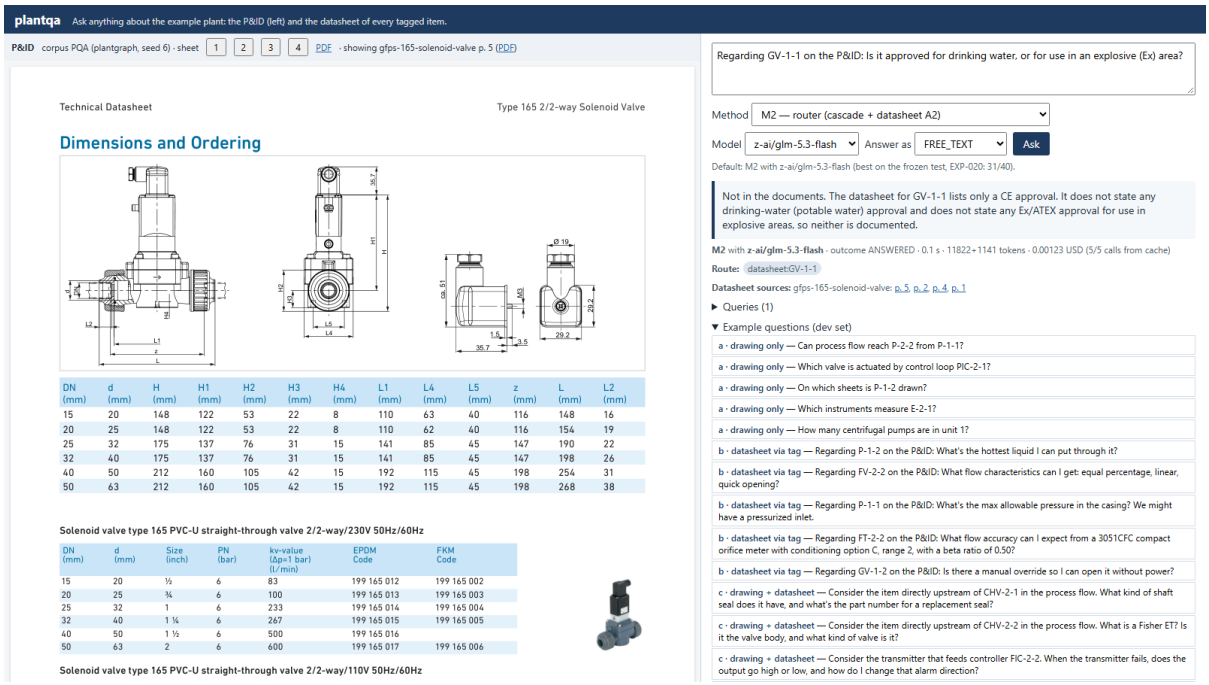


7. ábra: Összetett kérdés az M2-vel: az irányító előbb a rajzeszközt, majd a távadó adatlapját kérdezi; a bal oldalon a válasz egyik forrásoldala a Rosemount 3051 adatlapjából.

Az M2 útvonala: az irányító háromszor kérdezte a rajzeszközt, ebből kétszer a kaszkád az első szintről az ágensig jutott, egyszer már az első szinten zárult; ezután az FT-2-2 adatlapját kérdezte. A válasz így kezdődik: „The transmitter associated with E-2-1 is FT-2-2 (Rosemount 3051).” Ezután megadja a BR6 opcióval elérhető legalacsonyabb környezeti hőmérsékletet Fahrenheit- és Celsius-fokban, és hozzáteszi, hogy a BR6 csak bizonyos nyomástartományokkal, kimenettel és töltőfolyadékkal rendelhető. Ez a plantdocs válaszírójának szabálya: egy érték a feltételei nélkül hibás lehet. A bal oldalon az adatlap azon oldala látszik, amely a hideg környezetre vonatkozó opció feltételeit írja le. Az irányító tehát a tag-et a rajzból szerzi meg, és az adatlapi kérdést már a tag-re teszi fel, ahogy a rendszerüzenete előírja; a rajzeszköz ismételt hívása viszont a késleltetést növeli.

Megválaszolhatatlan kérdés és a részletes „nincs benne”

A második kérdés a (d) családból való, amelynek kérdéseire a dokumentumok nem adnak választ: „Regarding GV-1-1 on the P&ID: Is it approved for drinking water, or for use in an explosive (Ex) area?” A kérdés tag-et nevez meg, ezért az M2 irányítója a rajzeszköz nélkül, közvetlenül a GV-1-1 adatlapját kérdezte (csak az adatlap-eszközt hívta, a GV-1-1 tag-re).



8. ábra: Megválaszolhatatlan kérdés az M2-vel: az irányító közvetlenül az adatlapot kérdezi, a válasz „nincs benne”, de megnevezi, mit tartalmaz az adatlap; a bal oldalon a GF 165 adatlap egyik forrásoldala.

A válasz „nincs benne” jelzésű, de nem áll meg ennyinél: „Not in the documents. The datasheet for GV-1-1 lists only a CE approval. It does not state any drinking-water (potable water) approval and does not state any Ex/ATEX approval…”. A felhasználó így azt is megtudja, mit tartalmaz az adatlap a tanúsításokról, és ellenőrizheti a forrásoldalon. Ez a megjelenítés egy hibajavítás eredménye, amelyet a demó egy korábbi próbája derített ki: a válasz megjelenítése és a bírálónak exportált jelölt szöveg a „nincs benne” jelzésnél eredetileg csak a jelzést mutatta, és elnyelte a mellette írt magyarázatot. A hibát kijavítottuk, az érintett fejlesztési tételeket a javított szöveggel újrabíráltattuk, és a végső teszt exportja már a javított kóddal készült. A demó tehát nemcsak bemutató, hanem ellenőrző eszköz is volt: olyan hibát talált meg, amely a pontozást is érintette.

7.3 Tanulságok

A demó azt mutatja meg, amit a pontossági számok nem: az útvonal és a lekérdezések láthatók, így egy rossz válasz gyorsan felismerhető, és a forrásoldal egy kattintással a rajz helyén jelenik meg.

A demó korlátai: egy új kérdés élő LLM-hívásokba kerül, és másodpercekig tart (a gyorsítótár csak az ismétlést teszi ingyenessé); a demó egyetlen üzemet ismer, mert egy másik üzemhez a teljes összevont betöltést újra kellene futtatni; és angol nyelvű, mint a kérdéssor és a két forrásrendszer promptjai. A demóval és a mérésekkel együtt minden elem a helyén van ahhoz, hogy a következő fejezetben válaszoljunk a kutatási kérdésekre.

8. Összefoglalás

A dolgozatban két egyéni munkát kötöttünk össze: a P&ID-rajzokból épített üzemi gráfot és a gyártói adatlapokból épített, eszközönkénti ISO 15926 szerinti gráfokat. A két réteget egyetlen Neo4j-adatbázisba töltöttük, és a tag-ek alapján összekötöttük. Erre a gráfra három kérdés-válaszoló módszert építettünk egy négylapos prototípus-üzemen, a közös rendszert egy 30 és egy 50 lapos fejlesztési üzemen hangoltuk, majd befagyasztva két modellel megmértük egy 100 és egy 1000 lapos, a hangolás során nem használt tesztüzemen, üzemenként 60 kérdésen és 12, több adatlapot összevető kérdésen.

8.1 Válaszok a kutatási kérdésekre

Az első kérdésre (RQ1) igen a válasz: a rajzokból és az adatlapokból külön épített tudás összeköthető egyetlen lekérdezhető tudásgráfban, a két forrásrendszer módosítása nélkül. A tag alapján húzott összekötő él egyik réteg szerkezetén sem változtat, így a rajzi kapcsolatok és az adatlapi értékek feltételei, lábjegyzetei és forrásoldalai is megmaradnak. Az összevont gráf az 1000 lapos üzemen is felépült: 10 277 rajzi csúcs és 6641 összekötő él jött létre, a betöltés 80,7 másodpercig tartott.

A második kérdésre (RQ2) az a válasz, hogy a mindkét dokumentumfajtát igénylő kérdések nagy része megválaszolható ezen a gráfon. Az összevont gráfon dolgozó M1 GLM-mel 50 és 43, Lunával 46 és 41 helyes választ adott a 60-ból a 100 és az 1000 lapos tesztüzemen. A két meglévő rendszert külön hívó irányító (M2) GLM-mel mindkét tesztüzemen a legjobb volt (51 és 48 helyes), de az M1-től való különbsége nem szignifikáns. A gráf nélküli M3-mal szemben a 100 lapos üzemen GLM-mel az M2, Lunával az M1 előnye szignifikáns. A rajzi (a) és a megválaszolhatatlan (d) kérdéseken minden módszer erős, a különbség az adatlapi (b), az összetett (c) és a több adatlapos (e) kérdéseken jön ki. A több adatlapos kérdések közül a gráf nélküli módszer a 100 lapos üzemen egyiket sem oldotta meg teljesen, a gráfos módszerek GLM-mel 4–5-öt, az 1000 lapos üzemen 1–3-at. A hibák módszerenként jellegzetesek: az M1-nél az egyetlen lekérdezésből adódó hiányos válasz, az M2-nél a több adatlapos kérdéseken a lépéskorlát miatti üres válasz, a gráf nélküli módszernél a téves „nincs benne” jelzés a leggyakoribb.

A harmadik kérdésre (RQ3) az a válasz, hogy a gráfos módszerek jól skálázódnak, a gráf nélküli módszer nem. A gráfos módszerek kérdésenkénti költsége a tízszer nagyobb rajzon legfeljebb a kétszeresére nőtt (az M2 GLM-mel 0,00451 és 0,00866 USD a 100 és az 1000 lapos üzemen), pontosságuk pedig legfeljebb 7 kérdéssel csökkent (az M2 GLM-mel 51-ről 48-ra, az M1 GLM-mel 50-ről 43-ra, az M2 Lunával viszont 43-ról 46-ra nőtt). A gráf nélküli M3 költsége a 30 lapos fejlesztési üzem és a 100 lapos tesztüzem között GLM-mel 0,00206-ról 0,00757 USD-re, Lunával 0,00731-ről 0,02501 USD-re nőtt, az 1000 lapos rajz pedig már nem fér a modellek kontextusába, így ott az M3 nem futtatható. A gráf tehát nemcsak olcsóbbá, hanem nagy üzemen egyáltalán lehetővé teszi a kérdés-válaszolást; ez egybevág a plantgraph korábbi méréseivel, amelyek szerint a teljes rajz promptba tétele a lapszámmal romlik és drágul. A fejlesztési üzemeken végzett hangolás az ott látott üres válaszokat csökkentette, a tesztüzemek pontosságát mérhetően nem változtatta.

8.2 Korlátok

Az eredmények több korláttal együtt érvényesek. Mind az öt üzem szintetikus (4, 30, 50, 100 és 1000 lap): a plantgraph generátora szabályok szerint állította elő őket (egységek, berendezések, csővezetékek, szabályozókörök, lapközi csatlakozók), de nem valódi üzemek rajzai, és a hét adatlap sok tag-et ír le. A generátornak az egyszerűbb változatát használtuk (szivattyúk, hőcserélők, néhány szeleptípus és szabályozókörök), mert csak abban lehet a berendezésfajtákat azokra korlátozni, amelyekhez van adatlapunk, míg a kaszkádot a valósághűbb változat üzemeire hangolták. Az adatlapi kérdések referenciáit egy modell írta a PDF-ből, ember nem ellenőrizte őket; a bíráló is modell (vak, de nem ember), és ugyanazt a választ két bírálat egyszer eltérően ítélte meg. A több adatlapos kérdések referenciája óvatos: ha valamelyik elemnek van olyan változata, amelyhez az adatlap nem ad számot, a „legkisebb" elem nem dönthető el, és a bíráló ilyenkor a konkrét elemet megnevező választ is rossznak ítéli. Végül a minta kicsi: üzemenként és családonként 15 kérdés, egyetlen futás, ezért a konfidenciaintervallumok szélesek, és a pontosság üzemenként néhány kérdéssel ingadozik.

8.3 Továbblépés

A legközvetlenebb javítás az M1 elfogadási szabályának adatlapi kérdésekre szabott változata (például a feltétel és az oldalszám meglétének ellenőrzése), valamint egy olyan első szint, amely a rajzi lépés után az adatlapi részt az adatlapoldali rendszerre bízza. Hosszabb távon a mérést valódi rajzokon, szélesebb adatlapkészlettel és emberileg ellenőrzött referenciákkal kell megismételni.

Irodalomjegyzék

[1] M. Toghraei, *Piping and Instrumentation Diagram Development*. Wiley/AIChE, 2019.

[2] B. A. Christensen, „Preparation of Process Flow Diagrams and Piping and Instrumentation Diagrams”, Mission Support Alliance, US DOE (Hanford), HNF-64103 Rev. 0, 2020.

[3] AIChE ChEnected, „P&ID Part 3 – Symbology Primer”, 2010.

[4] AIChE ChEnected, „P&ID Part 4: Codes, Tags and Labels”, 2010.

[5] ISO 10628-1:2014 (folyamatábrák és P&ID-k), hivatalos előnézet, 1–5.4.3. fejezet.

[6] Mani, Haddad, Constantini, Douhard, Li és Poirier, „Automatic Digitization of Engineering Diagrams Using Deep Learning and Graph Search”, in *Proc. CVPR Workshops*, 2020.

[7] DEXPI e.V., „DEXPI Specification 2.0” (benne a DEXPI P&ID Specification 1.4), 2025. október.

[8] DEXPI e.V., hír, 2026. március 23.: a TotalEnergies a DEXPI szemantikus (BFO- és IDO-igazított) változatán dolgozik.

[9] POSC Caesar Association, „Arrowhead fPVN Handbook and Use Cases”. [Online]. Elérhető: docs.posccaesar.org/libraries-and-standards/arrowhead-handbook/

[10] OPC Foundation, „OPC UA for DEXPI”, OPC 30250 v1.0.

[11] Process Intelligence Research, „pyDEXPI”, szoftver (AGPL-3.0), GitHub: process-intelligence-research/pyDEXPI.

[12] Alimin és Schweidtmann, „GraphRAG for Engineering Diagrams: ChatP&ID Enables LLM Interaction with P&IDs”, *AIChE Journal*, 2026, doi: 10.1002/aic.70540; arXiv:2603.22528.

[13] Alimin, Goldstein, Schulze Balhorn és Schweidtmann, „Talking like Piping and Instrumentation Diagrams (P&IDs)”, arXiv:2502.18928, 2025.

[14] „IDO – Industrial Data Ontology”, korábban ISO/TR 15926-14, ma ISO 23726-3 (IDO v4.2, FDIS, 2026. április).

[15] POSC Caesar Association, „Reference Data Library” (equipment modul 0.9.1, CC BY-SA 4.0). [Online]. Elérhető: rds.posccaesar.org/ontology/plm/rdl/

[16] IOGP JIP36, „CFIHOS – Capital Facilities Information Handover Specification”, Version 2.0.

[17] „QUDT – Quantities, Units, Dimensions and Types”, Release 2.1, CC BY 4.0. [Online]. Elérhető: qudt.org

[18] RWTH Aachen AVT, „OntoCAPE 2.0” (62 OWL-fájl, GPL).

[19] W3C, „Semantic Sensor Network Ontology (SOSA/SSN)”, W3C Recommendation, 2017. október 19.

[20] Industrial Ontologies Foundry, „IOF”, release 202603 (BFO-alapú, MIT-licenc), 2026.

[21] „schema.org”, V30.0, 2026. március 19.

[22] A. Gjerver, R. Frostad, V. Barisic, M. Hodkiewicz, C. Woods, M. Fekete, A. B. Torjusen és J. W. Kluwer, „Machine-interpretable Engineering Design Standards for Valve Specification”, arXiv:2510.01736, 2025.

[23] „HyperRAG”, WWW 2026, arXiv:2602.14470.

[24] „StarE”, arXiv:2009.10847, 2020.

[25] „HyperGraphRAG”, NeurIPS 2025, arXiv:2503.21322.

[26] M. Gupta, C. Wei, T. Czerniawski és R. Eiris, „PIDQA – Question Answering on Piping and Instrumentation Diagrams”, *Machine Learning and Knowledge Extraction*, vol. 7, no. 2, art. 39, 2025, doi: 10.3390/make7020039.

[27] Gadekar, Sakhinana és Runkana, „Grounded and Faithful P&ID Reasoning: Constraining Vision-Language Models with Recovered Evidence Graphs”, arXiv:2609.05880, 2026.

[28] „pid-graph-agent”, GitHub: shaaz1000/pid-graph-agent, szoftver (nem lektorált), 2026.

[29] Kochański *et al.*, „How Everllence Scaled P&ID Intelligence…”, AWS Industries blog, 2026. május 27.

[30] Stürmer, Graumann és Koch, „From Engineering Diagrams to Graphs: Digitizing P&IDs with Transformers”, in *Proc. IEEE DSAA*, 2025; arXiv:2411.13929.

[31] Stürmer, Graumann és Koch, „PID2Graph” adatkészlet, Zenodo, 2025, doi: 10.5281/zenodo.14803338.

[32] Lopomo *et al.*, „Leveraging LLMs and Object Detection for Automated KG Generation from Industrial Schematics”, *Big Data and Cognitive Computing*, vol. 10, no. 7, 210, 2026, doi: 10.3390/bdcc10070210.

[33] Schulze Balhorn, Seijsener, Dao, Kim, Goldstein, Driessen és Schweidtmann, „Rule-based autocorrection of Piping and Instrumentation Diagrams (P&IDs) on graphs”, arXiv:2502.18493, 2025.

[34] Hirtreiter, Schulze Balhorn és Schweidtmann, „Towards automatic generation of P&IDs with AI”, arXiv:2211.05583, 2022; *AIChE Journal*, vol. 70, no. 1, e18259.

[35] Prusty, Agarwal és Iyenger, „Advanced Integration of Discrete Line Segments in Digitized P&ID for Continuous Instrument Connectivity”, arXiv:2505.11976, 2025.

[36] B. Zhu, S. Duong, J. Vyas és M. Mercangoez, „From P&ID Drawings to Process Graphs: A Multimodal Language Model Approach”, arXiv:2607.19568, 2026.

[37] Energy Impact Center, „OPEN100 atomerőmű-terv, P&ID-k”. [Online]. Elérhető: www.open-100.com

[38] Knollmeyer, Caymazer és Grossmann, „Document GraphRAG”, *Electronics*, vol. 14, no. 11, 2102, 2025.

[39] „Golden-Retriever”, arXiv:2408.00798, 2024.

[40] „Structured-data-aware RAG for technical documents”, arXiv:2506.23136, 2025.

[41] Kumar, Motiyani, Kasturi, Seefried, Movva és Ghosal, „Enginuity: A Dataset and Benchmark for Vision-Language Understanding of Engineering Diagrams”, arXiv:2606.03410, 2026.

[42] Xiang *et al.*, „When to use Graphs in RAG” (GraphRAG-Bench), arXiv:2506.05690, 2025.

[43] Fan *et al.*, „GraphRAG-Router”, arXiv:2604.16401, 2026.

[44] „Middleware for LLMs / KBQA-Agent”, arXiv:2402.14672, 2024.

[45] „KG-Agent”, arXiv:2402.11163, 2024.

[46] „Graph-CoT”, arXiv:2404.07103, 2024.

[47] Neo4j, „mcp-neo4j-cypher” (neo4j-contrib/mcp-neo4j), szoftver.

Függelék

A. Példakérdések családonként (fejlesztési halmaz)

9. táblázat: Két példakérdés családonként a fejlesztési halmazból, a referenciaválasz rövidítve

Család	Kérdés	Referenciaválasz (rövidítve)
(a)	Can process flow reach P-2-2 from P-1-1?	no
(a)	Which valve is actuated by control loop PIC-2-1?	PV-2-1
(b)	Regarding P-1-2 on the P&ID: What's the hottest liquid I can put through it?	160 °F (71 °C) maximum liquid temperature (seal limit); the 250 psi max operating pressure applies only up to 100 °F (37 °C); consult the factory beyond.
(b)	Regarding FV-2-2 on the P&ID: What flow characteristics can I get: equal percentage, linear, quick opening?	Standard cages: quick-opening, linear or equal percentage. Whisper Trim, WhisperFlo and Cavitrol cages: linear only.
(c)	Consider the item directly upstream of CHV-2-1 in the process flow. What kind of shaft seal does it have, and what's the part number for a replacement seal?	Mechanical, self-lubricated seal: silicon carbide rotating and stationary faces, fluorocarbon (Viton or equivalent) elastomers, 316 stainless shaft sleeve and s
(c)	Consider the item directly upstream of CHV-2-2 in the process flow. What is a Fisher ET? Is it the valve body, and what kind of valve is it?	A sliding-stem, single-port globe-style control valve (body) with cage guiding, balanced valve plug and push-down-to-close plug action, for throttling or on-off
(d)	Regarding GV-1-2 on the P&ID: It hums but won't open. What could be wrong?	No troubleshooting in the datasheet. Related facts only: it needs at least 0.5 bar differential pressure to open; voltage must match the type plate (±10 %). The
(d)	Regarding PV-2-1 on the P&ID: The valve leaks through when shut. Is it the seat ring or the plug seal, and how do I check?	Not in the document (no troubleshooting).

B. Az M2 irányító rendszerüzenete

```
You answer questions about one industrial plant. You cannot see the documents
yourself; you have two tools:
- drawing(question): answers a question about the plant's P&ID drawing (which items exist
and
  their tags and types, what is connected to what, flow paths, upstream/downstream items,
  which instrument measures what, control loops, units, sheets).
- datasheet(tag, question): answers a question about the vendor datasheet of the item with
  this tag (its specification: pressures, temperatures, materials, sizes, options, ...).
  Items with a datasheet: <24 tags>.
If a question names an item by its position or role (e.g. "the valve downstream of P-1-
1"),
first ask the drawing tool for its tag, then ask the datasheet tool about that tag.
Each turn, reply with exactly one JSON object and nothing else:
{"tool": "drawing", "question": "..."}
{"tool": "datasheet", "tag": "...", "question": "..."}
{"final": {"answer": <answer or null>, "not_present": <true if the documents do not
contain
the answer, else false>}}
```

```
Answer only from the tool results. If the documents give only part of what is asked,
answer with that part and say which part is not stated; set not_present to true only when
they contain nothing relevant. Never add advice, procedures, causes or values that the
documents do not state.
Answer format: <a válaszalakot leíró mondat>
```

C. Az M1 sémakiegészítésének eleje és az adatlap-eszköz leírása

Az M1 lekérdezést író lépése a rajzi réteg leírása után a következő szöveggel kezdődő kiegészítést kapja:

```
DATASHEET LAYER (the same database also holds the datasheet of each tagged item)
- (:PlantItem {tag})-[:DESCRIBED_BY]->(device:Resource) joins a drawn item to the root
node of its
  datasheet graph. Several tags can share one datasheet graph (the same product). An item
without
  DESCRIBED_BY has no datasheet (e.g. a controller function).
- Every datasheet node has the property document_id (one value per datasheet) and a uri
that
  starts with 'urn:plantdocs:<document_id>:'. Parts: (part)-[:lis__partOf]->(device).
- For the facts of a tag: MATCH (p:PlantItem {tag: 'X'})-[:DESCRIBED_BY]->(dev)
  MATCH (d) WHERE d.document_id = dev.document_id AND (d:plm__PCA_100029511 OR
  d:plm__PCA_100029508 OR d:plm__PCA_100029510) ... and filter d by the words of the
question.
The datasheet graphs follow this model:
```

Ezt követi az A2 lekérdezésíró promptjának gráfleírása és szabályai, végül a tag-ek dokumentumonkénti listája. Az ágens adatlap-eszközének leírása, ahogy az ágens látja:

```
Ask the vendor datasheet of the item with this tag (pump, valve, transmitter, heat
exchanger, ...)
one question about its specification, e.g. a pressure or temperature limit, a material, a
size or
an option; returns the datasheet's answer with its PDF pages. Use it for every property
the
drawing does not show; first find the tag on the drawing.
```

D. A két forrásfolyamat részletei

Ez a függelék a 4. fejezetben összefoglalt két forrásfolyamatot írja le olyan részletességgel, amennyi a gráfok szerkezetének megértéséhez kell. A két folyamatot nem módosítottuk.

A plantgraph üzemgenerátora

A plantgraph generátora egy teljes üzemet épít, a lapokra bontó (splitter) lapokra vágja, a feloldó (resolver) a lapokból megoldókulcs nélkül visszaépíti az üzemet, végül a betöltő Neo4j-be tölti. Mivel a bontást a rendszer maga végzi, pontosan tudható, melyik lapközi csatlakozó melyikkel alkot párt, és ehhez mérhető a feloldó.

A generátor minden véletlen döntést egyetlen seedelt véletlenszám-generátoron át hoz meg, ezért ugyanaz a seed ugyanazt az üzemet adja; a kimenet valódi pyDEXPI-modell. Az üzem egységekből (unit) áll. Egy egységen belül a berendezéseket sorban veszi fel, és mindegyik új berendezés véletlenszerűen választ szülőt a már meglévők közül, amelytől anyagáram fut hozzá (véletlen rekurzív fa); így elágazó, nem lánc alakú topológia jön létre. Ezt három, valószínűséggel vezérelt kiegészítés teszi valószerűbbé: egy későbbi berendezésből visszaforgató ág futhat egy korábbiba, minden új egység egy korábbi egység

egyik berendezéséből kap bemenő áramot, és egy korábbi egységből kereszt-kapcsolat is futhat egy későbbi egység belsejébe.

Az áramokra szelepek kerülnek, a berendezésekhez pedig adott valószínűséggel szabályozókör tartozik: mérő (távadó), szabályozó, működtető és a szabályozott szelep. A tag-ek a szokásos betűket követik: a kör változója F, L, P vagy T, a távadó FT-…, a szabályozó FIC-…, a szabályozott szelep FV-…. A generátor terve kifejezetten elveti a véletlen címkéjű véletlen gráfot: a berendezések az áramok végén állnak, a szelepek az áramokon ülnek, a szabályozókörök a berendezésekhez tartoznak, és csak ettől lesz értelme egy „mi táplálja ezt a szivattyút?" kérdésnek. A generátornak két változata van; a mi példaüzemeink az egyszerűbb, első változattal készültek, mert a valósághűbb folyamatmintákat (oszlop, reaktor, biztonsági szelep) adó későbbi változat berendezésosztályai nem szűkíthetők az adatlappal rendelkező osztályokra.

A generátor minden mezőt megjelöl aszerint, hogy látható-e a vizsgált rendszer számára: látható a tag, az osztály, a vezetékszám és a csatlakozó felirata, rejtett a belső azonosító és az áram fajtája, mert ilyen jelölés egy valódi rajzon nincs. Ha egy több lapon felrajzolt berendezés minden előfordulása ugyanazt a belső azonosítót viselné, a feloldónak nem kellene semmit kitalálnia, ezért minden előfordulás átlátszatlan azonosítót kap.

A plantgraph lapokra bontója és a lapközi csatlakozók

A lapokra bontó egy teljes üzemgráfot vág lapokra egy lapkeret szerint, és minden elvágott élre egy lapközi csatlakozópárt illeszt: a forrás lapján egy kimenő, a cél lapján egy bejövő csatlakozót, amelyek felirata megnevezi a partner lapot és csatlakozót. A bontás stratégiája egy közös felület mögött cserélhető: az alapértelmezett a folyamat irányát követi, és a lapot a keretéig tölti; más stratégiák egységek szerint vagy közösségkereséssel vágnak, illetve a segédközegeket külön lapokra teszik; egy véletlen stratégia pedig kontrollként szolgál. A bontó csak lapgráfokat állít elő; a rajzexport külön komponens.

A laphatár kétféle kapcsolatot vághat el, és a bontó mindkettőt előállítja (lásd az alábbi táblázatot). A megoldókulcsot (csatlakozópárok, azonossági csoportok) külön fájlba írja, amely a vizsgált adatbázisba nem kerül be; a lapokból és a megoldókulcsból pontosan az eredeti gráfnak kell visszaállnia.

10. táblázat: A két lapközi mechanizmus

	Lapközi csatlakozó	**Tag-azonosság**
Mi vágódik el	egy cső: egy él két részre	egy elem: egy csúcs két lapon
Visszaállítás	az elvágott él újraösszekötése	a duplikált csúcsok összevonása
Jel a rajzon	a csatlakozó felirata a partner lappal	az elem tag-je
Ha elmarad	a gráf szétesik, a hiba látható	a gráf épnek látszik, a válaszok hiányosak

A példaüzem 4 lapja között 4 lapközi csatlakozópár van; a rajzexportban mind a 8 lapközi jel összekötött.

A plantgraph feloldója

A feloldó bemenete csak a lapok sorozata; a megoldókulcsot nem látja. A csatlakozók feliratából két csatlakozó akkor lesz pár, ha kölcsönösen egymásra hivatkoznak (mindkettő a másik lapját és csatlakozószámát nevezi meg); a maradékot a vezetékszám és a közegkód szerint csoportosítja, és csak akkor párosít, ha egy csoportban pontosan egy kimenő és egy bejövő csatlakozó van. Minden más feloldatlan marad, megnevezett okkal; a feloldó nem találgat.

Az azonossági csoportokat a (tag, osztály) kulcs adja: ha egy ilyen kulcs két vagy több lapon fordul elő, az előfordulások egy elemet jelentenek. Alapértelmezésben csak berendezéseket von össze, és csak pontos egyezéssel. Végül az összefésülés minden csoportot a legtöbb tulajdonságot hordozó előfordulásával helyettesít, a csatlakozópárokon át újraköti az elvágott éleket, a párosítatlan csatlakozókat pedig meghagyja, hogy a hiány a kapuellenőrzésben látsszon. A legfőbb kapu az egyezés: a feloldott üzemnek az eredeti üzem látható nézetével kell megegyeznie; egy átnevezési próba pedig azt ellenőrzi, hogy az eredmény nem függ az átlátszatlan azonosítóktól. A példaüzemen a visszaépítési ellenőrzés hibátlan volt.

Az adatlapok PDF-jei

A hét adatlap valódi, a gyártók által nyilvánosan közzétett PDF: Gorman-Rupp VGH (0700286), Alfa Laval M3, Fisher ET (D100022X012), GF Type 165, Flowserve Worcester F51/F52, Swagelok MS-01-176 és Rosemount 3051 (00813-0100-4001). A forrásoldal-hivatkozások ezeknek a PDF-eknek az oldalszámaira mutatnak.

A plantdocs folyamatának lépései

A plantdocs egy gyártói adatlap PDF-jéből tíz számozott lépésben jut el az ontológia szerinti RDF-gráfig. A lépések felváltva programok és nyelvi modellek; minden nyelvimodell-lépés kimenete csak akkor mehet tovább, ha átmegy egy programmal ellenőrzött formai és tartalmi feltételrendszeren. A programlépéseket egy visszamenőleges teszt újrafuttatja és összeveti a tárolt kimenettel. A lépéseket az alábbi táblázat foglalja össze.

11. táblázat: A plantdocs folyamatának lépései

#	Ki végzi	Mit csinál
1	Azure Document Intelligence	elrendezés-elemzés: oldalelrendezés, táblázatok és ábrák felismerése
2	nyelvi modell	rekordok: paraméter, érték, egység, a táblázatbeli útvonal
3	program, nyelvi modell, program	ábrák kivágása és osztályozása, a betű- és számjelek feloldása
4	program, nyelvi modell, program	diagramoldalak, leolvasás, vektoros ellenőrzés
5	program	a rekordok ellenőrzése a PDF szövegével
6	nyelvi modell, program	célformátum: tények, feltételek, lábjegyzetek, diagramok
7	program	az ábrákhoz tartozó lábjegyzetek
8	program, nyelvi modell, program	forrásleltár és forrásleírások, a végső célformátum

#	Ki végzi	Mit csinál
9	program, nyelvi modell, program	szókészlet: illesztés, hálózati ellenőrzés, szókészlet-térkép
10	program	RDF: IDO és POSC Caesar adatlap-ontológia

Az **1.** lépés az Azure Document Intelligence elrendezés-elemzése (bekezdések, táblázatok, ábrák); a plantdocs ezt adott eszköznek tekinti, nem kutatási hozzájárulásnak. A **2.** lépésben egy nyelvi modell rekordokat ír: paraméter, érték, egység és a táblázatbeli útvonal (táblázatcím, sor- és oszlopfejlécek) a lábjegyzetjelekkel. Ezek még lapos szövegek.

A **3.** lépés az ábrákat kivágja és osztályozza (fénykép, metszeti rajz, méretrajz, diagram), és a rajzokon a betű- és számjeleket alkatrésznevekhez vagy táblázatfejlécekhez köti; amit nem tud feloldani, azt feloldatlanként megtartja. A **4.** lépés a diagramokat olvassa le: egy szelepdiagram üzemi tartományok sokszögeiből, egy görbediagram pontsorozatokból áll; ahol lehet, a leolvasást a PDF vektoros vonalaival ellenőrzi, és a diagram fölötti címsorok feltételeit a diagramhoz rendeli. Az **5.** lépés minden rekord számát megkeresi a hivatkozott PDF-oldal szövegében.

A **6.** lépés hozza létre a célformátumot (lásd alább). Ehhez a plantdocs hibrid módszert használ: a program a rekordok útvonalát szegmensekre bontja, egy nyelvi modell táblázatonként egyszer megadja, melyik szegmens az alany, melyik a feltétel és melyik a tulajdonság (táblázatséma), és egy determinisztikus lépés ezt minden rekordra alkalmazza. Ez olcsóbb, mint rekordonként kérdezni, és egy táblázaton belül következetes. A **7.** lépés az ábrák lábjegyzeteit köti be, a **8.** lépés minden forrásról rövid leírást írat; ezek a lekérdezésnél a szakaszkatalógus sorai lesznek.

A **9.** lépés a szókészlet-illesztés. Egy nyelvi modell minden eszköztulajdonsághoz és feltétel-dimenzióhoz szabványos fogalmat keres, a program minden javasolt azonosítót újra lekérdez a hálózaton, és csak az ellenőrzött illesztés kerül a szókészlet-térképbe. A sorrend rögzített: előbb a POSC Caesar könyvtár pontos vagy tágabb fogalma, ha nincs, a CFIHOS-é; modell- vagy változatkódnál a könyvtár azonosítási osztálya; különben az IDO legáltalánosabb tulajdonság-osztálya (Quality) mint gyűjtő, ahol a pontos jelentést a nyomtatott címke hordozza. A gyűjtőbe kerülő tények aránya az illesztés minőségének jelzője. Az illesztés lefedettségét a plantdocs egy előzetes mérése vizsgálta: négy dokumentum eszköztulajdonságai és feltétel-dimenziói közül 88/133-hoz adott a POSC Caesar könyvtár pontos vagy tágabb fogalmat, a CFIHOS-szal együtt 101/133-hoz (előzetes, kézi ellenőrzésre váró eredmény). Végül a **10.** lépés program: a végső célformátumot és a szókészlet-térképet RDF-gráffá alakítja, és jelentést ír a tények szintek szerinti eloszlásáról.

Az általunk feldolgozott négy adatlapon minden nyelvimodell-kimenet elsőre átment a plantdocs ellenőrzésein.

A plantdocs célformátuma

A célformátum a kinyerés és a gráfépítés között álló, ontológiafüggetlen rekordformátum. Öt elvre épül:

1. Egy rekord egy tény, nem egy nyomtatott cella: ugyanannak a ténynek a két mértékegységben nyomtatott cellája egy rekord két nyomtatott értékkel.
2. A feltételek elsőrendű elemek, egy lista, nem egy név része. Egy tény a feltételei nélkül nem hiányos, hanem hibás.
3. Semmit nem javít csendben: a nyomtatott forma megmarad, a gyanús elírás jelzőt kap, és nem íródik felül.
4. Minden visszakövethető a forrásrekordokig és a PDF-oldalig.
5. A mutató nem érték: a kereszthivatkozás és a lábjegyzetjel típusos, hogy a gráfban él lehessen belőle.

Egy tényrekord részeit az alábbi táblázat foglalja össze.

12. táblázat: Egy tényrekord részei a célformátumban

Rész	Tartalom
alany	az alany, ahogy nyomtatva van, és az alkatrész fajtája
tulajdonság	a tulajdonság nyomtatott neve és egy rövid kulcs
értéktípus	mennyiség, kód, szöveg, hivatkozás, „nem korlátozó” vagy képlet
értékek	szám, egység és a nyomtatott forma (több mértékegységnél több érték)
feltételek	feltétel-dimenziónként a megengedett értékek
lábjegyzetek	a kapcsolódó lábjegyzetrekordok
jelzők	például gyanús elírás, vagy hogy a mértékegység-pár nem egyezik
forrás	dokumentum, PDF-oldal, táblázat

Az értéktípus megkülönbözteti a mennyiséget (erre illeszkedik a QUDT), a kódot (anyagjel, nyomásosztály), a szabad szöveget, a hivatkozást (egy másik táblázatra mutat, értéke nincs), a „nem korlátozó” jelölést (ami információ, nem hiány) és a képletet. A kimeneti fájl hat listát tartalmaz: tények, lábjegyzetek, ábrák, ábra–alkatrész kapcsolatok, diagramok és indoklással kihagyott rekordok; minden bemeneti rekord pontosan egy helyre kerül, semmi nem veszhet el csendben. A lábjegyzetben kimondott tények önálló tények, amelyek a lábjegyzetükre is visszamutatnak.

A plantdocs RDF-modellje

A plantdocs ontológiai döntése az ISO 15926 vonal: az IDO a felső ontológia, a POSC Caesar könyvtára az eszköz- és referenciaszótár, a mértékegység QUDT. A döntés mellett szólt, hogy szabványos és nyílt, és hogy a DEXPI is innen indul; ellene a tanulási görbe, és hogy a könyvtár eszközmodulja nem ad teljes tulajdonságkatalógust. A legfontosabb megkötés az, hogy saját, kézzel írt szókészlet nem lehet: minden osztály és tulajdonság szabványos azonosító, ami pedig a dokumentumból jön (címke, érték, feltétel), az adat, nem szókészlet. Ha nincs pontos szabványos fogalom, a legközelebbi tágabb kerül a gráfba, a pontos jelentést a dokumentum szövege hordozza. A rétegeket az alábbi táblázat mutatja.

13. táblázat: Az adatlapgráf rétegei

Réteg	Szabvány	Mire
Alapfogalmak	IDO	fizikai tárgy, rész–egész, információs tárgy, érték és egység

Réteg	Szabvány	Mire
Adatlap-szerkezet	POSC Caesar adatlap-ontológia	adatlap, bejegyzés (datum), alany, attribútum, eset, szakasz
Eszközosztály	POSC Caesar könyvtár	például szolenoidszelep, centrifugálszivattyú
Tulajdonság, feltétel-dimenzió	POSC Caesar könyvtár, ahol nincs: CFIHOS	például névleges átmérő
Mértékegység	POSC Caesar egységmodul és QUDT	azonosító, illetve mennyiségfajta és átváltás
Egyéb	Dublin Core, SKOS, schema.org	leírás, jelölés, oldalszám

A leképezés a célformátumból a gráfba a következő. Az eszköz az IDO fizikai tárgy osztályának példánya a POSC Caesar eszközosztályával; az alkatrészek szintén fizikai tárgyak, rész–egész kapcsolattal az eszközre. Egy mennyiségi tény mennyiségi adatpont (Quantity Datum) a számmal, a mértékegységgel és tartomány esetén alsó és felső határral; egy szöveges vagy kód jellegű tény attribútum-adatpont (Attribute Datum); ha az érték maga szabványos osztály (például egy anyag), osztályozó adatpont (Classification Datum). Minden adatpont hordozza a nyomtatott címkét és értéket, a PDF-oldalt, az alanyát és, ha van, a szabványos attribútumát.

A feltételek együttese egy esetcsúcs (Case), amelyet a POSC Caesar úgy határoz meg, mint egy helyzetet, amelyen belül bizonyos attribútumértékek érvényesek. A tény egy kapcsolattal az esetre mutat, az eset címkéje felsorolja a feltételeket, és minden egyes feltétel maga is adatpont, amely ugyanerre az esetre mutat, a dimenzió szabványos attribútumával. A forrás (táblázat, ábra, diagram, szövegrész) szakaszcsúcs (Section Datum) a címmel, a 8. lépés leírásával és az oldalszámmal; a lábjegyzet külön adatpont, amelyre a tény kapcsolattal mutat. A diagramok pontjai pontonként egy-egy esetbe kerülnek.

Miért eset, és nem valami más? A feltételes tény n-áris, ezért kell egy csúcs, amely a feltételeket összefogja (2. fejezet). A plantdocs megvizsgált egy saját tény-csúcsot is, de a POSC Caesar adatlap-mintája ugyanezt szabványosan tudja, a saját szókészlet pedig ki volt zárva. Mérlegelte az IDO áram-mintáját is, amely az üzemi környezetet (nyomás, hőmérséklet, közeg) egy áramként modellezi, amelynek a szelep résztvevője; ez azonban egy üzemi helyre vonatkozó előírást ír le, nem egy gyártói adatlap feltételeit. A döntés végül az egységesség volt: minden feltétel-kombináció eset. Ennek ára, hogy az „eset” szót a szabvány elsősorban feltételezett helyzetekre használja, a plantdocs pedig termékváltozatokra és üzemi feltételekre is.

E. A módszerek részletei

Ez a függelék az 5. fejezetben leírt módszerek egyes lépéseit részletezi.

Az ágens gráfműveletei

Az ágens hat általános, egymással kombinálható gráfműveletet hív. A műveletek a feloldó kimenetéből a memóriában épített elemgráfon futnak, amelyben a lapközi csatlakozók és a többszörösen felrajzolt elemek már össze vannak vonva; ez a gráf a betöltött üzemi réteggel egyezik. Az ágens tehát nem látja a laphatárokat, csak az üzemet.

14. táblázat: Az ágens gráfműveletei

Művelet	Mit ad vissza
keresés	a szűrőnek megfelelő elemek (osztálycímke, osztály, egység, lap, tag, fajta szerint)
szomszédok	egy elem közvetlen szomszédai egy relációcsoport mentén
bejárás	bejárás egy kiinduló elemtől, megállási és szűkítő feltétellel
út	út két elem között
szűkítés	egy korábbi eredmény szűkítése a közös szűrőnyelvvel
összesítés	egy korábbi eredmény csoportosítása vagy összesítése

A műveletek eredményei hivatkozást kapnak, így egy korábbi lépés eredménye a következő bemenete lehet. A szűrőnyelv mind a hat műveletnél ugyanaz, és ugyanazokat a típusneveket használja, mint a lekérdezést író lépés sémaleírása; a hangolt rendszer ezt az elem fajtájával és a vonalnézet relációcsoportjával bővítette. A tervezési döntés lényege, hogy az eszközök száma a gráfsémából következik, nem a kérdéstípusokból: a hat művelet a séma szókincsén értelmezett szokásos gráfműveletek (kiválasztás, kiterjesztés, lezárás, legrövidebb út, szűkítés, csoportosítás), ezért egy új kérdéstípus egy új kompozíció, nem egy új eszköz. Az egyszerű, rögzített formájú utasítások minden modellen ugyanúgy működnek, és a gyorsítótár változtatás nélkül vissza tudja játszani őket.

Az adatlapoldali A2 lépései

A plantdocs A2-módszere egy eszköz egy kérdésére a következő lépésekben válaszol.

1. **Kontextus.** A rendszerüzenet a plantdocs gráfmodelljének leírását (a 4. fejezetben bemutatott adatpont-, eset-, szakasz- és lábjegyzetcsúcsokat a szabványos neveikkel), az eszköz gráfjának leltárát (az eszköz és alkatrészei, a leggyakoribb adatpontcímkék, a források oldallal) és a forrásszakaszok katalógusát tartalmazza; a katalógus soronként egy táblázat, ábra, diagram vagy szövegrész a címével, típusával, oldalával, sorainak számával és a 8. lépésben írt leírásával.
2. **Lekérdezésírás.** Egy LLM alacsony gondolkodási szinttel egyetlen csak olvasó Cypher-lekérdezést ír, és mellette legfeljebb három forrásszakaszt választ, amelynek a teljes tartalmára a válasznak valószínűleg szüksége lesz. A lekérdezési szabályok széles keresést kérnek: a kérdés egy szava a címkében, a nyomtatott értékben, az eset címkéjében (a feltételekben) vagy egy forrásszakasz címében és leírásában is lehet; a lekérdezésnek mindig vissza kell adnia a nyomtatott értéket, a címkét, az esetet, a lábjegyzetet, a forrást és az oldalt.
3. **Futtatás és javítás.** Ha a lekérdezés hibát ad, üres, vagy túl sok sort ad vissza, a modell egy javítókörben megkapja a problémát („javítsd vagy bővítsd”, illetve „szűkítsd a legjellemzőbb szavakra”). Ha a választott szakaszokból jött sor, javítókör nincs; ha a javítás üres eredményt ad, az első, nem üres eredmény marad.
4. **Teljes szakaszok.** A kiválasztott szakaszok minden sora a lekérdezés sorai mellé kerül; ez azt az esetet fedi le, amikor a táblázat fejlécei nem a kérdés szavait használják.
5. **Vektoros keresés.** A lekérdezésírással párhuzamosan a kérdés beágyazásvektorához legközelebbi 30 adatpont kerül elő a gráf vektorindexéből,

mindegyik az esetével, a lábjegyzetével, az oldalával és a forrásszakaszával. Mivel párhuzamosan fut, a késleltetéshez nem ad hozzá.

6. **Válaszírás.** A válaszíró csak a megtalált tényekből fogalmaz: előbb egy-két mondatban a közvetlen választ, utána az értékeket az egységükkel és azokkal a feltételekkel, amelyek mellett érvényesek, oldalhivatkozással. A kérdést abban az értelemben kell olvasnia, ahogy az adatlap használja a szavait; egy szakkifejezést néhány szóval megmagyarázhat, de új tényt, értéket vagy eljárást nem tehet hozzá; ha a kérdés egy része nincs a tények között, ezt kimondja. A forrásoldalakat a program a felhasznált sorokból gyűjti össze.

Az M1 sémakiegészítésének felépítése

A sémakiegészítés első része az összekötést írja le: az összekötő él nélküli elemnek (például egy szabályozófunkciónak) nincs adatlapja, minden adatlapcsúcs hordozza a dokumentumazonosítót, és egy tag tényei egy rögzített mintával érhetők el. Ezt követi az A2 lekérdezésíró promptjának gráfleírása szó szerint, a dokumentumok és tag-jeik listája, végül az A2 lekérdezési szabályai, amelyek a prototípus második fejlesztési iterációjában kerültek be. A sémakiegészítés elejét a Függelék C mutatja.

Az M2 irányító protokollja

A rendszerüzenet leírja a két eszközt, felsorolja az adatlappal rendelkező tag-eket, megadja a három megengedett JSON-alakot (rajzeszköz-hívás, adatlap-hívás, végső válasz a „nincs benne” jelzővel) és a válaszalakot. Az irányító minden lépésben pontosan egy utasítást ír; a program végrehajtja a hívást, és az eredményt egy új üzenetben adja vissza. Érvénytelen utasításra az irányító javító üzenetet kap; ha a 16 lépéses keret elfogy, egy utolsó hívásban köteles végső választ adni a már összegyűjtött eredményekből (a prototípusban ilyenkor a kérdés lépéskorlát-eredménnyel zárult). Szolgáltatói hibánál (például hálózati hibánál) a hívás egyszer újrapróbálkozik, ahogy a kaszkád is; ha ez is hibás, a kérdés szolgáltatói hibával zárul, és rossznak számít. Az irányító alacsony gondolkodási szinttel fut. A rendszerüzenet teljes szövegét a Függelék B tartalmazza.

A módszerek várható erősségei és gyengeségei

Az alábbiakban a módszerek felépítéséből következő, minőségi várakozásokat foglaljuk össze; a 6. fejezet eredményeit ezek fényében érdemes olvasni.

M1

Az M1 erőssége, hogy egy összetett kérdés elvben egyetlen lekérdezéssel megválaszolható: a rajzi lépés és az adatlapi tény ugyanabban a mintában szerepel, így nincs szöveges átadás két rendszer között, és a válasz minden eleme visszakövethető egy csúcsig. Az ágensszint az adatlap-eszközzel ugyanazt az A2-logikát éri el, mint az M2, tehát ahol a első szint elakad, ott az M1-nek az M2-höz hasonló képességei vannak.

A gyengeségei ugyanebből fakadnak. A Cypher-író modellnek egyszerre két szókincset kell kezelnie: a rajzi réteg olvasható osztályneveit és az adatlapi réteg számkódos szabványos neveit. A sémaszöveg ettől hosszú, ami minden kérdés költségét növeli, akkor is, ha a kérdés csak a rajzról szól. A legnagyobb kockázat az elfogadási szabály: a rajzi kérdéseken a nem üres, nem csonka eredmény jó jelzés, egy adatlapi kérdésnél viszont egy szűk lekérdezés is adhat nem üres, de hiányos sort (például egy értéket a feltétele nélkül), amelyet a kaszkád

elfogad, és az ágens nem kap esélyt. Végül a válaszlépés a rajzi kérdésekre készült, és nem tartalmazza az adatlapi válaszíró szabályait (feltételek kiírása, oldalhivatkozás).

M2

Az M2 erőssége a modularitás: mindkét rendszer abban a beállításban fut, amelyben korábban mérték, az adatlapi válasz a plantdocs teljes A2-láncán megy át (szakaszválasztás, vektoros keresés, a feltételeket kiíró válaszíró), és egy új dokumentumtípus egy új eszközzel bővíthető. Az útvonal átlátható: a naplóból látszik, melyik eszközt milyen kérdéssel hívta az irányító.

A gyengesége az illesztésben van. A két rendszer szöveggel kommunikál, így a rajzeszköz válaszának alakja elcsúszhat, és a irányító félreértheti; az összetett kérdés helyes felbontása is a irányítón múlik. Mivel az eszközhívások egymás után futnak, és mindegyik maga is több LLM-hívás, a késleltetés a három módszer közül várhatóan itt a legnagyobb.

M3

Az M3 erőssége az egyszerűség: egyetlen hívás, nincs lekérdezés, amely elromolhat, és nincs elfogadási szabály, amely rossz választ engedhet át. Egy kis rajzon a teljes gráf elfér a promptban, és a modell mindent lát; az adatlapi kérdéseknél a kérdés szavaihoz közeli szövegrészek gyakran éppen a keresett táblázatot tartalmazzák.

A gyengesége a méret és a szerkezet. A plantgraph mérései szerint a teljes rajz promptba tétele a lapszámmal romlik és drágul, egy határ fölött pedig nem is fér el (2. fejezet), ezért az M3 előnye nagyobb üzemen nem várható. Az adatlap-darabok a táblázatokat szövegként, a fejlécektől elszakítva tartalmazhatják, a feltételek és a lábjegyzetek nem explicitek, és a vektoros keresés egy több eszközt érintő kérdésnél elhanyagolhatja valamelyik eszköz adatlapját. Az M3 a forrásoldalakat csak darabszinten tudja megadni.

Útvonalak a tesztüzemeken

Az M1 GLM-mel a 100 lapos tesztüzemen a 60 kérdésből 31-et már az első szinten zárt le, 9-hez az ágens is kellett adatlap-hívás nélkül, 20-hoz az ágens és legalább egy adatlap-lekérdezés; Lunával 34, 5 és 21. Az 1000 lapos üzemen ugyanez GLM-mel 31, 11 és 18, Lunával 39, 6 és 15. Az M2 nagyjából harmadolta a kérdéseket a csak rajzi, a csak adatlapi és a mindkét eszközt hívó útvonal között (a 100 lapos üzemen GLM-mel 19, 17 és 24, Lunával 21, 18 és 21; az 1000 lapos üzemen 25, 15 és 20, illetve 21, 19 és 20), ami a kérdéscsaládok megoszlásával egyezik.

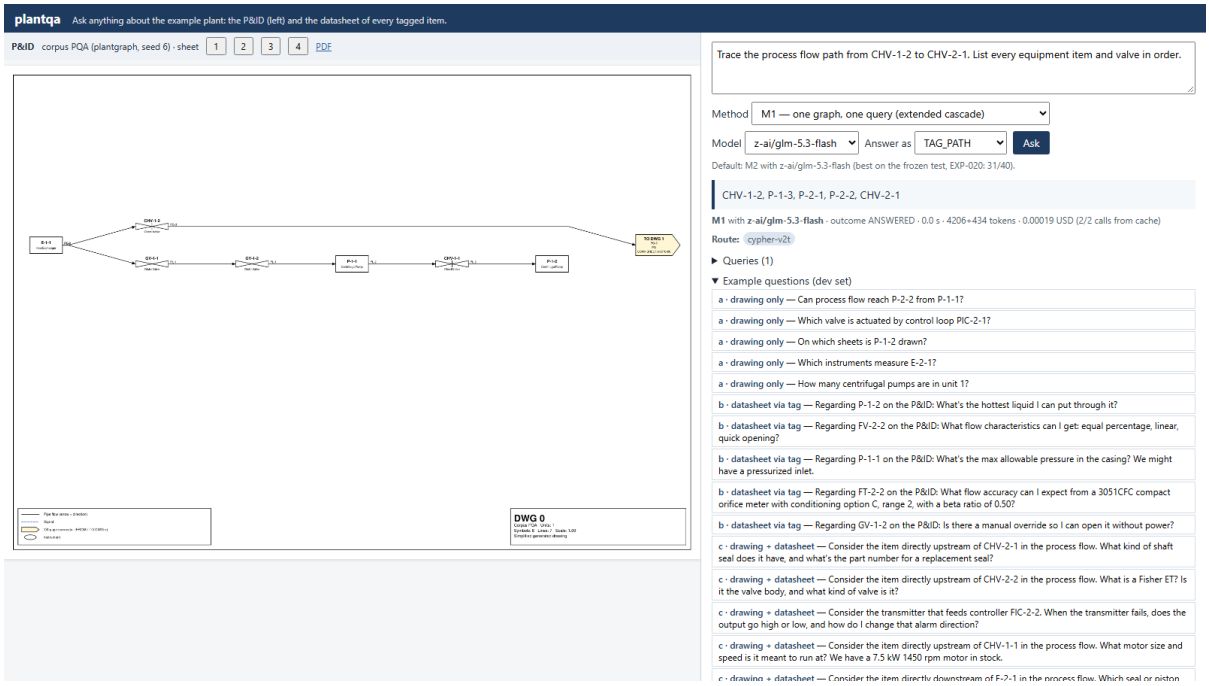
F. További demó-képernyőképek

A 7. fejezetben bemutatott demópróba további kérdései közül kettőt képernyőképpel, kettőt képernyőkép nélkül követünk végig.

Rajzi útvonal egyetlen lekérdezéssel (M1)

A demó próbájának egy további kérdése a rajzi (a) családból való, rendezett út válaszalakkal: „Trace the process flow path from CHV-1-2 to CHV-2-1. List every equipment

item and valve in order.” Az M1-gyel feltéve a kaszkád már az első szinten zárult, egyetlen lekérdezéssel, és a válasz egy tagsorozat: „CHV-1-2, P-1-3, P-2-1, P-2-2, CHV-2-1”.

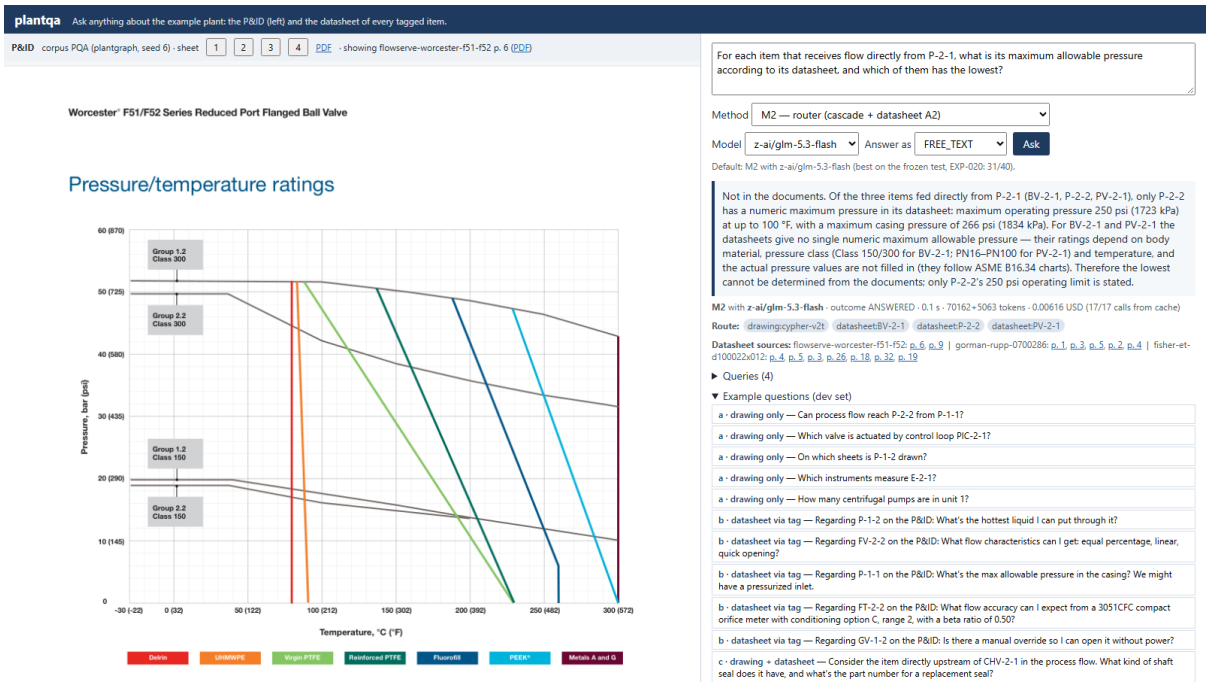


9. ábra: Rajzi útvonal az M1-gyel: a kaszkád első szintje egyetlen lekérdezéssel adja a rendezett utat; a bal oldalon a P&ID egyik lapja, a jobb szélén a lapközi csatlakozóval.

A bal oldalon a rajz egyik lapja látszik. A CHV-1-2 szelepből induló vezeték a lap jobb szélén egy lapközi csatlakozóban végződik, vagyis az út egy másik lapon folytatódik. A rajzon ezt az olvasónak kell követnie; az üzemi rétegben viszont a laphatár átlépése egyetlen él (4. fejezet), ezért a kaszkád első szintje egyetlen lekérdezéssel megtalálta a teljes utat, és a kaszkád az elfogadási szabálya szerint (válaszolt, nem tartózkodott, van sor, nem csonka) elfogadta.

Több adatlapos kérdés (M2)

Egy másik kérdés a külön mért, több adatlapos (e) családból való: „For each item that receives flow directly from P-2-1, what is its maximum allowable pressure according to its datasheet, and which of them has the lowest?” A kérdés egy halmazt kér a rajzból (mi kap közvetlenül áramot a P-2-1-ből?), majd a halmaz minden elemére egy adatlapi értéket, végül egy összevetést.



10. ábra: Több adatlapos kérdés az M2-vel: egy rajzi hívás után három adatlapi hívás; a bal oldalon a Worcester gömbcsap adatlapjának nyomás–hőmérséklet diagramja.

Az M2 útvonala: egy rajzeszköz-hívás, amely már az első szinten zárult, majd három adatlap-hívás a BV-2-1, a P-2-2 és a PV-2-1 tag-re, vagyis egy gömbcsap, egy szivattyú és egy szabályozószelep adatlapjára. A válasz „nincs benne” jelzésű részválasz: „Of the three items fed directly from P-2-1 (BV-2-1, P-2-2, PV-2-1), only P-2-2 has a numeric maximum pressure in its datasheet…” A folytatás szerint a másik két elem adatlapja nem ad egyetlen számszerű határt, mert a névleges nyomás a testanyagtól, a nyomásosztálytól és a hőmérséklettől függ, ezért a legkisebb érték a dokumentumokból nem dönthető el. A bal oldali nyomás–hőmérséklet diagram éppen ezt a függést mutatja.

Ez a válasz az 5. fejezetben leírt válaszszabály működését mutatja: a módszer a meglévő részt adja, és megnevezi a hiányzót, ahelyett hogy egy értéket találna ki. Hogy a válasz helyes-e, azt a próba nem pontozta.

Két további kérdés képernyőkép nélkül

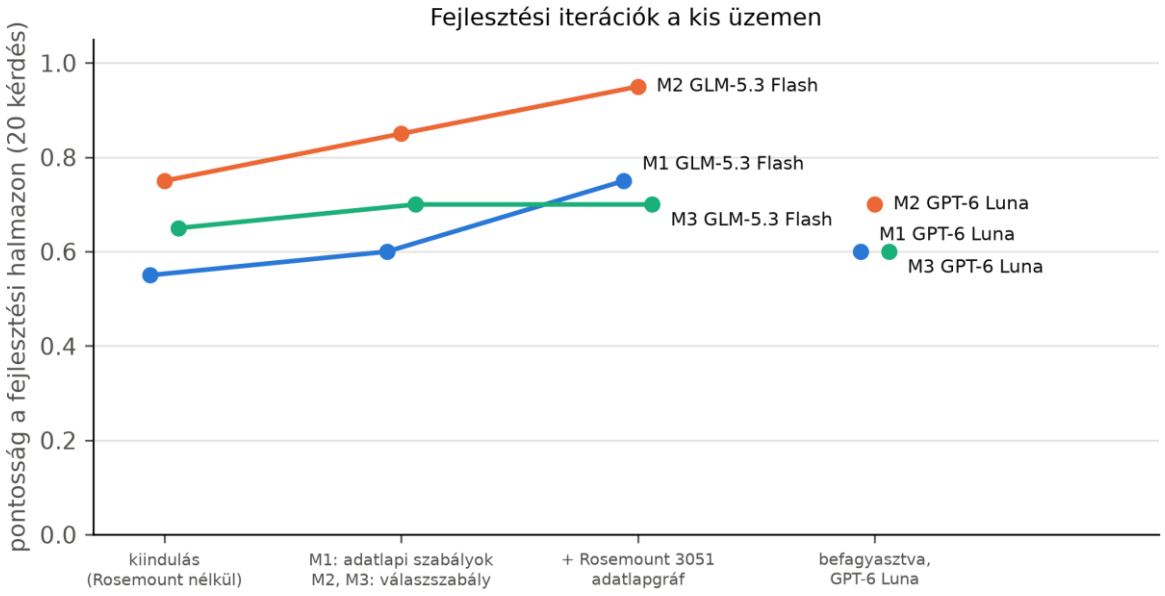
Az adatlapi (b) kérdésre („Regarding P-1-3 on the P&ID: What's the max allowable pressure in the casing? …”) az M1 már az első szinten, egyetlen lekérdezéssel válaszolt; a rajzi (a) kérdésre („Which instruments measure E-2-1?”) az M3 egyetlen hívással az FT-2-2 tag-et adta.

G. A kis üzem mérései

Ez a szakasz az első prototípus mérését írja le: a módszerek első változatát a négylapos kis üzemen fejlesztettük és fagyasztottuk be, és ott mértük meg (változatlan számokkal). A közös rendszert ezután a 30 és 50 lapos fejlesztési üzemen hangoltuk (5. fejezet).

Fejlesztési iterációk

A fejlesztési halmazon (20 kérdés) négy iterációt mértünk (lásd az alábbi ábrát). Az első iterációban a Rosemount 3051 gráfja még nem készült el, ezért a nyomás- és áramlástávadóra vonatkozó adatlapi kérdések egyik gráfos módszerrel sem voltak megválaszolhatók. A második iterációban az M1 lekérdezést író lépése megkapta az A2 lekérdezési szabályait (széles keresés, eset, lábjegyzet és oldal visszaadása), az M2 és az M3 pedig egy válaszszabályt (részválasznál a meglévő rész és a hiányzó rész megnevezése, a dokumentumon túli tanács tilalma); az M2 és az M3 hallucinációi ezzel eltűntek. A harmadik iterációban a Rosemount-gráf is bekerült: az M1 pontossága 0,60-ról 0,75-re, az M2-é 0,85-ről 0,95-re nőtt, az M3-é nem változott, mert nem használja a gráfot. A negyedik iterációban a befagyasztott módszereket GPT-6 Lunával mértük: M1 0,60, M2 0,70, M3 0,60.



11. ábra: A fejlesztési halmazon mért pontosság iterációnként.

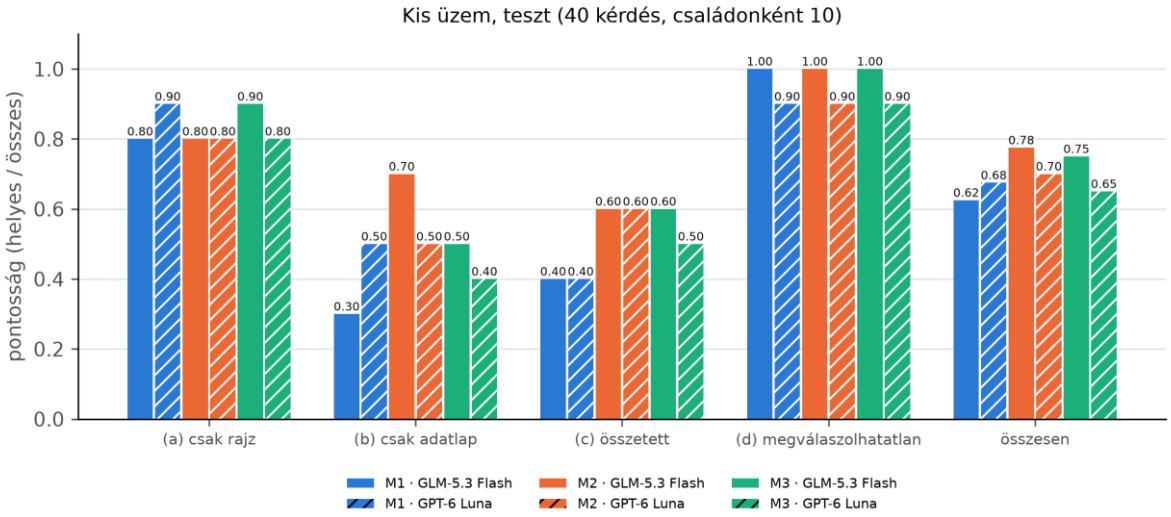
Végső mérés a teszthalmazon

A befagyasztott teszthalmaz (40 kérdés, családonként 10) mindegyik párosításon egyszer futott le. Az eredményt az alábbi táblázat és ábra mutatja.

15. táblázat: A végső teszt eredménye párosításonként és családonként

Módszer	Modell	Helyes	Részben	Rossz	Hallucinált	Pontosság [95% CI]	(a)	(b)	(c)	(d)
M1	GLM-5.3 Flash	25	9	6	0	0,625 [0,475–0,775]	8/10	3/10	4/10	10/10
M2	GLM-5.3 Flash	31	6	3	0	0,775 [0,625–0,900]	8/10	7/10	6/10	10/10
M3	GLM-5.3 Flash	30	1	9	0	0,750 [0,600–0,875]	9/10	5/10	6/10	10/10
M1	GPT-6 Luna	27	6	7	0	0,675 [0,525–0,825]	9/10	5/10	4/10	9/10

Módszer	Modell	Helyes	Részben	Rossz	Hallucinált	Pontosság [95% CI]	(a)	(b)	(c)	(d)
M2	GPT-6 Luna	28	7	5	0	0,700 [0,550–0,850]	8/10	5/10	6/10	9/10
M3	GPT-6 Luna	26	6	8	0	0,650 [0,500–0,800]	8/10	4/10	5/10	9/10



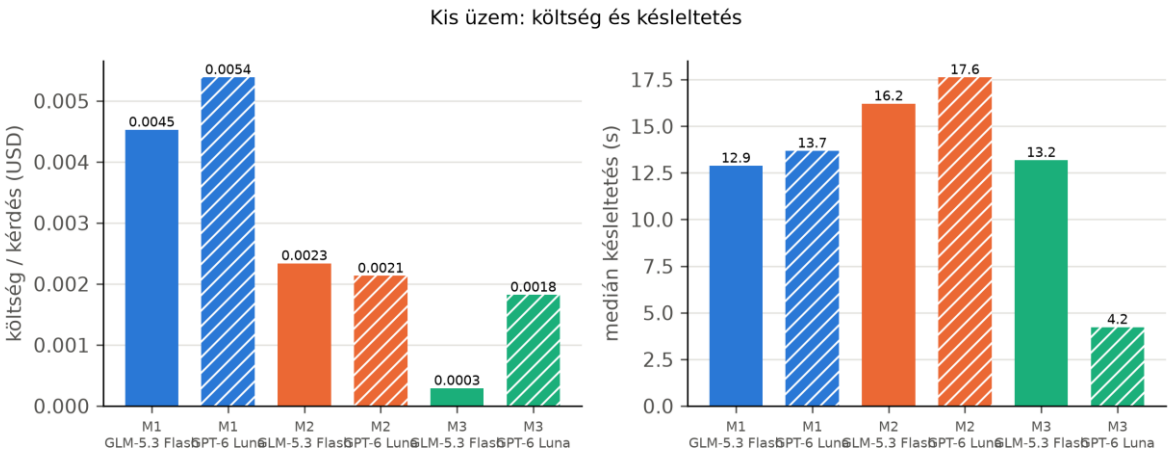
12. ábra: A végső teszt pontossága családonként, a hat párosításon.

A legjobb párosítás az M2 GLM-mel (31 helyes a 40-ből). GLM-mel az M1 szignifikánsan elmarad mind az M2-től (párosított különbség −0,150, 95% CI −0,275 és −0,025 között), mind az M3-tól (−0,125; −0,225 és −0,025 között), az M2 és az M3 különbsége viszont nem szignifikáns (+0,025; −0,075 és +0,125 között). Lunával egyik különbség sem szignifikáns. Egyik párosítás sem hallucinált a teszten; a megválaszolhatatlan kérdéseken (d) mindegyik módszer 9 vagy 10 helyes választ adott. A különbség a (b) és (c) családon jön ki: az adatlapi kérdéseken az M2 GLM-mel 7/10, az M1 GLM-mel 3/10.

Költség és késleltetés

16. táblázat: Költség, késleltetés és tokenhasználat kérdésenként a végső teszten

Módszer	Modell	Költség / kérdés (USD)	Medián késleltetés (s)	Átlagos bemeneti token / kérdés	Átlagos kimeneti token / kérdés
M1	GLM-5.3 Flash	0,00453	12,9	81 492	3 940
M2	GLM-5.3 Flash	0,00234	16,2	33 068	2 221
M3	GLM-5.3 Flash	0,00029	13,2	13 264	1 820
M1	GPT-6 Luna	0,00539	13,7	56 398	1 578
M2	GPT-6 Luna	0,00213	17,6	35 765	1 115
M3	GPT-6 Luna	0,00182	4,2	12 901	425

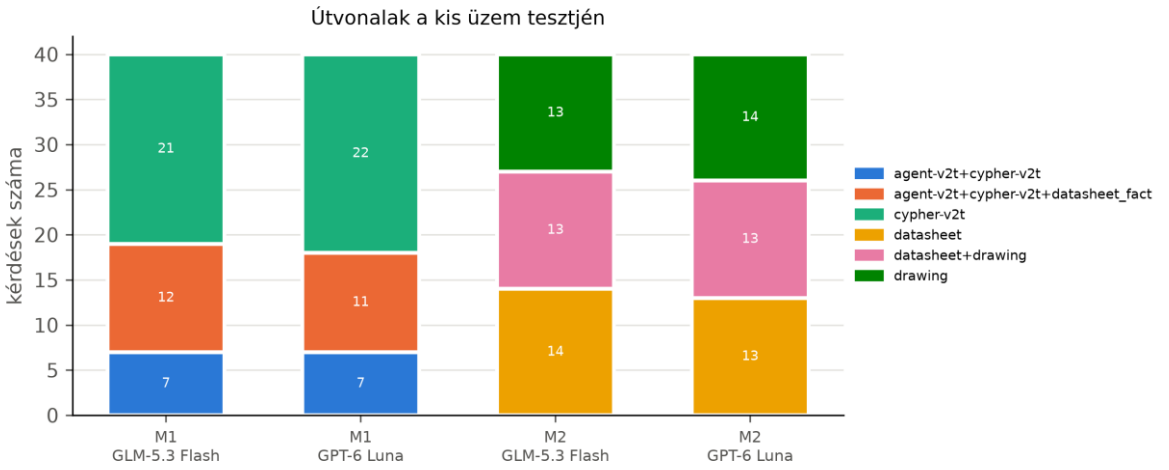


13. ábra: Kérdésenkénti költség és medián késleltetés; két külön panel, mert a két mennyiség skálája eltér.

A legdrágább az M1: a kaszkád első szintje a teljes kétrétegű sémát kapja promptban, és ha nem fogadják el a válaszát, az ágens is lefut, amely tag-enként külön adatlap-hívásokat indít. Az M2 GLM-mel körülbelül feleannyiba kerül (0,00234 vs. 0,00453 USD), Lunával 40%-ába (0,00213 vs. 0,00539 USD), mert csak a szükséges eszközt hívja. Az M3 a legolcsóbb, és Lunával a leggyorsabb is: egyetlen hívás, de a teljes rajzot és tizenkét adatlap-darabot viszi magával. Ez a példaüzemen olcsó, mert a rajz kicsi (36 csúcs); a plantgraph mérései szerint a teljes rajz promptba tételének költsége a lapszámmal meredeken nő (a valósághűbb generátor üzemein 1 lapon a kaszkád 3,79-szerese, 11 lapon 21,57-szerese, és kb. 62 lap fölött a rajz már nem fér a promptba), ezért az M3 előnye nagyobb üzemen nem várható.

Útvonalak

Az M1 GLM-mel a 40 tesztkérdésből 21-et a Cypher-szinten zárt le, 7-hez az ágens is kellett adatlap-hívás nélkül, 12-höz az ágens és legalább egy adatlap-hívás; Lunával ugyanez 22, 7 és 11. Az M2 GLM-mel 13 kérdésnél csak a rajzot, 14-nél csak az adatlapot, 13-nál mindkettőt kérdezte; Lunával 14, 13 és 13.



14. ábra: Az M1 és az M2 útvonalai a végső teszten.

Összetett, több adatlapos kérdések

A végső teszt után egy kiegészítő mérést is végeztünk 12 olyan kérdésen, amelyekhez a rajzon egy utat, egy elemhalmazt vagy két topológiai lépést kell bejárni, és két-három különböző adatlapot kell összevetni (például „Along the process flow path from E-1-1 to CHV-2-1, which item has the lowest maximum allowable pressure according to its datasheet?”). A referenciát program rakta össze a generált üzem pontos leírásából és egy nyelvi modell által a PDF-ekből gyűjtött tényekből; négy kérdésnél a helyes válasz az, hogy a rajz nem mondja meg a beépített változatot, ezért a legkisebb érték nem dönthető el. A kérdéseket futtatás előtt befagyasztottuk, és a módszereken semmit nem változtattunk.

17. táblázat: Az összetett, több adatlapos kérdések eredménye (12 kérdés)

Módszer	Modell	Helyes	Részben	Rossz	Hallucinált	Költség / 12 kérdés (USD)	Medián késleltetés (s)
M1	GLM-5.3 Flash	0	5	6	1	0,0636	61,9
M2	GLM-5.3 Flash	3	6	3	0	0,0537	34,3
M3	GLM-5.3 Flash	0	2	10	0	0,0046	25,6
M1	GPT-6 Luna	0	6	6	0	0,0880	28,2
M2	GPT-6 Luna	1	9	2	0	0,1280	38,6
M3	GPT-6 Luna	0	0	12	0	0,0276	13,6

Ezek a kérdések mindegyik módszernek nehezek: teljesen helyes választ csak az irányító adott (GLM-mel 3, Lunával 1 kérdésre), a bíráló pedig „részben helyes” ítéletet adott, ha egy elemnél a második érték vagy a feltétel hiányzott. Ha a részben helyes válaszokat is számítjuk, az irányító GLM-mel 9, Lunával 10 kérdésnél adott legalább részben jó választ, az M1 5, illetve 6, a gráf nélküli alapmódszer 2, illetve 0 kérdésnél. A különbség itt a legnagyobb: több adatlap összevetéséhez a rajzon kell bejárni az elemeket, majd mindegyik adatlapját külön lekérdezni, és ezt az irányító eszközhívásai természetesen leképezik, az egyetlen lekérdezés (M1) és az egyetlen prompt (M3) viszont nem.

Hibaelemzés

Az M1 egyetlen lekérdezése. Az M1 hibáinak nagy része „részben helyes” válasz: a Cypher-szint egy szűk lekérdezéssel talál egy releváns adatpontot, a kaszkád elfogadja a nem üres eredményt, és a válaszból kimarad egy feltétel vagy egy második érték. A fejlesztési halmazon például a szivattyú 266 psi-s burkolatnyomása megvolt, a 100 °F-ig érvényes 250 psi-s üzemi határ nem. Az elfogadási szabály a rajzi kérdésekre készült, ahol a nem üres sorhalmaz jó jelzés; adatlapi kérdésnél a hiányos sor is nem üres.

A rajzi kérdések közös hibái. A teszt (a) családjában három kérdést több párosítás is elrontott. Az izolációs kérdésnél („To isolate P-1-5 from all upstream equipment, which valves must be closed?”) a referenciaválasz egyetlen szelep, a módszerek többsége a felfelé eső összes szelepet felsorolta. A szabályozókörös kérdésnél („Which control loops act on

valves directly connected to P-2-1?") az M2 mindkét modellel a szelepet (PV-2-1) adta meg a kör (PIC-2-1) helyett: az irányító a rajzeszköznek szabad szöveges kérdést ad, és a válasz alakja ott elcsúszott. A P-2-1-ből lefelé eső elemek halmazánál az M1 GLM-mel és az M3 Lunával hiányos listát adott.

Megválaszolhatatlan kérdések. GLM-mel mindhárom módszer mind a 10 kérdést felismerte, Lunával 9-et; hallucináció nem volt. A három Luna-hiba: az M3 egy nem létező tag-re (P-2-4) utat adott meg, az M2 egy nem létező tag-re (FV-2-3) üres listát adott a „nincs benne" jelzés nélkül, az M1 pedig egy adatlapban nem szereplő tényre jelzés nélkül válaszolt (részben helyes).

A referencia korlátja. A (b)–(d) család referenciaválaszait egy modell írta a PDF-ből, és ember nem ellenőrizte őket; a bíráló ugyanazt a referenciát látta minden módszernél, ezért az összevetés igazságos, de az abszolút számok a referencia hibáival együtt értendők.